



인공지능시대의 윤리

인공지능의 편향성



1

편향의
개념과
발생 원인

편견과 편향의 구분

편견

개인의 심리적 고정관념

편향

시스템 구조가 한쪽으로 기울어진 상태

알고리즘 편향의 정의

- 학습 데이터와 설계 과정에서 불공정성이 개입됨
- 선택 · 분류 · 활용 기준에 **인간의 가치판단이 포함됨**
- 의도하지 않아도 차별적 결과가 발생함

2

데이터
편향 사례와
사회적 영향

데이터 불균형의 문제

- ① 과거 데이터가 사회적 차별을 반영함
- ② AI가 왜곡된 현실을 정상으로 학습함
- ③ 편향이 반복 · 강화되는 구조를 가짐

대표적 기술 사례

- 구글 이미지 분류 AI가 인종 차별 오류를 발생시킴
- 니콘 얼굴 인식이 특정 인종을 오인식함

사회적 확산 효과

- 편향된 AI가 더 극단적인 편향을 재생산함
- 피해가 **사회적 약자에게 집중됨**
- 기술 문제가 아닌 **사회 구조 문제로 확장됨**

3

알고리즘
설계 편향과
제도적 문제

설계 단계의 은폐된 가치판단

- 알고리즘은 중요 변수와 기준을 선택함
- 설계자의 세계관과 사회 전제가 반영됨
- 객관성 뒤에 **인간 개입**이 숨겨짐

공공 · 금융 영역 사례

컴파스

- ▶ 형사 사법 영역에서 인종 편향을 재현함

EVAAS

- ▶ 교육 평가의 공정성을 훼손함

애플카드

- ▶ 성별 편향 논란을 야기함

투명성 부족의 위험

- 결정 근거가 설명되지 않는 **블랙박스 발생**함
- 알고리즘 불투명성이 **차별을 은폐**함
- 책임 소재가 불명확해짐



윤리적 대응 방안

맥락을 고려한 설계

- ▶ AI 사용 목적과 사회적 영향을 함께 고려함
- ▶ 기술 정확도보다 **사회적 파급효과를 중시함**
- ▶ 인간과 AI의 관계를 설계에 포함함

설명 가능한 인공지능

- ▶ 판단 과정을 단계적으로 해석하려는 시도임
- ▶ 인간이 이해 가능한 **중간 설명 구조를 도입함**
- ▶ AI와 인간의 소통 가능성을 확장함

제도와 거버넌스의 역할

- ▶ GDPR을 통해 AI 편향을 제도적으로 통제함
- ▶ 개인의 설명 요구권과 데이터 통제권을 보장함
- ▶ AI 윤리를 **사회 전체의 책임으로 확장함**

