




# 인공지능시대의 윤리

인공지능의 투명성



1

인공지능이  
블랙박스가  
된 배경

## 초기 인공지능의 구조

- 규칙과 명령어를 **사람이 직접 설계한 시스템**이었음
- 판단 과정과 결과의 근거를 **추적하기 쉬웠음**
- 결과에 대한 **설명 가능성**이 비교적 **높았음**

## 현대 인공지능의 변화

- 빅데이터와 딥러닝 기반 **자율 학습 구조로 전환**됨
- AI가 사람이 설계하지 않은 **패턴을 스스로 생성**함
- **내부 판단 과정**이 인간에게 **설명되기 어려워짐**

2

블랙박스  
인공지능의  
문제점

## 판단 과정의 불투명성

- 입력과 출력만 확인 가능하고 중간 과정은 확인 불가함
- AI가 어떤 특징을 근거로 판단했는지 알기 어려움

결과의 신뢰성과 검증 가능성이 낮아짐

## 사회적 위험 사례

- 자율주행차 사고에서 AI 판단 책임 소재가 불명확함
- 의료 AI의 진단 결과를 의사가 신뢰하기 어려움

생명 · 안전 영역에서 설명 불가능성이 치명적 문제로 작용함

3

성과와  
투명성의  
딜레마

## 딥러닝 구조의 한계

- 성능 향상을 위해 수많은 **파라미터가 결합됨**
- 구조가 복잡해질수록 인간의 **이해 가능성은 감소함**
- AI 스스로 생성한 규칙을 인간이 **해석하기 어려움**

## 윤리적 선택의 문제

- 고성능이지만 불투명한 AI와 신뢰 가능한 AI 사이의 갈등임
- **정확성**만을 기준으로 AI를 **평가하기 어려워짐**
- **투명성**이 **인공지능 윤리의 핵심 기준**으로 부상함

4

설명 가능한  
인공지능  
(XAI)

## XAI의 개념과 등장

XAI

2017년 DARPA에서 공식 제안됨  
AI 판단 결과와 근거를 제시하는 기술임

- ▶ 블랙박스 AI의 한계를 보완하기 위한 접근임

## XAI의 주요 기능

- ① 판단 근거와 사용된 특징을 인간 언어로 설명함
- ② AI 모델의 강점과 약점을 분석 가능하게 함
- ③ 인간이 AI 판단을 감독·수정할 수 있는 구조를 제공함

## 인공지능 신경과학의 접근

- AI 내부 구조를 **인간의 뇌처럼 분석**하려는 시도임
- 특정 입력 요소를 제거 · 변형하여 **판단 변화를 관찰**함
- AI 의사결정에 핵심적으로 작용하는 요소를 파악함

## 실제 연구와 적용 사례

- AI 신경망을 시각화해 **판단 이유를 설명하는 기술** 개발됨
- AI가 자신의 행동 이유를 **언어로 설명하도록 훈련**함
- 단순 설명을 넘어 **자기 설명형 AI 가능성**을 제시함

