



인공지능시대의 윤리

트롤리 딜레마와 자율주행차



1

트롤리
딜레마의
철학적 기원

트롤리 딜레마의 기본 구조

트롤리 딜레마

다수와 소수 중 피해를 선택해야 하는
윤리적 사고실험임

- ▶ 행동과 비행동의 결과를 비교하도록 설계된 문제임
- ▶ 의도와 결과의 도덕적 차이를 드러내는 구조임

필리파 쏿의 문제 제기

- 필리파 쏿은 도덕 판단 충돌 상황을 분석하고자 함
- 완전히 옳은 선택이 존재하지 않는 상황을 설정함
- 도덕 원칙의 한계를 탐구하기 위한 철학적 질문임

2

자율주행
기술과
트롤리
딜레마의
현실화

자율주행 환경의 변화

- 자율주행차는 인간 운전자 없이 판단을 수행함
- 사고 회피 과정에서 선택 불가능한 상황에 직면함
- 철학적 사고실험이 실제 도로 상황으로 전환됨

윤리 문제의 기술적 확장

- 자율주행차의 판단은 기술 문제가 아닌 윤리 문제임
- 사고 발생 시 사회적 · 법적 책임 문제로 확장됨
- AI 설계 단계에서 윤리 기준을 사전 설정해야 함

3

공리주의적 접근과 그 한계

피해 최소화 논리와 문제

공리주의

- ▶ 전체 피해를 **최소화**하는 선택을 중시함
- ▶ **다수를 살리는 선택**이 직관적으로 선호됨
- ▶ 알고리즘 적용이 용이한 판단 방식임

생명 가치 수치화의 문제

- ▶ 생명을 **숫자로 비교하려는 위험**이 발생함
- ▶ 연령 · 건강 · 신분 비교는 **차별을 유발**함
- ▶ 윤리적으로 정당화되기 어려운 판단임

4

의도와 결과의 도덕적 구분

직접 행위와 부수적 결과

- 방향 전환은 **의도된 피해**를 발생시키는 행위임
- 비개입 선택은 **부수적 결과**로 해석됨
- 결과가 같아도 도덕적 평가는 달라짐

AI 윤리 판단의 한계

- AI는 윤리적 사고 능력을 갖지 않음
- 센서 데이터와 계산 변수만 처리함
- 윤리 판단은 **설계자의 책임 영역**임



윤리 기준 결정의 주체

- 윤리 기준은 기술자 **개인**이 결정할 수 없음
- 철학 · 법 · 사회가 **공동으로 논의**해야 함
- **사회적 합의**에 기반한 기준이 필요함

Moral Machine 실험의 시사점

- **문화권에 따라** 윤리적 선택이 **다르게** 나타남
- 단일한 세계 표준 윤리 설정이 어려움
- **사회 · 문화적 맥락**을 반영한 설계가 요구됨

