



인공지능시대의 윤리

최수의 딜레마와 자율주행차



1

죄수의 딜레마의
개념과
이론적 구조

죄수의 딜레마의 기본 설정

- 개인이 합리적으로 행동해도 집단 전체에는 불리한 결과가 발생함
- 상호 협력이 최선이지만 **개인 선택은 배신으로 수렴함**

개인 합리성과 집단 합리성이 서로 충돌하는 구조임

내시균형의 의미

- 상대의 선택과 무관하게 **최선인 전략이 존재함**
- 양측 모두 전략을 바꿀 유인이 없는 상태임

최적이 아닌 균형에 머무르게 함

2

죄수의 딜레마와
자율주행
알고리즘의
연결

자율주행 사고 상황의 특성

- 자율주행차는 위급 상황에서 반드시 하나의 선택을 해야 함
- 선택은 탑승자 보호와 보행자 보호 사이의 판단을 포함함
- 기술적 판단이 **윤리적 선택으로 전환됨**

개인 합리성과 사회 안전의 충돌

- 탑승자 보호 알고리즘은 **개인에게 합리적인 선택임**
- 모든 차량이 같은 선택을 하면 **도로 전체 위험이 증가함**
- 죄수의 딜레마 구조가 교통 시스템 전반에서 재현됨

3

자율주행
윤리
알고리즘의
두 가지
모델

알고리즘 모델

공리주의적 알고리즘

- ▶ 전체 피해를 **최소화**하는 선택을 우선함
- ▶ **다수를 살리는 방향**으로 의사결정을 설계함
- ▶ 사회 전체 관점에서는 이상적인 결과를 유도함

탐승자 중심 알고리즘

- ▶ 어떤 상황에서도 **차량 탐승자를 우선 보호**함
- ▶ 개인과 가족의 **안전**을 중시하는 설계임
- ▶ 집단적으로는 사고 위험 증가 가능성이 있음

설문조사가 보여준 윤리적 태도

- 이론적으로는 공리주의 선택을 지지함
- 실제 구매 상황에서는 **탐승자 보호를 선호**함
- 도덕 판단과 실제 행동 사이 **괴리가 존재**함

기대수명 기반 게임이론 분석

- 개인 입장에서는 탐승자 중심 전략이 유리함
- 모두가 같은 전략을 선택하면 최악의 결과가 발생함

자율주행 알고리즘에서도 죄수의 딜레마가 반복됨

4

인간의
윤리 인식과
선택의 모순



윤리 규제의 필요성과 한계

- 공리주의 알고리즘의 강제는 **기본권 침해 논쟁**을 유발함
- 희생 위험을 제도화할 수 있는지에 대한 문제임
- 기술 윤리를 넘어 **법 · 정책 · 사회적 합의가 요구됨**

핵심 윤리 원칙과 한국의 기준

- 생명을 차등 평가하거나 특정 집단을 희생시켜서는 안 됨
- 피해 최소화 노력은 투명하고 설명 가능해야 함
- **인간 존엄성, 사회 공공성, 기술 합목적성**이 기준임

