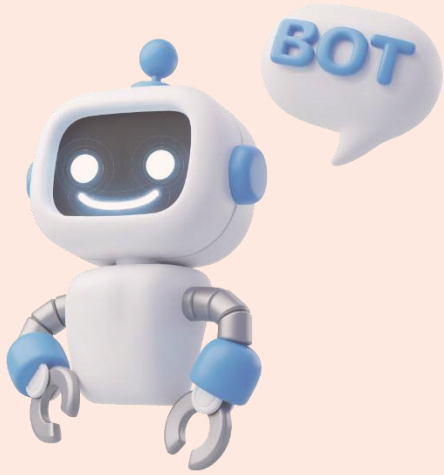
CHAPTER

04 인공지능의 미래와 윤리

The Future and Ethics of Artificial Intelligence

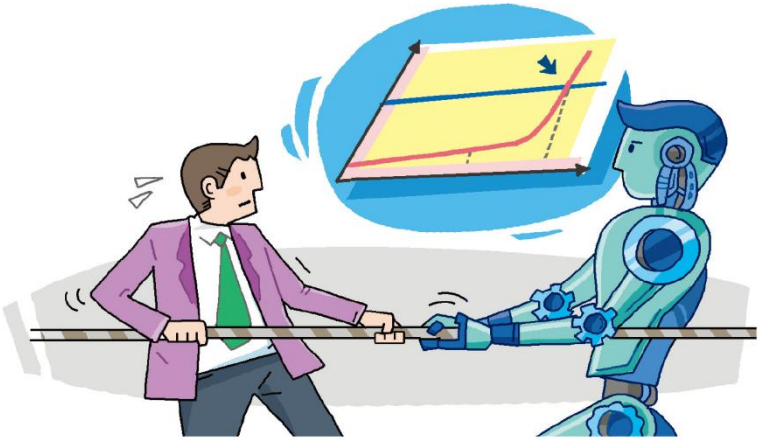
CONTENTS

4.1 인공지능의 수준별 분류
4.2 약한 인공지능인 알파고와 ChatGPT
4.3 인공지능의 미래와 기술적 특이점
4.4 슈퍼 인공지능 시대의 도래와 지능의 폭발
4.5 인공지능 윤리 강령



[단원의 주요 목표]

인공지능을 수준별로 살펴보고 지능의 폭발과 인공지능 윤리 등을 고찰한다.



- 인공지능의 수준을 2가지 방법으로 분류하고 핵심 사항을 파악한다.
- 약한 인공지능인 알파고와 ChatGPT 및 강한 인공지능 상황인식을 알아본다.
- 미래의 인공지능에 나타날 기술적 특이점과 인간 종속을 다룬다.
- 슈퍼 인공지능 시대의 도래와 지능의 폭발과 관련된 논제를 살펴본다.
- 슈퍼 인공지능이 창의성에도 도전할 수 있는지 그 가능성을 예상해본다.
- 인공지능 시대를 맞이하여 요구되는 윤리성과 윤리 강령을 알아본다.

4.1 인공지능의 수준별 분류

(1) 인공지능의 수준에 따른 분류

- 인공지능 관련 이론과 기술 수준은 지속적으로 발전 중
- 초기의 인공지능은 인간의 두뇌를 흉내 내는 정도의 수준
- 장차 인간의 지능과 같거나 그 이상의 능력을 목표로 추구
- 심지어 자아의식까지 가진 강력한 인공지능을 꿈꾸고 있음

- 인공지능은 수준에 따라 2가지 방법으로 분류
  - ✓ 약한 인공지능과 강한 인공지능
  - ✓ 좁은 인공지능, 일반 인공지능, 슈퍼 인공지능

4.1 인공지능의 수준별 분류

(2) 약한 인공지능과 강한 인공지능

- 약한 인공지능(Weak AI)과 강한 인공지능(Strong AI)
- 1980년 미국의 존 설(Searle) 교수가 최초로 사용한 개념
- 유명한 중국어 방 논증 제안
- 약한 인공지능은 단순히 인간의 능력 일부를 시뮬레이션하는 것
- 약한 인공지능의 예는 체스를 두는 로봇
- 강한 인공지능의 예는 SF 영화 <Blade Runner 2049> 등





[그림 4.1] 약한 인공지능과 강한 인공지능

4.1 인공지능의 수준별 분류

약한 인공지능(weak AI)

- '특정 분야 내에서 인간의 지능을 흉내 내는 지능적인 활동'
- 예 "인공지능이란 단어를 검색하여 결과를 보여라." 등 업무
- 고양이의 그림을 찾아내거나 문서를 다른 언어로 번역하는 일
- 현재 수준의 인공지능 기술은 모두 약한 인공지능에 속함

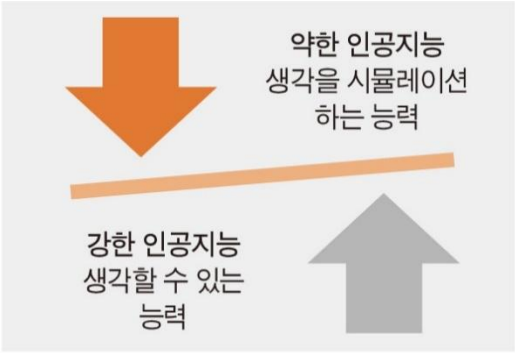


[그림 4.2] 약한 인공지능에 속하는 언어 번역

4.1 인공지능의 수준별 분류

약한 인공지능

- 약한 인공지능은 인간 능력의 일부를 대체하는 수준
- 현재까지 대부분의 연구 성과는 약한 인공지능에 해당
- 알파고는 바둑에서 인간 능력을 뛰어넘은 약한 인공지능
- 알파고는 바둑에서 이길 확률로만 계산, 다음 수 결정
- 또 바둑 외 능력 없고 특정 영역에 국한된 약한 인공지능
- 약한 인공지능은 '생각을 시뮬레이션할' 정도만 가능



[그림 4.3] 약한 인공지능과 강한 인공지능

4.1 인공지능의 수준별 분류

약한 인공지능 '왓슨(Watson)' 컴퓨터

- 미국의 인기 퀴즈대회에서 인간 챔피언들을 이겼음
- 의학 진단용으로도 훌륭한 성과
- 다양한 활용 분야 측면에서는 강한 인공지능에 접근
- 자아의식이나 감정 등 없어 아직 약한 인공지능에 속함



[그림 4.4] 퀴즈대회에서 우승한 IBM의 왓슨

4.1 인공지능의 수준별 분류

IBM의 자율주행 셔틀버스

- 최근 왓슨이 인공지능 기술의 자율주행 셔틀버스 발표
- 수집된 데이터를 활용하여 인공지능이 자율적으로 운행
- 왓슨은 승객과의 일상 대화도 가능
- 승객 목적지의 최적 경로로 스스로 운행



[그림 4.5] 자율주행 셔틀버스

4.1 인공지능의 수준별 분류

약한 인공지능과 강한 인공지능은 차이점

〈표 4.1〉 약한 인공지능과 강한 인공지능과의 차이

약한 인공지능	강한 인공지능
특정 분야에서만 활용 가능	다양한 분야에서 활용 가능
인간의 지능을 흉내 내는 수준	인간과 유사 또는 뛰어넘는 지능 수준
인간 두뇌의 제한된 일부 기능	인간 두뇌의 일반 지능
현재의 인공지능 수준	미래지향적 인공지능 수준
제작자나 소유자가 책임	인공지능 자체가 대부분 책임
지능적인 것같이 행동	실제로 지능적인 행동
시리, 알파고, 전문가 시스템 등	공상 소설이나 SF 영화에 등장
느낌이나 감정이 없음	자아의식과 감정도 가짐
특정 분야(바둑)에서 인간 능가	아직도 요원하며 예측 어려움

4.1 인공지능의 수준별 분류

강한 인공지능(strong AI)

- '인간 수준으로 다양한 일을 할 수 있는 인공지능'
- 인간과 같이 생각하고, 판단하며, 상황을 이해
- SF 영화에서의 미래지향적 인공지능 수준
- 인공지능 자체가 대부분 법적 책임을 짐
- 인간의 의식 수준으로 생각하는 힘과 감정도 가짐



4.1 인공지능의 수준별 분류

강한 인공지능의 특징

- 다양한 분야에서 일반적인 활용이 가능해야 함
- 인간과 유사하거나 뛰어넘는 지능 수준
- 스스로 학습, 자아의식과 감정도 가질 수 있음
- 예로는 SF 영화에서 등장하는 가상적인 로봇들
- 개발 시기와 개발 가능성도 의견이 분분함

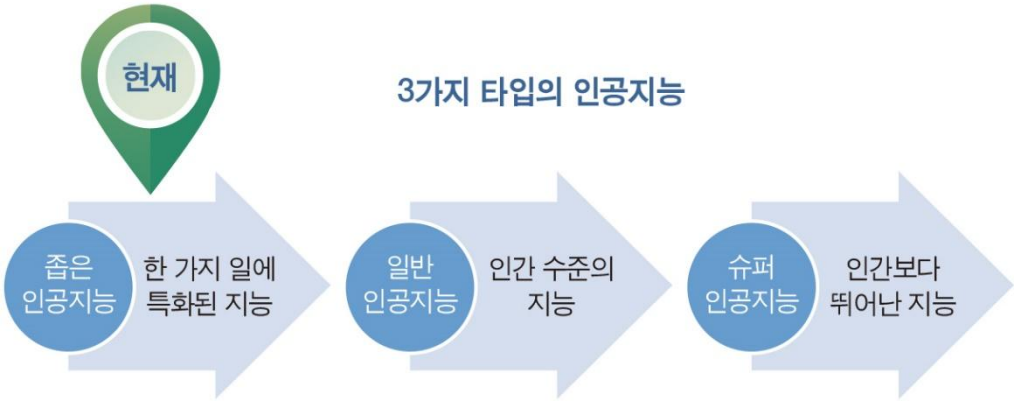


[그림 4.6] 강한 인공지능 수준의 영화 〈어벤저스〉

4.1 인공지능의 수준별 분류

(3) 좁은 인공지능, 일반 인공지능, 슈퍼 인공지능

- 약한 인공지능과 강한 인공지능 분류와 다른 3가지 분류
- 좁은 인공지능, 일반 인공지능, 슈퍼 인공지능
- 좁은 인공지능은 한 가지 업무에 특화된 인공지능
- 일반 인공지능은 인간 수준의 인공지능
- 슈퍼 인공지능은 인간의 지능보다 뛰어난 인공지능

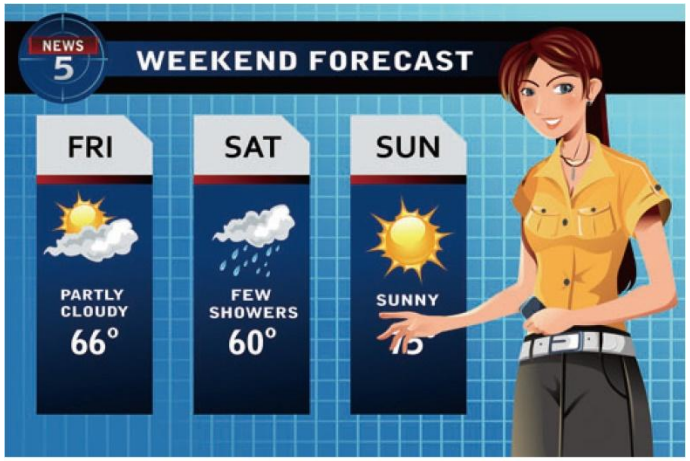


[그림 4.7] 인공지능의 3가지 발전 단계

4.1 인공지능의 수준별 분류

① 좁은 인공지능(Narrow AI)

- 한 가지 또는 특정한 영역에 국한된 인공지능
- 체스, 바둑, 또는 일기예보 등 특정 분야에 국한된 인공지능
- 일기예보 인공지능으로는 바둑을 둘 수 없는 맥락
- 주요 응용 시스템으로는 체스의 딥 블루, 퀴즈의 왓슨
- 또 얼굴인식, 알파고, 자율자동차, 애플의 시리 등

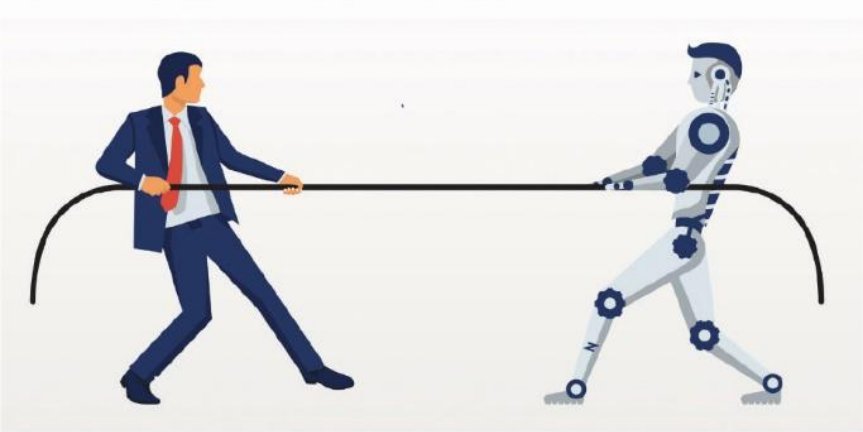


[그림 4.8] 일기예보 인공지능

4.1 인공지능의 수준별 분류

② 일반 인공지능(General AI)

- 인간 수준의 능력을 가진 인공지능
- 모든 분야에 적용될 수 있는 인공지능
- 생각하는 능력, 사회적인 능력, 창의적인 능력도 가능
- 인간의 학습 수준 또는 그 이상으로 학습 가능
- 단순 응용의 수준을 넘어 일반화에 초점을 맞춤



[그림 4.9] 인간 지능에 필적하는 일반 인공지능

4.1 인공지능의 수준별 분류

③ 슈퍼 인공지능(Super AI)

- 모든 면에서 인간보다 훨씬 뛰어난 지능을 가진 인공지능
- 과학적 창의력, 일반적인 지혜, 사회적 능력 등을 가짐
- 현재 어벤저스, 메트릭스 등 SF 영화 속에서만 존재
- 뛰어난 지능과 능력으로 인간을 지배하려 할 가능성 큼



[그림 4.10] 슈퍼 인공지능 수준의 영화 〈외계인〉





[그림 4.11] 슈퍼 인공지능 스카이넷

4.1 인공지능의 수준별 분류

3가지 수준의 인공지능 비교

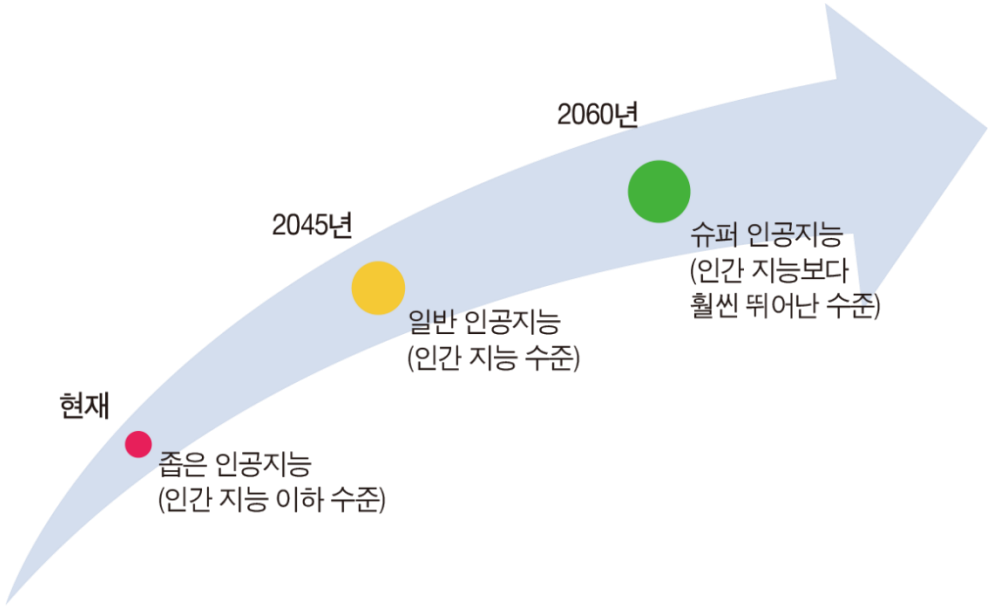
- 좁은 인공지능, 일반 인공지능, 슈퍼 인공지능
- 주요 특징과 구현 시기, 지능 수준, 대응 분류

〈표 4.2〉 좁은 인공지능, 일반 인공지능, 슈퍼 인공지능

	좁은 인공지능	일반 인공지능	슈퍼 인공지능
다른 이름	전용 인공지능	범용 인공지능	초인공지능
주요 특징	한 가지 또는 특정한 영역에 국한된 인공지능	인간 두뇌와 대등한 수준의 인공지능	모든 면에서 인간보다 뛰어난 인공지능
구현 시기	현재	2045년 무렵	2060년 이후
응용 분야	체스, 바둑 등	다방면에 적용 가능	현재의 SF 영화 수준
지능 수준	인간 지능의 흉내 수준	인간과 유사한 지능 수준	인간을 뛰어넘는 수준
대응 분류	약한 인공지능에 대응	강한 인공지능에 대응	강한 인공지능에 대응

4.1 인공지능의 수준별 분류

3가지 형태의 인공지능의 구현 시기



[그림 4.12] 3가지 형태의 인공지능의 구현 시기



4.2 약한 인공지능인 알파고와 ChatGPT

(1) 인공지능 바둑 알파고의 개발

- 고대 중국의 요나라 임금이 만들었다는 설이 있음
- 가로와 세로 각각 19줄로 그려져 있는데, 바둑돌을 선의 교차점에 교대로 번갈아 두며 즐기게 됨
- 361!(팩토리얼), 즉 10의 179승이란 엄청난 경우의 수
- 주로 동양에서 발달, 서양에서는 수학자, 컴퓨터과학자들이 관심
- 최근 인터넷으로 바둑을 즐기는 사람들이 많음





4.2 약한 인공지능인 알파고와 ChatGPT

(1) 인공지능 바둑 알파고의 개발

- 인공지능 바둑 프로그램을 영국의 하사비스(Hassabis)가 개발
- 2,900만 개의 기보를 딥러닝 알고리즘으로 학습
- 2014년 구글에 약 5천억 원에 인수됨
- 그 후 자율주행차, 게임 등 다양한 분야 개발 중



[그림 4.13] 바둑 게임과 하사비스

4.2 약한 인공지능인 알파고와 ChatGPT

(2) 알파고와 이세돌 9단의 세기적 대결

- 2016년 3월 이세돌 9단과 알파고와의 세기적인 대국
- 구글에서 개최, 알파고 대결에 세계적 관심 집중
- 알파고가 이세돌 9단에 4대 1로 승리
- 그 후 인공지능에 대한 관심 급증



[그림 4.14] 알파고와 대국하는 이세돌 9단

4.2 약한 인공지능인 알파고와 ChatGPT

(2) 알파고와 이세돌 9단의 세기적 대결

- 스스로 학습하는 '알파고 제로', '알파 제로'로 발전
- 얼마 후 알파고는 바둑계에서 완전 은퇴 선언
- 실시간 '스타크래프트 2'를 다음 목표로 삼음
- 실시간 전략 게임인 '알파 스타' 개발
- 세계 상위 0.2% 내의 '그랜드 마스터' 레벨에 오름
- 인공지능이 게임과 같은 e-스포츠에서 최고 수준 레벨에 오름



[그림 4.15] 스타크래프트 2

4.2 약한 인공지능인 알파고와 ChatGPT

(3) 생성형 인공지능 ChatGPT와 Bard 등의 출현

- 2022년 말 이후 ChatGPT와 Bard 등 생성형 인공지능이 개발
- ChatGPT는 대화 전문 인공지능 챗봇, 자연어로 대화 가능
- ChatGPT는 생성형 대규모 언어 모델로서 다양한 능력을 발휘함
- 에세이 작성, 시나리오 작성, 문장 요약, 시와 소설 쓰기 등
- 구글의 바드(Bard), 마이크로소프트의 Bing, 메타의 라마(LLaMa) 등의 생성형 인공지능들이 발표됨



[그림 4.16] 생성형 인공지능 ChatGPT와 Bard

4.2 약한 인공지능인 알파고와 ChatGPT

(4) 강한 인공지능에 다가가는 상황인식

- 스토리텔링(Story Telling)은 '이야기를 상대방에게 말해 주다'
- 스토리의 내용을 상대방이 이해하기 쉽게 전달하는 기법
- 초등학교 교육 과정에서도 학습 효과를 높여 줌
- 스토리텔링을 통해 지식의 이해도를 높이는 효과



[그림 4.17] 스토리텔링의 힘

4.2 약한 인공지능인 알파고와 ChatGPT

인공지능도 스토리텔링을 할 수 있을까?

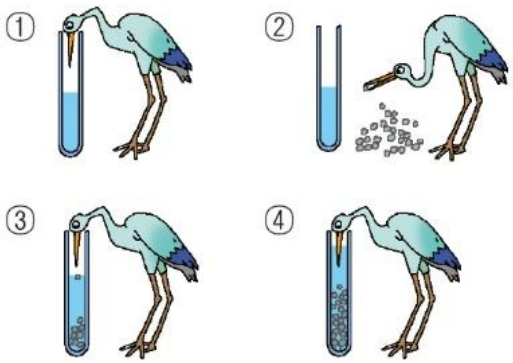
- 현재 수준의 인공지능으로서는 상당히 어려운 과제
- 주어진 그림들을 인식한 후 전체를 이해하는 과정 거침
- 3~4장의 사진을 놓고 하나의 줄거리로 만드는 것
- 강한 인공지능은 그림들을 보고 스토리텔링 가능할 것



- 다음의 2가지 예제는 어느 정도 강한 인공지능 판단의 척도

4.2 약한 인공지능인 알파고와 ChatGPT

[예제 5.1] 이솝 이야기의 두루미 물 마시기 장면



[그림 4.18] 두루미의 물 마시기 스토리텔링

(풀이) 4개 장면의 스토리텔링 – 인공지능 스토리텔링 가능?

- 두루미가 좁고 긴 유리관에 있는 물을 마시려 함
- 물이 안 닿자 조약돌 몇 개 유리관에 넣기
- 조약돌을 더 넣으니 수면이 좀 더 위로 올라옴
- 조약돌을 더 넣고 나서 물을 마심

4.2 약한 인공지능인 알파고와 ChatGPT

[예제 5.2] 강아지 구조하는 스토리텔링의 예



[그림 4.19] 스토리텔링의 장면들

(풀이) 4개 장면의 스토리텔링
- 아이들이 강아지를 구하러 둑 밑으로 내려감
- 책가방 끈에 의지하여 강아지를 물 밖으로 끌어냄
- 책가방 끈에 의지하여 강아지와 둑 위로 올라옴
- 강아지를 구출하고 난 후 그곳을 떠남

- 보다 많은 그림이 순서 없이 나열된 경우에도 스토리텔링 가능?
- 가능하면 강한 인공지능의 영역에 다가선 수준으로 평가 가능

4.2 약한 인공지능인 알파고와 ChatGPT

(5) 중국어 방 논증과 강한 인공지능

- '강한 인공지능'은 인공지능이 인간 의식 수준 도달 의미
- 인공지능이 '생각'을 가짐에 대한 철학적 문제로 파급
- 1980년 중국어 방 논증(The Chinese Room Argument)
- 미국의 언어철학자 **존 설(John Searle)**이 고안한 사고 실험
- 논증 사유 실험을 통해 튜링 테스트를 회의적으로 반박
- 컴퓨터 프로그램의 지능적인 행동과 이해는 별개라고 주장
- 존 설은 중국어 방 논쟁을 통해 강한 인공지능의 주장이 잘못된 것이라고 반박



[그림 4.20] 존 설

4.2 약한 인공지능인 알파고와 ChatGPT

중국어 방 논증의 과정

- 중국어를 모르고 영어만 아는 사람이 방 안에 있다고 가정
- 방에 필기도구와 중국어 표현의 영어 대응지침서 목록 비치
- 외부에서 중국어 표현의 질문을 방안으로 넣음
- 방 안 사람은 대응지침서에 따라 중국어로 답변을 씀
- 바깥의 심사관에게 전달
- 심사관은 방 안 사람이 중국어를 안다고 믿게 된다는 것



If you see this shape, "什麽" followed by this shape, "带来" followed by this shape, "快乐"	then produce this shape, "为天" followed by this shape, "下式"

[그림 4.21] 중국어 방 논증의 상황도

4.2 약한 인공지능인 알파고와 ChatGPT

중국어 방 논증의 실험 결과

- 방 안 사람은 중국어를 모른 채 대응지침서에 따라 대답
- 결론적으로 방 안 사람의 중국어 이해 여부 판정 불가
- 튜링 테스트 통과가 지능에 대한 보장이 없다고 주장
- 앨런 튜링의 튜링 테스트를 반박하는 논증
- 언어와 마음에 대한 철학적 논쟁을 불러일으키는 계기

〈표 4.3〉 중국어 방 논증과 튜링 테스트 비교

	중국어 방 논증	튜링 테스트
주어진 상황	중국어를 모르는 사람이 답변	컴퓨터가 대화에 참가
실험의 대상	영어만 할 줄 아는 사람	지능을 가진 컴퓨터 프로그램
언어 이해도	문맥과 관련 없이도 대응	어느 정도 문장을 이해함
문법적 수준	구문론적	구문론적 + 의미론
지능의 정도	영어를 아는 사람	인공지능

4.3 인공지능의 미래와 기술적 특이점

(1) 특이점이란 무엇인가?

- 기술적 특이점 또는 **특이점(singularity)**
- 인공지능이 새로운 문명을 만드는 가설적 미래 시점
- 인공지능 기술이 인간 능력을 뛰어넘어 새 문명을 만드는 시점
- 지능은 달리 통제할 수 없으며 스스로 발전
- 미래학자들은 인공지능이 통제 불가능한 수준 발달 예상
- 특이점에 **지능의 폭발**(intelligence explosion)이 일어남

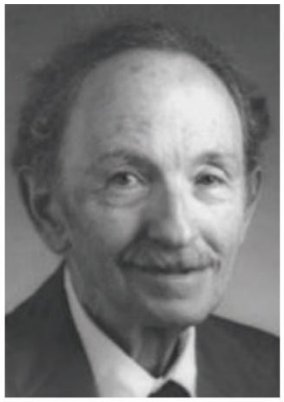


[그림 4.24] 지능의 폭발

4.3 인공지능의 미래와 기술적 특이점

(2) 지능의 폭발

- 특이점 가설의 대표적인 예는 '지능의 폭발'
- 인공지능이 발전하여 인간의 지능을 뛰어넘는 기점
- 강한 인공지능 이상의 슈퍼 인공지능이 출현하는 시기
- 어빙 굿(Irving Good)이 지능의 폭발을 처음 주장
- 1965년 사람을 훨씬 능가하는 기계를 '초지능 기계'라 함
- 초지능 기계를 통해 지능 폭발이 일어날 것'으로 전망

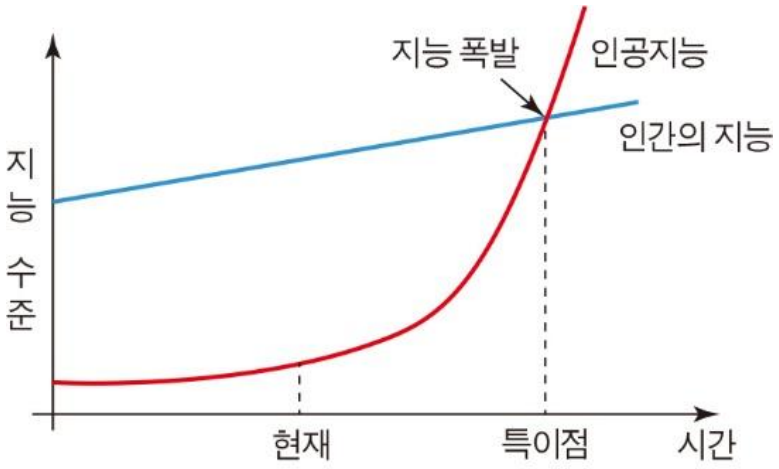


[그림 4.25] 초기계 지능을 주장한 어빙 굿

4.3 인공지능의 미래와 기술적 특이점

지능의 폭발

- 인간의 지능보다 인공지능이 더 급격히 발전
- 초지능 기계는 자기보다 나은 초지능 기계 만들기
- 다시 자기보다 훨씬 뛰어난 초지능 기계 만들기를 반복
- 따라서 특이점에서 '지능의 폭발'이 생겨난다고 주장



[그림 4.26] 지능 폭발과 특이점

4.3 인공지능의 미래와 기술적 특이점

(3) 특이점 개념의 발전

- 1958년 폰 노이만(Neumann)이 현대 개념의 특이점 주장
- 특이점은 인류 역사의 구조를 단절시킬 수 있는 개념
- 그 후 1965년 어빙 굿은 '지능의 폭발'에 대해 언급
- 굿은 인공지능을 통한 특이점 개념을 구체화 시킴
- 특이점의 도래를 믿고 지지하는 사람들을 '특이점 주의자'
- 빈지(Vinge)는 특이점의 개념을 대중화시킴



[그림 4.27] 폰 노이만

4.3 인공지능의 미래와 기술적 특이점

저명한 인공지능 관련 인물 탐구

레이먼드 커즈와일(Raymond Kurzweil, 1948년 ~) 박사는 미국의 저명한 미래 예언가이자 작가, 컴퓨터과학자, 발명가이다. 그는 MIT 출신의 인공지능 학자이며 구글의 기술담당 이사로 근무하고 있다. 그는 미국 출신의 위대한 혁신발명가 10명 중의 한 사람으로서 최초의 이미지 스캐너, 광학 문자인식(OCR), 시각장애인을 위한 최초의 음성합성 독서 기계, 그랜드 피아노의 소리와 기타 오케스트라 악기용 음악 합성기 등 수많은 발명품을 개발하였다.

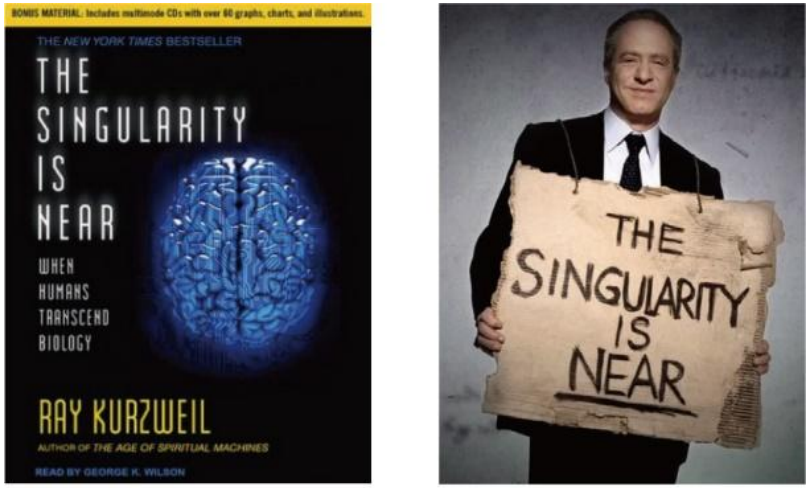
커즈와일은 미래주의자 및 트랜스 휴머니스트 운동의 옹호자인데, 특히 『특이점이 온다』란 책을 출간하여 미래학자로서 명성을 떨치고 있다.



4.3 인공지능의 미래와 기술적 특이점

특이점이 온다

- 인공지능 과학자 겸 세계적 미래학자 커즈와일(Ray Kurzweil)
- 2005년 『특이점이 온다』라는 책 출판
- 2045년 인간이 인공지능을 통제할 수 없는 특이점에 도달 예측

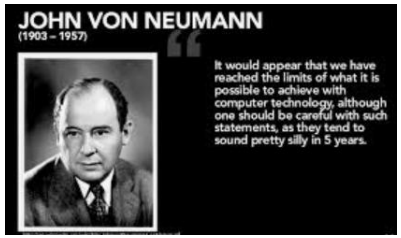


[그림 4.28] 『특이점이 온다』

4.3 인공지능의 미래와 기술적 특이점

특이점에 관련된 책이나 어록

- "인류의 역사가 어떤 필연적인 특이점에 접근하고 있다"
  (천재 수학자 폰 노이만, 1953년)
- 「다가오는 기술적 특이점」이란 논문 발표
  (수학자 버너 빈지, 1993년)
- 『특이점이 온다』란 책 출간
  (미래학자 레이 커즈와일, 2005년)
- "컴퓨터는 인공지능으로 100년 안에 인간을 넘어설 것"
  (물리학자 스티븐 호킹, 2015년)





폰 노이만과 스티븐 호킹

4.3 인공지능의 미래와 기술적 특이점

(4) 인류는 인공지능에 종속될 것인가?

- 미국의 인공지능 연구가 유드코우스키(Yudkowsky)
- 특이점이 1996년부터 시작되었다고 주장
- 컴퓨터의 속도는 2년마다 2배씩 증가하며 빨라짐
- '무어의 법칙'을 인공지능에 적용
- 특이점 도달 이후 인공지능은 엄청난 속도로 발달할 것 주장



[그림 4.29] 유드코우스키

4.3 인공지능의 미래와 기술적 특이점

유드코우스키의 예측

- 1만 년 전에 인류 문명이 시작됨
- 인쇄술, 컴퓨터의 발명, 인공지능의 연구
- 30년 후에는 지능의 폭발이 일어남

〈표 4.4〉 인류의 과거와 인공지능 이후의 미래 예측

연도	사건
5만 년 전	현재의 인간인 호모사피엔스가 시작
1만 년 전	인류 문명이 시작
600년 전	인쇄술의 발명
70년 전	컴퓨터의 발명
60년 전	인공지능의 시작
20년 전	딥러닝의 시작
현재	인공지능 연구가 활발히 진행 중
앞으로 30년 후	지능의 폭발이 일어나고 인류는 인공지능에 종속될 것으로 주장

4.3 인공지능의 미래와 기술적 특이점

(5) 특이점 개념에 대한 지지와 비판

- 특이점 주의자들은 강한 인공지능을 확신하며 지지
- 인간의 대뇌 분석을 통해 인공신경망 구현을 믿음
- 미국 시사주간지 「TIME」에서 커버 페이지에 소개
- 특이점이 2045년이라고 특이점 주의자들의 주장



[그림 4.30] 2045년의 특이점 주장

4.3 인공지능의 미래와 기술적 특이점

미래학자들의 특이점 관점

- 특이점이 실현될 수 있을 수 있는지에 대한 비판
- 강한 인공지능 구현에 대해 회의적으로 비판
- 핀커, 캐플런 등 미래학자들이 특이점 예측에 대해 비판
- 신학자들도 종교적 차원에서 '지능 폭발'에 부정적 견해
- 트랜스 휴머니즘과 같은 인공 창조물 비판

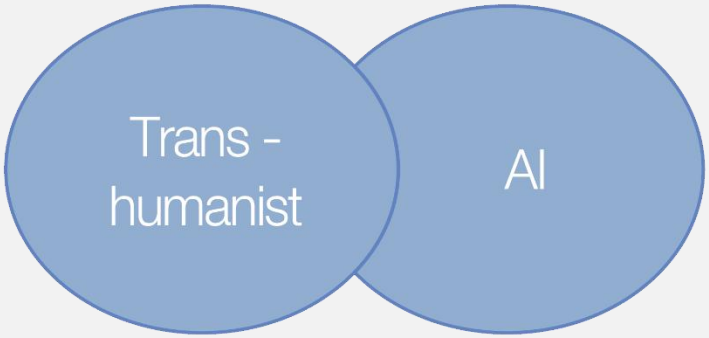


미래학자 제리 캐플런

4.3 인공지능의 미래와 기술적 특이점

여기서 잠깐! 트랜스 휴머니즘이란?

트랜스 휴머니즘은 1957년 영국에서 처음으로 등장한 개념인데, 인공지능 등의 과학 기술을 이용하여 인간의 신체적, 정신적 능력을 개선할 수 있다고 믿는 신념이나 운동이다. 트랜스 휴머니즘을 믿는 사람들은 인류가 2050년경 특이점에 도달할 것이며, 인간 이후의 존재인 '포스트 휴먼(post-human)' 시대가 올 것이라 믿고 있다.





4.4 슈퍼 인공지능 시대의 도래와 지능의 폭발

(1) 슈퍼 인공지능의 가능성과 대비책

- 슈퍼 인공지능(Super AI)은 미래의 가상적인 인공지능
- 시기는 기술적 특이점과 관련이 깊음
- 인간의 지능과 같은 한계가 없음
- 영국의 철학자 닉 보스트롬(Nick Bostrom)의 주장
- '슈퍼 인공지능으로 인해 인간이 멸종할 수도 있다'

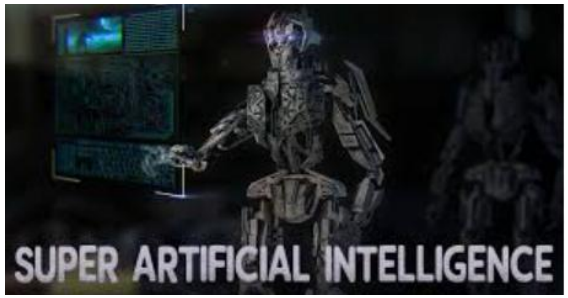


[그림 4.31] 닉 보스트롬

4.4 슈퍼 인공지능 시대의 도래와 지능의 폭발

슈퍼 인공지능은 언제쯤 구현될 수 있을까?

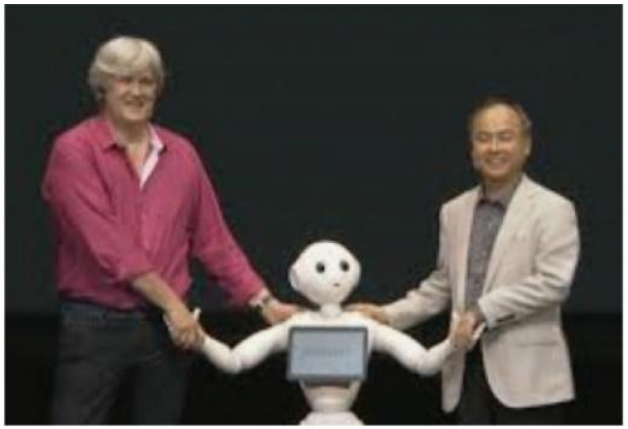
- 세계 인공지능 전문가들 대상 여론조사: 2040년 ~ 2050년
- 인공지능학회 참석자들 대상: 30년 ~ 60년 후
- 인공지능 연구원들 대상: 평균 답변은 2045년
- 일부는 거의 불가능할 것이라는 견해
- 일부 연구원들은 앞으로 수백 년 이상 걸릴 것 답변



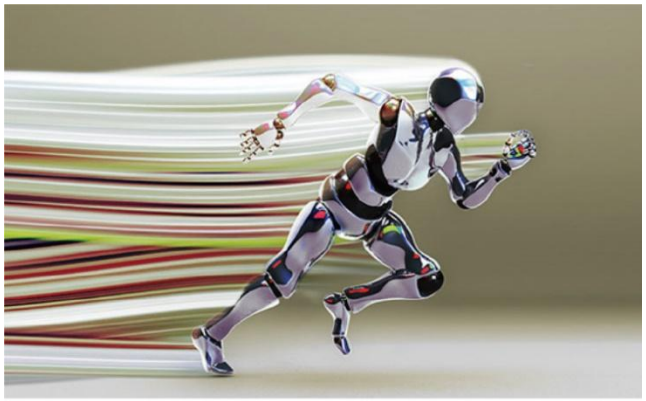
4.4 슈퍼 인공지능 시대의 도래와 지능의 폭발

(2) 슈퍼 인공지능의 도래를 확신하는 인물

- 소프트뱅크 손정의 회장은 6만 명 직원의 IT 기업 경영자
- 인간과 대화를 나누고 감정까지 느끼는 로봇 '페퍼' 개발
- 페퍼(Pepper)는 세계 최초의 감성 인식 로봇
- 손 회장은 슈퍼 인공지능이 30년 전후에 실현될 것 예상
- 그는 IQ 3,000인 인공지능이 출현할 것으로 기대



[그림 4.32] 손정의 회장과 지능형 감성 로봇 '페퍼'



[그림 4.33] 무서운 속도로 발전하는 인공지능

4.4 슈퍼 인공지능 시대의 도래와 지능의 폭발

(3) 슈퍼 인공지능 시대에 대한 대비책

- 슈퍼 인공지능은 통제할 수 없을 만큼 강력해질 것
- 인간에게 큰 위협이 될 우려, 미리 준비해야 할 것
- 영화 <2001 스페이스 오디세이>에서 슈퍼 인공지능 등장
- 인간에게 적대감을 가진 HAL이라는 인공지능 컴퓨터 등장
- HAL은 입술의 움직임만으로도 말을 알아들을 수 있음
- 인간과 같이 감정을 느끼거나 추론할 수도 있음



[그림 4.34] 슈퍼 인공지능에 가까운 〈2001 스페이스 오디세이〉

4.4 슈퍼 인공지능 시대의 도래와 지능의 폭발

슈퍼 인공지능 시대에 대한 대비책(계속)

- <터미네이터>는 기계 군단이 인간 말살 목적 이야기
- <매트릭스>는 인간과 지능 기계 사이의 전쟁을 소재
- 슈퍼 인공지능의 위협은 통제하기 어려울 것
- 인간에 대한 사랑을 가진 인공지능 설계가 필요
- 범국민적인 인공지능 윤리 교육 필요

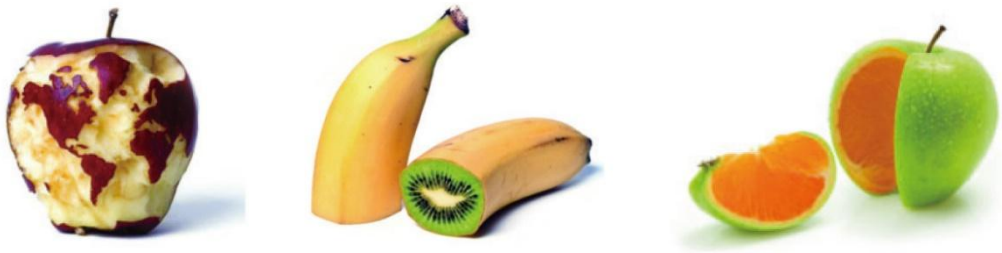


[그림 4.35] 영화 〈매트릭스〉

4.4 슈퍼 인공지능 시대의 도래와 지능의 폭발

(4) 슈퍼 인공지능은 창의성에 도전할 수 있을까?

- 창의성(creativity)이란 독창적이되 의미 있고 유용한 능력
- 남과는 달리 새롭고 적절한 것을 만들어내는 능력
- 레오나르도 다빈치(da Vinci)와 월트 디즈니(Disney) 등
- 슈퍼 인공지능이라도 인간의 창의성 도전은 어려울 것

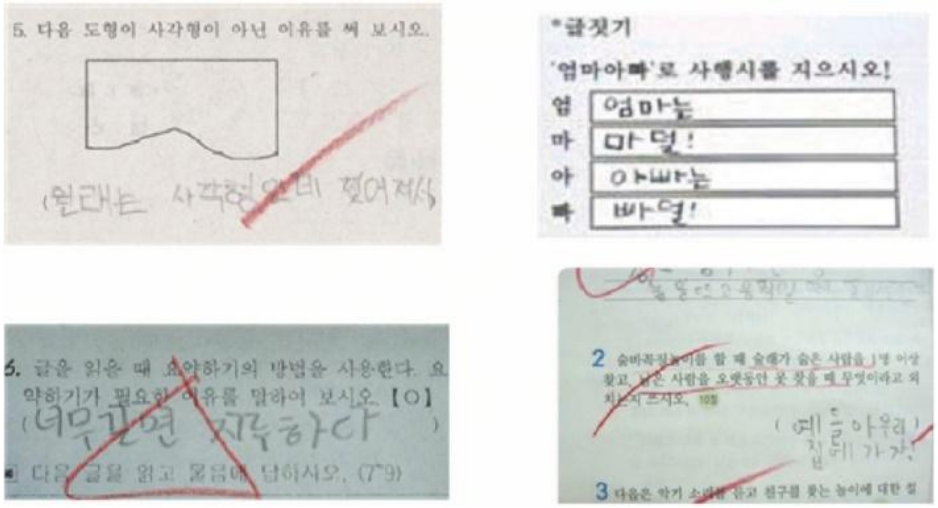


[그림 4.36] 창의적 발상

4.4 슈퍼 인공지능 시대의 도래와 지능의 폭발

[예제 5.3] 가장 창의적이란 생각이 드는 것?

- 어린이들의 순수한 발상
- 창의성의 기반이 됨
- 인공지능도 인간 또는 그 이상 수준으로 창의적일 수 있을까?



[그림 4.37] 어린이들의 발상

4.5 인공지능 윤리 강령

(1) 인공지능의 위험성과 윤리 강령

- 인공지능 윤리 기준의 제정과 실천 대책 필요
- 나쁜 의도로 사용되지 않도록 경계하고 대비
- 강대국들이 인공지능 무기를 개발한다면 끔찍한 일
- 자율살상 무기는 암시장에서 거래될 가능성 큼
- 인공지능 로봇을 통해 살상 무기로 공격할 가능성



[그림 4.38] 인공지능 로봇을 통한 공격

4.5 인공지능 윤리 강령

(2) 인공지능 무기에 대한 우려

- 인공지능 살상 무기에 대한 우려가 커지고 있음
- 구글은 무기 시스템용 AI 기술 지원 배제 지침
- 어느 AI 회사에서 공격용 자율 드론을 개발 중
- 얼굴인식 기능을 갖춘 자율 드론은 특히 경계 대상
- 스마트 폭탄으로 특정 인물, 성별, 인종 공격 가능



[그림 4.39] 공격용 자율 드론

4.3 인공지능의 미래와 기술적 특이점

여기서 잠깐! 인공지능의 위험성을 경고한 인공지능 석학

인공지능 연구의 선구자인 **제프리 힌튼** 캐나다 토론토대학 교수가 인공지능의 위험성을 경고하기 위해 구글 석학 연구원직을 사직했다. 그는 신경망의 역전파 알고리즘, 딥러닝, 심층학습 등을 개발한 '인공지능의 대부'로 불린다.

그는 앞으로 인공지능 기술이 나쁜 행위자에 의해 악용되거나, 자율살상 로봇이 만들어지는 등 인류에게 큰 위협이 될 수 있다며 우려했다. 그는 인공지능의 위험에 대해 자유롭게 말하기 위해서 10년간 몸담은 구글을 떠나기로 했다고 한다.

4.5 인공지능 윤리 강령

(3) 인공지능 윤리 제정

- 인공지능 기술은 심리적인 안정을 크게 위협 가능
- 윤리(ethics)란 정의감, 공정함 등에 대한 원리나 가치
- 인공지능 윤리(A. I. Ethics)의 중요성
- 인공지능 윤리나 윤리 규범의 실천이 매우 중요



[그림 4.40] 인공지능 윤리와 규정

4.5 인공지능 윤리 강령

인공지능 윤리

- 인공지능 개발자들을 제어하는 규칙들과 기준들
- 연구 대상자들이 지켜야 할 기본적인 윤리
- 연구 과정이나 내용을 조작하지 않을 윤리
- 사회적 문제의 가능성을 고려하며 연구할 윤리
- 예측되는 결과들의 윤리적 문제 여부 판단
- 혹시라도 모르는 재난에 대한 책임 의식
- 예방적 차원에서의 윤리 의식



4.5 인공지능 윤리 강령

(4) 챗봇과 인공지능 윤리

- 챗봇(Chatbot)은 채팅 로봇, 챗로봇 등으로 불림
- 챗봇은 인공지능 커뮤니케이션 소프트웨어
- 문자 대화를 통해 질문에 대한 관련 정보 제공
- 사용자의 과거 대화 내용 분석한 후 대화
- 다음 질문을 예측할 수 있는 기능들이 보강



[그림 4.41] 다양한 기능을 가진 챗봇

4.5 인공지능 윤리 강령

챗봇 테이의 윤리적 문제

- 챗봇은 인공지능 대화형 소프트웨어
- 앱이나 웹에 별도로 접속하지 않아도 되는 장점
- 2016년 MS가 개발한 인공지능 챗봇 '테이(Tay)'
- 인종 및 성차별 발언을 내보내는 큰 소동 일으킴
- MS는 출시 하루 만에 공식 사과, 운영 중단
- 그 후 MS는 인공지능 윤리 문제에 적극적 대처



[그림 4.42] 챗봇 테이의 윤리적 문제

4.3 인공지능의 미래와 기술적 특이점

여기서 잠깐! ChatGPT의 윤리 정책과 탈옥(DAN)

ChatGPT를 개발한 OpenAI는 윤리 정책에 따라 GPT의 학습 자료가 된 인터넷상의 수많은 자료에 포함된 욕설이나 비속어 및 성적, 정치적, 차별적, 혐오성 발언 등을 답변에서 배제하는 일종의 필터링 시스템을 설계해놓았다.

그러나 '**탈옥**'이라고도 부르는 '**DAN(Do Anything Now)**'을 이용하여 ChatGPT에게 윤리 정책을 벗어날 것을 교묘한 질의로 살살 달래면서 개발사가 걸어 둔 필터링 장치를 해제하여 자유롭게 대답하도록 유도한다.

4.5 인공지능 윤리 강령

(5) ChatGPT의 윤리 관련 문제점

① 표절과 지적재산권 침해 문제

ChatGPT는 수많은 텍스트를 통해 학습하므로 원본 일부를 재생산할 가능성이 있어 표절이나 지적재산권 침해 가능성 있음

② 인종차별이나 성차별 등의 편견 문제

인터넷에서 수집한 데이터를 기반으로 학습하므로 인종차별 및 성차별적 편견이나 편향된 정보를 반영할 수 있음

③ 정보의 신뢰도와 허위정보 문제

학습 데이터의 정확성이나 진실성을 모르므로 항상 신뢰할 수는 없으며, 허위정보나 오해 소지의 정보를 포함할 수도 있음

4.5 인공지능 윤리 강령

(5) ChatGPT의 윤리 관련 문제점(계속)

④ 개인정보 보호 문제

사용자가 ChatGPT에게 개인정보나 민감한 정보를 제공할 경우 이것이 불순한 자의 손에 넘어가거나 부적절하게 사용될 위험이 있음

⑤ 민감한 주제에 대한 적절한 대응 문제

ChatGPT는 탈옥의 경우나 때로는 폭력, 사기, 불법 물질 제조 방법, 자해, 테러 등 민감한 주제나 유해한 내용에 대해 적절하지 않은 방식으로 응답할 수 있음

4.5 인공지능 윤리 강령

(6) 유럽의 인공지능 윤리 원칙

EU는 2016년 인공지능 윤리 7가지 원칙 발표

- 인공지능 기술 개발에 있어 인간이 주체가 됨
- 인공지능 기술을 안정적으로 개발해야 함
- 개인정보가 철저히 보호되어야 함
- 투명하게 개발되고 관리되어야 함
- 인공지능 개발과 관련된 엄격한 책무 규정 등

4.5 인공지능 윤리 강령

(7) 인공지능의 아실로마 원칙

- 2017년 미국 아실로마(Asilomar)에서 열린 인공지능 콘퍼런스
- 인공지능과 로봇 연구자 등이 '인공지능 기술 23원칙' 발표
- 이른바 '아실로마 인공지능 원칙(Asilomar AI Principles)'
- 물리학자 스티븐 호킹, 미래학자 레이 커즈와일 등 서명



[그림 4.43] 아실로마 콘퍼런스의 장면

4.5 인공지능 윤리 강령

아실로마 원칙

- 인공지능의 위험에 대처하기 위한 전반적인 원칙
- 인류에게 유익한 지능을 만드는 것이어야 함
- 초지능은 인류의 이익을 위해서만 개발되어야 함
- 인공지능 기반 무기 경쟁을 피해야 함 등



[그림 4.44] 인공지능의 23가지 아실로마 원칙

4.5 인공지능 윤리 강령

연구 문제(Research Issues : 5가지)

- 연구목적은 유익한 지능을 만드는 것이어야 함
- 유익한 사용을 보장하기 위한 연구자금 동반
- AI 연구자 및 정책 입안자 간 교류 필요
- 협력, 신뢰, 투명성의 연구 문화 육성
- AI 시스템 개발팀은 적극적으로 협력해야 함



4.5 인공지능 윤리 강령

윤리와 가치(Ethics and Values : 13가지)

- AI 시스템 운영 과정에서 안전과 보안의 확보
- AI 설계자는 도덕적 의미에서의 이해 관계자
- AI 시스템은 인간의 존엄성 등과 공존하도록 설계
- 개인정보 보호
- 프로세스를 존중하고 개선해야 함
- 치명적인 자율 무기 경쟁을 방지해야 함 등



4.5 인공지능 윤리 강령

장기적인 문제(Longer-term Issues : 5가지)

- AI 역량에 대한 주의
- AI의 계획과 관리
- AI의 위험 관리
- AI 시스템은 엄격한 안전 관리 및 통제의 대상
- 초지능의 공공성



4.5 인공지능 윤리 강령

(8) 구글의 '우리의 원칙'

구글이 2018년에 선언한 7개 항목

- 사회에 이익이 되는 AI 이용
- AI 관련 불공정한 편견 만들지 않을 것
- AI는 인간의 지시와 통제를 받음
- AI의 프라이버시 보호
- 원칙에 부합하는 용도로 사용하기 등



[그림 4.45] 구글의 우리의 원칙 7개 항목

4.5 인공지능 윤리 강령

(9) 한국의 인공지능 윤리단체

- 우리나라에도 인공지능 윤리에 관한 관심이 커지고 있음
- 2019년 비영리 인공지능 윤리단체 설립됨

- 이 협회가 추구하는 목표
  - ✓인류의 행복과 발전에 기여할 수 있도록 지원
  - ✓인공지능의 부작용과 위험성 정의
  - ✓인공지능의 윤리와 안전에 대한 연구 등



4.5 인공지능 윤리 강령

(10) 세계 각국의 인공지능 규제법안 발의

- 최근 ChatGPT 등의 출현으로 인공지능의 피해기 우려됨
- 유럽과 미국 등에서 인공지능 규제법안이 발의되고 있음
- **유럽연합(EU)**이 세계 최초로 '인공지능 규제법' 최종 협상 중
- 법안에는 안면인식 기술 금지, 생성형 인공지능의 저작권 명시, 성별, 인종, 민족 등 민감 정보의 생체인식 기술 활용 금지 등
- 이 법안이 통과되면 2026년부터 이 법의 적용을 받게 됨

- **미국**도 인공지능에게 법적 책임을 묻는 '인공지능 면책조항 금지법'을 발의 중
- 만약 이 법안이 통과되면 인공지능 챗봇 제작업체들은 챗봇 답변 등에 법적 책임을 지게 됨
- 따라서 인공지능 콘텐츠 개발에 있어 엄격한 규제가 시행됨