06·1

인공지능 · 6주차 1차시

점들만 보고 선을 찾는 법, 회귀

2026.10.08 (목) 강은송 교수님 교안 Regression 1–27쪽 5주차 2차시는 휴강(개천절 대체휴일)

오늘은 질문 하나를 끝까지 따라갑니다

"손에 있는 건 데이터(점)뿐인데, x와 y의 관계를 식으로 찾을 수 있을까?"

Part 1 · 섹션 01–12

선형 회귀 — 숫자를 예측

모델 정하기 → 얼마나 틀렸는지 재기(RSS) → 가장 덜 틀리는 계수 찾기 → 평가(R^2)

Part 2 · 섹션 13–17

로지스틱 회귀 — Yes/No를 예측

직선으로는 확률이 안 됨 → 시그모이드 → 로그 오즈 → 최대우도 → 0.5 기준 분류

왜 배우고, 어디에 힘을 줄까

회귀는 4주차에 배운 **지도 학습**(입력 x와 정답 y가 함께 있음)의 첫 번째 실제 모델입니다. 오늘 익힐 "모델 식을 정한다 → 얼마나 틀렸는지 숫자로 잰다 → 그 숫자를 가장 작게(또는 크게) 만드는 계수를 찾는다"는 순서가 SVM, 결정 트리에서도 반복됩니다. 그래서 계산보다 이 흐름이 중요합니다.

구분	섹션	교수님 말씀 · 할 수 있어야 할 것
꼭 이해	01–05	x → 모델 → y 형식. 데이터(점)만 있고, 선형 회귀를 만든다는 것은 β_0, β_1을 찾는 것. 모자(^) = 예측값
흐름 이해	06	"이 식을 직접 푸는 문제는 안 나올 것 같다, 이런 식으로 푼다까지는 이해". 잔차를 제곱하는 이유는 말할 수 있어야 함
꼭 이해	07–10	R^2·Adjusted R^2의 뜻, 회귀계수는 상관관계로 해석(인과로 단정 금지)
가볍게	11	다항 회귀: "차수를 올리면 구불구불해질 수 있다" 정도. 그 이상은 심화라 안 다룸
꼭 이해	13–17	선형 회귀로 분류가 안 되는 이유, 시그모이드, $p(x)$·$1 - p(x)$·로그 오즈, 최대우도, 0.5 기준 분류

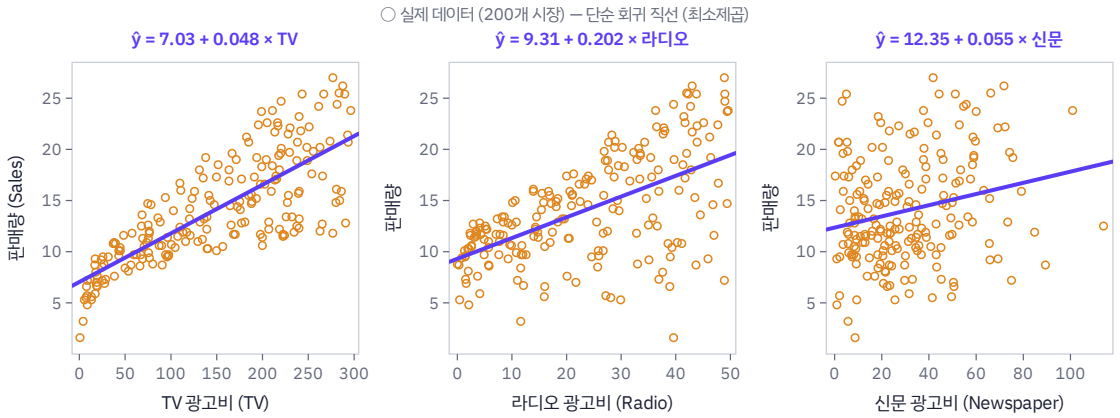
Part 1 · 교안 1–21쪽

선형 회귀 Linear Regression

01–04 데이터·용어·분류 | **05–06** 모델과 계수 찾기 | **07–10** 평가와 해석 | **11–12** 다항 회귀·질문

01

광고비로 판매량을 설명할 수 있을까



Advertising 데이터 — TV·Radio·Newspaper 광고비(가로)와 판매량 Sales(세로), 파란 선은 각각의 단순 회귀 직선

Advertising 데이터는 TV, 라디오, 신문 광고에 쓴 예산과 그 결과 **판매량** sales을 기록한 데이터입니다. 오늘 주제는 **회귀** regression입니다.

그래프 읽기와 회귀가 하려는 일

세 그래프 모두 세로축은 판매량, 가로축은 각 매체 광고비입니다.

- **TV** — 점이 오른쪽 위로 뚜렷하게 올라감 → 관계가 강함
- **Radio** — 올라가지만 점이 더 퍼져 있음
- **Newspaper** — 점이 넓게 흩어짐 → 관계가 약해 보임

파란 직선은 각 매체 하나만으로 판매량을 설명한 **단순 회귀 직선**입니다.

교수님 말씀 — 회귀가 하려는 일

저 동그라미들(데이터)을 가장 잘 설명할 수 있는 파란색 선을 찾고 싶은 것입니다. 실제로 우리가 알고 있는 것은 **동그라미(데이터)뿐**이고, 파란 선은 데이터로부터 찾아내야 합니다.

교수님 말씀 — 위치 다시 짚기

인공지능 ⊃ 기계학습 ⊃ 딥러닝 ⊃ 생성형 AI. 오늘 배우는 회귀는 이 중 **기계학습의 지도 학습**에 속합니다.

이 데이터로 던질 수 있는 질문 Questions from Data

질문	English	답하는 도구
광고비와 판매량 사이에 **관계가 있는가?**	Is there a relationship between advertising budget and sales?	회귀계수, t·F 검정
그 관계는 **얼마나 강한가?**	How strong is the relationship ...?	R^2
어떤 매체가 판매에 기여하는가?	Which media contribute to sales?	다중 회귀
미래 판매를 **얼마나 정확히** 예측할 수 있는가?	How accurately can we predict future sales?	신뢰구간
관계가 **선형**인가?	Is the relationship linear?	다항 회귀
매체끼리 **시너지**(상승효과)가 있는가?	Is there synergy among the advertising media?	수업에서 다루지 않음

이 질문들에 답하는 방법이 회귀 분석 regression analysis입니다. 입력(광고비)과 출력(판매량)의 관계를 추정하고 예측합니다.

02

x → 모델 → y

교수님 말씀 — 기본 형식

```
x → system(model) → y
```

입력 x를 시스템(모델)에 넣으면 출력 y가 나옵니다.

같은 개념을 분야마다 다른 이름으로 부릅니다. 통계학은 "독립변수·종속변수", 기계학습은 "특징·레이블"을 주로 씁니다. 오른쪽 표의 왼쪽 열끼리, 오른쪽 열끼리는 모두 같은 대상입니다.

독립변수 Independent variable x, x_i, X, $\mathbf{X}$	**종속변수** Dependent variable y, y_i, Y, $\mathbf{Y}$
Input — 입력	Output — 출력
Feature — 특징	Target — 타깃(목표값)
Attribute — 속성	Label — 레이블
Predictor — 예측변수	Response — 반응변수
Risk factor — 위험 요인	Class — 클래스(범주)
	Outcome — 결과

변수 표기법 — 스칼라, 벡터, 확률변수, 행렬

표기	모양	뜻	예
x (y)	소문자	**스칼라** — 숫자 하나	어떤 한 지역의 TV 광고비 230.1
$\mathbf{x}_i$ ($\mathbf{y}_i$)	굵은 소문자	**벡터** — 숫자 여러 개의 묶음	i번째 데이터의 (TV, Radio, Newspaper)
X (Y)	대문자	**확률변수** — 값이 확률적으로 정해지는 변수	"광고비"라는 변수 자체
X (**Y**)	굵은 대문자	**행렬** — 데이터 전체	n개 데이터 × p개 특징의 표

교수님 말씀

무조건 지켜지지는 않지만 알고 있으면 좋습니다.

광고 데이터에서는 TV·Radio·Newspaper 광고비가 **독립변수**(predictor), Sales가 **종속변수**(response)입니다. "독립"은 우리가 주는 값, "종속"은 독립변수에 따라 정해지는 값입니다. 교안이 이후 **Predictor, Response**를 계속 씁니다.

03

회귀란 What is Regression?

선형 회귀 모델 Linear Regression Model은 출력 변수 Y를 입력 변수 X들의 선형 결합 linear combination으로 나타냅니다.

선형 결합은 여러 변수에 각각 계수를 곱한 뒤 더한 형태입니다. 예: 3×TV + 0.5×Radio + 7

선형 회귀의 목적

1. 변수 X와 Y의 관계를 **수학식으로 설명**한다
2. 반응 변수 Y의 **미래 값을 예측**한다

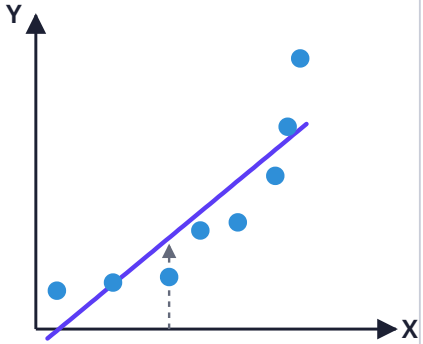
교수님 말씀 — 이번 수업의 회귀

회귀에는 선형 회귀와 로지스틱 회귀가 있습니다.

로지스틱은 Part 2(13–17)에서 다룹니다.

회귀의 분류 Category of Regression

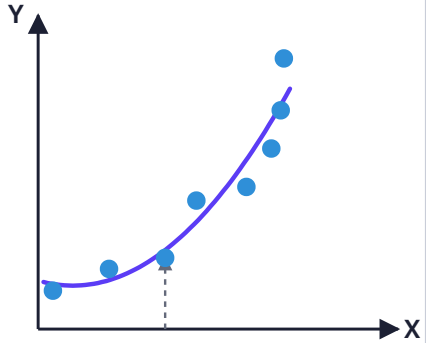
단순 선형 모델
Simple Linear Model



$y = b_0 + b_1x$

직선

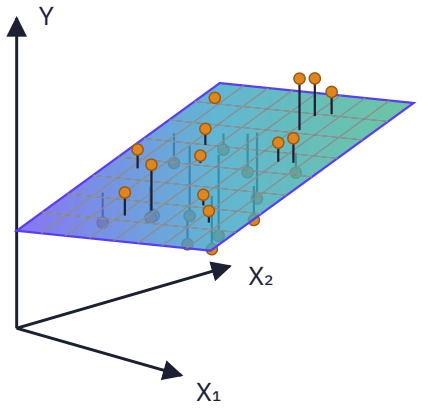
다항 모델
Polynomial Model



$y = b_0 + b_1x + b_2x^2$

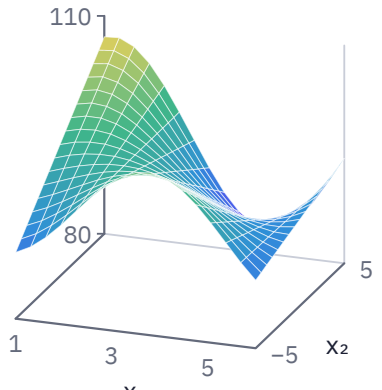
곡선 (x^2항 추가)

다중 선형 회귀
Multiple linear regression



평면 (독립변수 2개)

다중 비선형 회귀
Multiple nonlinear regression



곡면 (독립변수 2개)

교안 그림 — Simple Linear · Polynomial · Multiple linear · Multiple nonlinear

	선형 Linear	비선형 Nonlinear
단순 회귀 Simple — 독립변수 1개	$y = b_0 + b_1x$ (직선)	$y = b_0 + b_1x + b_2x^2$ (곡선, 다항 모델)
다중 회귀 Multiple — 독립변수 2개 이상	평면 (3차원에서)	곡면

교안 그림의 다항 모델 식은 $b_2x_1{}^2$로 적혀 있지만 x^2를 뜻하는 것으로 보입니다(확인 필요 1번).

수업은 선형만 — 선 → 면 → 초평면

교수님 말씀

비선형 회귀는 다루지 않습니다(훑어만 보고 넘어감). 수업에서는 **선형(linear)**만!

교수님 말씀 — 입력 x의 모양

단순 회귀: 입력이 x 하나(스칼라)

다중 회귀: 입력이 $\mathbf{x} = [x_1, x_2, \ldots, x_N]$(벡터)

독립변수	공간	회귀가 맞추는 것
1개 (단순)	2차원 (x, y)	**선** (직선)
2개 (다중)	3차원 (x_1, x_2, y)	**면** (평면) — 08 그림
3개 이상 (다중)	4차원 이상	**초평면** hyperplane

"3차원 이상부터 초평면"은 독립변수가 3개 이상이라 (x_1, x_2, x_3, y)처럼 공간이 4차원 이상인 경우입니다. 그림으로 그릴 수 없습니다.

헷갈리기 쉬운 지점 — 다항 모델은 왜 "선형 회귀"로도 부르나 보충

$$y = b_0 + b_1 x + b_2 x^2$$

이 식은 **x에 대해서는 곡선**(비선형)이지만, 계수 b_0, b_1, b_2에 대해서는 선형 결합입니다.

x^2를 새 변수 x_2로 보면 $y = b_0 + b_1 x + b_2 x_2$라는 **다중 선형 회귀와 같은 식**이 됩니다.

그래서 다항 회귀는 선형 회귀와 같은 방법(최소제곱)으로 계수를 구합니다. 교안 분류표는 **그래프 모양 기준**으로 비선형 쪽에 두었습니다.

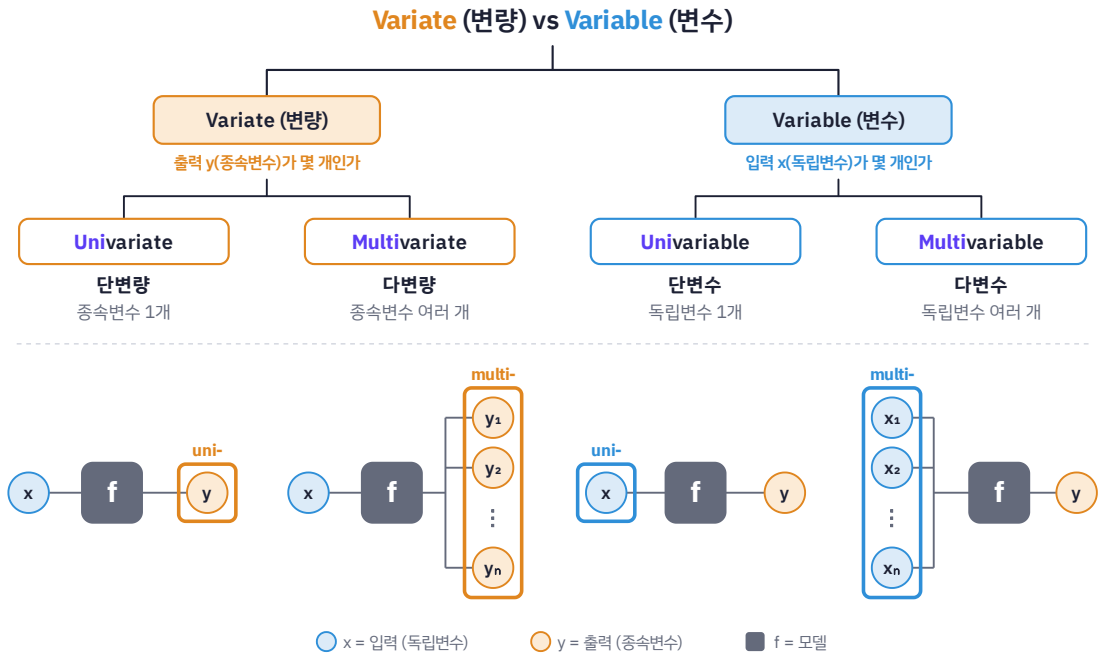
04

Variate는 y를, Variable은 x를 셉니다

"다중 회귀"를 영어로 **multiple regression**이라고 하는데, 비슷하게 생긴 **multivariate**와 자주 혼동됩니다.

노란 상자(출력 y)의 개수로 **Variate**를, 하늘색 상자(입력 x)의 개수로 **Variable**을 구분합니다.

그림 출처: soyounson.github.io/variate_variable



네 용어 정리

용어	한국어	무엇의 개수
Univariate	단변량	종속변수(y) **1개**
Multivariate	다변량	종속변수(y) **여러 개**
Univariable	단변수	독립변수(x) **1개**
Multivariable	다변수	독립변수(x) **여러 개**

광고비 3개로 판매량 1개를 예측하는 다중 회귀는 multivariable(다변수)이지 multivariate가 아닙니다.
Multivariate 회귀는 판매량과 고객 수처럼 **y를 여러 개 동시에** 예측하는 경우입니다.

교수님 말씀

우리는 variable 위주로 공부할 예정입니다.

즉 입력(x)의 개수에 따라 단변수 → 다변수로 넓혀 가고, 출력 y는 하나로 둡니다.

05

단순 선형 회귀 Simple Linear Regression

독립변수가 하나일 때, 즉 **input 하나, output 하나**일 때 다음 모델을 **가정**합니다.

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

β_0	**절편** intercept — X = 0일 때 Y의 값
β_1	**기울기** slope — X가 1 늘 때 Y가 변하는 양
β_0, β_1	**회귀계수** coefficients = **파라미터** parameters — 모르는 상수, 데이터로 추정
ε	**오차항** error term — 직선으로 설명되지 않는 나머지

교수님 말씀 — 식 읽는 법

중학교 때 배운 y = ax + b와 매치해서 생각해도 됩니다: β_1 = a(기울기), β_0 = b(절편). ε는 **에러텀**입니다.

β_0, β_1을 부르는 이름이 다양합니다: **parameter**, **(learnable) parameter**, **weight**(가중치). 모두 같은 것입니다.

무엇을 가지고 있고, 무엇을 찾나

교수님 말씀

우리가 가지고 있는 것은 **데이터**이고, 선형 회귀를 만들겠다는 것은 결국 β_0과 β_1을 찾겠다는 것입니다. X와 Y를 여러 개 보면서 찾습니다.

구분	무엇
가지고 있는 것	데이터 $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$
찾는 것 (학습)	$\beta_0, \beta_1 \rightarrow$ 추정값 $\hat{\beta}_0, \hat{\beta}_1$
내는 것	새 x에 대한 예측값 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

필기의 "가진 건 데이터 X, Y는 학습 결과"는 첫 줄·셋째 줄로 정리했습니다. 학습할 때는 x와 y를 쌍으로 모두 가지고 있습니다(정리 방식은 추측이 섞여 있음).

실제 β_0, β_1은 모릅니다. 데이터로 구한 추정값이 있으면 이렇게 예측합니다.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

교수님 말씀 — 햇 심볼

햇(hat, ^) 심볼은 예측하는 값입니다.

β_1은 진짜 기울기(모름), $\hat{\beta}_1$은 데이터로 계산한 기울기 / y는 실제 값, $\hat{y}$는 모델이 예측한 값. 이 구분이 다음 섹션 "잔차"의 열쇠입니다.

06

"잘 맞는다"를 숫자로 — 잔차 제곱합

데이터에 가장 잘 맞는 직선, 즉 $\hat{\beta}_0$과 $\hat{\beta}_1$을 어떻게 고를까요? 먼저 "가장 잘 맞는다"를 숫자로 정의해야 합니다.

- i번째 데이터의 예측값: $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$
- **잔차** Residual: $e_i = y_i - \hat{y}_i$ — 실제 값과 예측값의 차이
- **잔차 제곱합** Residual Sum of Squares, RSS:

$$RSS = e_1^2 + e_2^2 + \cdots + e_n^2$$

교수님 말씀 — 이번 수업의 범위

단순 선형 회귀에서 직접 식을 풀어서 구하는 것 정도만 해 봅니다.

경사하강법 gradient descent도 하지만 그건 뒤쪽에서 다룹니다. 우리는 x, y를 가지고 있습니다.

RSS를 가장 작게 만드는 $\hat{\beta}_0, \hat{\beta}_1$ = 최소제곱법

$$RSS = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

잔차 e_i에 예측식을 그대로 넣어 펼친 같은 식

RSS는 **$\hat{\beta}_0, \hat{\beta}_1$을 무엇으로 고르느냐에 따라 값이 바뀌는 함수**입니다. 이 값을 가장 작게 만드는 $\hat{\beta}_0, \hat{\beta}_1$을 찾는 방법이 최소제곱법 least squares입니다.

교안: "Find estimator of β_0 and β_1 (i.e., $\hat{\beta}_0$ and $\hat{\beta}_1$)." 즉 이 단계의 목표는 진짜 계수의 추정값을 구하는 것입니다.

왜 제곱하나

교수님 말씀

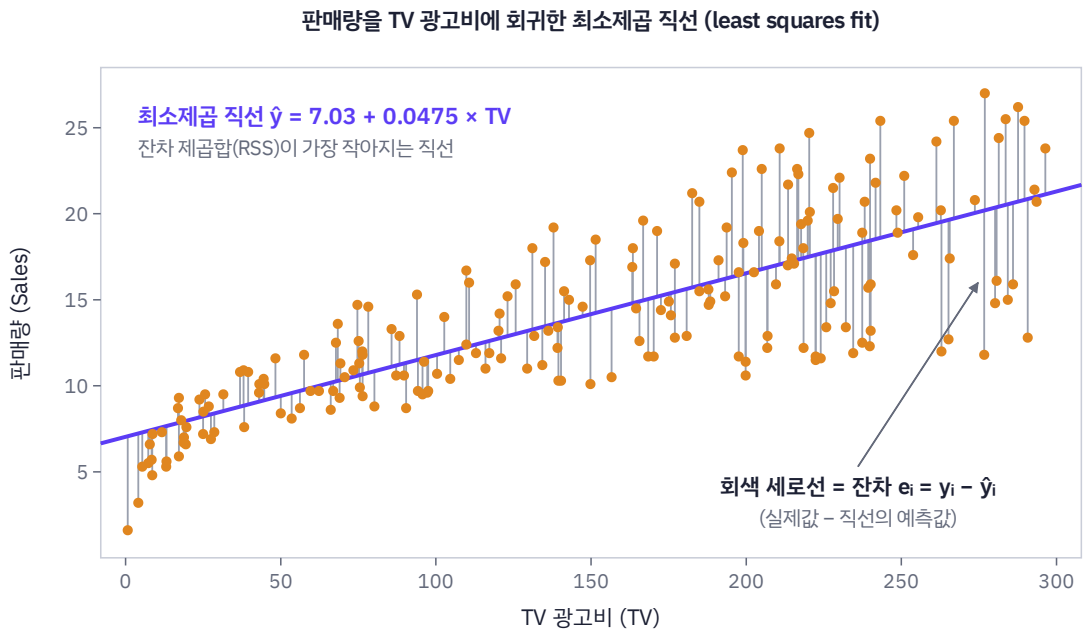
잔차를 **제곱**해서 더하기도 하고, **절댓값**으로 더하기도 하고, (제곱합에) **루트**를 씌우기도 합니다. 공통점은 모두 양수로만 만든다는 것입니다.

이유: 오차가 +2인 점도 있고 −2인 점도 있을 수 있는데, 그대로 더하면 0이 되어 오차가 없는 것처럼 계산되어 버리기 때문입니다.

방법	식	보충
제곱해서 더하기	$\sum e_i^2$	RSS — 최소제곱법. 미분이 쉬워 직접 풀이 가능
절댓값으로 더하기	$\sum \lvert e_i \rvert$	평균내면 MAE(평균절대오차). 큰 오차에 덜 민감
제곱합에 루트	$\sqrt{(\sum e_i^2 / n)}$	RMSE. 단위가 y와 같아 해석이 쉬움

예: 잔차가 (+2, −2)이면 그냥 더하면 **0**, 제곱합은 8, 절댓값 합은 4. 앞의 0은 "완벽하다"는 틀린 결론을 줍니다.

예: 판매량을 TV 광고비에 회귀한 최소제곱 직선



The least squares fit for the regression of sales onto TV — 회색 세로선이 잔차

교수님 말씀

예시 그래프에서 **회색선은 에러텀**(오차)을 의미합니다.

회귀는 어디까지나 최적·최선을 찾는 것입니다. 지금 데이터에 완벽하게 맞춰도, 새로운 데이터가 들어오면 100% 맞지 않을 수 있습니다.

엄밀히는 ε(진짜 직선에서 벗어난 양)과 잔차 e_i(추정한 직선에서 벗어난 양)는 다르지만, 잔차는 오차를 데이터로 추정한 값이라 같은 뜻으로 써도 됩니다. 뒷부분은 4주차의 **일반화**와 같은 이야기입니다.

최소제곱 추정 알고리즘 3단계 Least Squares Estimation Algorithm

1 **오차 제곱합을 식으로 쓴다** $\sum_{i=1}^{n} \{ y_i - (\beta_0 + \beta_1 x_i) \}^2$

2 **이 값을 최소로 하는 β_0, β_1을 찾는 문제로 정의**

$$C(\beta_0, \beta_1) = \min_{\beta_0, \beta_1} \sum_{i=1}^{n} \{ y_i - (\beta_0 + \beta_1 x_i) \}^2 \quad \cdot \quad (\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{\beta_0, \beta_1} C(\beta_0, \beta_1)$$

arg min = 최솟값 자체가 아니라, 최솟값을 만드는 변수 값

3 **각 계수로 편미분해서 0으로 놓는다**

$$\frac{\partial C}{\partial \beta_0} = -2 \sum (y_i - (\beta_0 + \beta_1 x_i)) = 0 \qquad \frac{\partial C}{\partial \beta_1} = -2 \sum (y_i - (\beta_0 + \beta_1 x_i)) \, x_i = 0$$

교수님 말씀 — 줄이려는 함수의 이름 (Step 2)

내가 줄이고자 하는 함수를 어떻게 정의할지에 따라 이름이 여러 가지입니다: **목적함수** objective, **손실함수** loss, **비용함수** cost. 위 식의 C가 cost의 C입니다.

왜 미분해서 0으로 놓나 보충

C는 β_0, β_1에 대한 **아래로 볼록한 2차 함수**입니다. 그릇 모양이라 가장 낮은 지점에서는 기울기(미분값)가 0입니다.

그래서 "미분 = 0"인 지점을 풀면 최소점이 나옵니다. 1학기에 배운 "극솟값에서 미분 = 0"과 같은 원리입니다.

편미분(∂)이란

C는 변수가 β_0, β_1 두 개인 함수입니다. **편미분** partial derivative $\partial C/\partial\beta_0$은 β_1을 상수로 고정하고 β_0으로만 미분한 것입니다.

예: $C = (y - \beta_0 - \beta_1 x)^2$이면 체인 규칙으로

$\partial C/\partial\beta_0 = 2(y - \beta_0 - \beta_1 x)\cdot(-1) = -2(y - \beta_0 - \beta_1 x)$

$\partial C/\partial\beta_1 = 2(y - \beta_0 - \beta_1 x)\cdot(-x) = -2(y - \beta_0 - \beta_1 x)x$

교안 3단계 식의 −2와 x_i가 여기서 나옵니다.

두 식을 연립해서 풀면 — 해 Solution

$$\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\bar{x} = \frac{1}{n}\sum x_i, \quad \bar{y} = \frac{1}{n}\sum y_i$$

평균

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$를 다시 쓰면 $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$. 즉 회귀직선은 항상 평균점 $(\bar{x}, \bar{y})$를 지납니다.

교수님 말씀

$\bar{x}$(x바), $\bar{y}$(y바)는 **평균**을 의미합니다.

이 식을 직접 푸는 문제는 안 나올 것 같습니다. 그냥 "이런 식으로 푼다"까지는 이해가 필요합니다.

손으로 한 번 계산해 보기 보충 예제

점 3개 **(1, 2), (2, 3), (3, 5)** → $\bar{x} = 2$, $\bar{y} = 10/3$

1. 분자 $\sum(x_i - \bar{x})(y_i - \bar{y}) = (-1)(-4/3) + 0 + (1)(5/3) =$ **3**
2. 분모 $\sum(x_i - \bar{x})^2 = 1 + 0 + 1 =$ **2** → $\hat{\beta}_1 = 1.5$
3. $\hat{\beta}_0 = 10/3 - 1.5 \times 2 = 1/3$ → $\hat{y} = 0.333 + 1.5x$

확인

예측값 1.833, 3.333, 4.833

→ 잔차 0.167, −0.333, 0.167

→ 잔차의 합이 0입니다. 3단계 첫 번째 식($\partial C/\partial \beta_0 = 0$)이 바로 "잔차의 합 = 0"이라는 조건입니다.

07

결정계수 R^2 Coefficient of Determination

직선을 구했으면 "이 직선이 데이터를 **얼마나 잘 설명하는가**"를 숫자로 알고 싶습니다.

- 회귀 모델이 데이터의 변동을 얼마나 잘 설명하는지 나타내는 척도
- y의 전체 분산 중 모델이 설명하는 비율
- 범위: $0 \le R^2 \le 1$ (모델이 매우 나쁘면 음수가 나오기도 함)
  $R^2 = 1$이면 잘 맞음, 0이면 못 맞춤

$$R^2 = 1 - \frac{SSE}{SST} = \frac{SSR}{SST}$$

$$SST = SSR + SSE$$

y의 전체 변동을 둘로 나눔

변동의 분해 — SST = SSR + SSE



SST	Y의 전체 변동 (Total)	$\Sigma(y_i - \bar{y})^2$
SSR	모형에 의해 설명되는 변동 (Regression)	$\Sigma(\hat{y}_i - \bar{y})^2$
SSE	모형에 의해 설명되지 않는 변동 (Error)	$\Sigma(y_i - \hat{y}_i)^2$

SST = SSR + SSE → R^2 = SSR / SST

기호	식	뜻
SST Total	$\sum(y_i - \bar{y})^2$	Y의 **전체** 변동
SSR Regression	$\sum(\hat{y}_i - \bar{y})^2$	모형에 의해 설명되는 변동
SSE Error	$\sum(y_i - \hat{y}_i)^2$	모형으로 설명되지 않는 변동 (= RSS)

그냥 평균 $\bar{y}$로 예측했을 때의 오차가 SST입니다. 회귀선을 쓰면 그 중 SSR만큼이 설명되고 SSE만큼이 남습니다. 그래서 R^2 = SSR/SST는 "평균만 쓸 때보다 오차를 몇 % 줄였나"입니다. R^2 = 0.8이면 Y 변동의 80%를 X로 설명합니다.

06의 예제로 R^2 계산하기

$y = (2, 3, 5)$, $\bar{y} = 10/3$

1. $SST = (4/3)^2 + (1/3)^2 + (5/3)^2 = 42/9 \approx$ **4.667**
2. $SSE = 0.167^2 + 0.333^2 + 0.167^2 \approx$ **0.167**
3. $R^2 = 1 - 0.167 / 4.667 \approx$ **0.964**

평균만 쓸 때의 오차 중 **96.4%**를 직선이 줄였다는 뜻입니다.

R^2가 음수가 되는 경우 (보충)

최소제곱으로 구한 직선을 같은 데이터에 쓰면 $SSE \le SST$라서 R^2는 0 이상입니다.

그런데 다른 방법으로 만든 모델이나 **테스트 데이터**에서 재면, 평균 $\bar{y}$로만 예측하는 것보다 오차가 더 클 수 있습니다($SSE > SST$). 그러면 $1 - SSE/SST$가 음수가 됩니다. 교안의 "sometimes negative if the model is very poor"가 이 경우입니다.

08

다중 선형 회귀 Multiple Linear Regression

01의 그래프는 매체를 하나씩 따로 봤습니다. 하지만 실제 판매량은 세 매체가 함께 만든 결과입니다. 독립변수를 여러 개 한꺼번에 넣는 모델입니다.

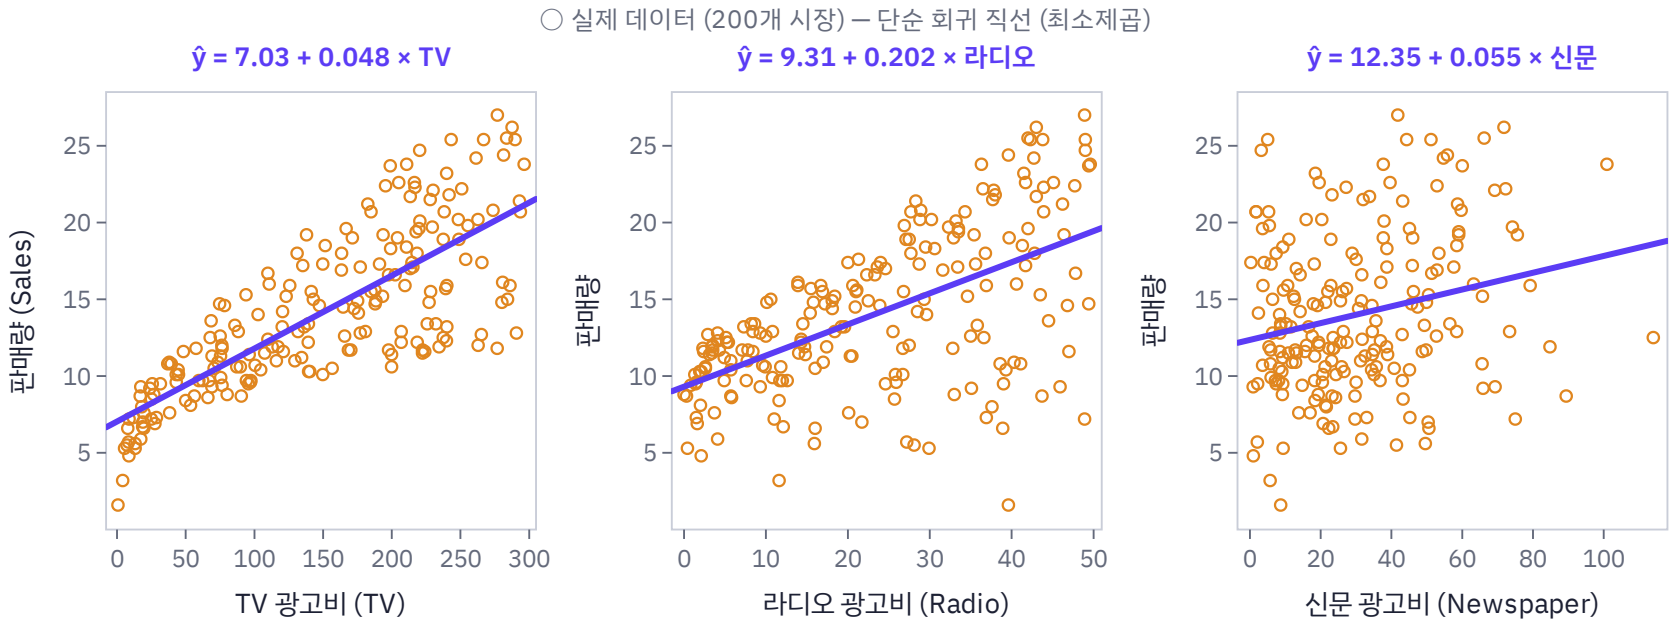
$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon$$

β_j는 다른 예측변수를 모두 고정했을 때, X_j가 1 늘면 Y가 **평균적으로** 얼마나 변하는지를 뜻합니다.

We interpret β_j as the average effect on Y of a one unit increase in X_j, holding all other predictors fixed.

광고 예제의 다중 회귀 모델

$$\text{sales} = \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times \text{newspaper} + \varepsilon$$



교안 15쪽 — 01과 같은 세 산점도

세 그래프를 따로 보는 대신, 세 광고비를 한 식에 동시에 넣어 판매량을 설명합니다. 그래서 β_1은 "라디오·신문 광고비가 그대로일 때 TV 광고비가 1 늘면 판매량이 평균적으로 얼마나 변하나"입니다.

추정과 예측 Estimation and Prediction

추정값 $\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_p$가 있으면 다음 식으로 예측합니다.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p$$

계수는 단순 회귀와 똑같이 잔차 제곱합을 최소로 하는 값으로 정합니다.

$$\text{RSS} = \sum (y_i - \hat{y}_i)^2 = \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \cdots - \hat{\beta}_p x_{ip})^2$$

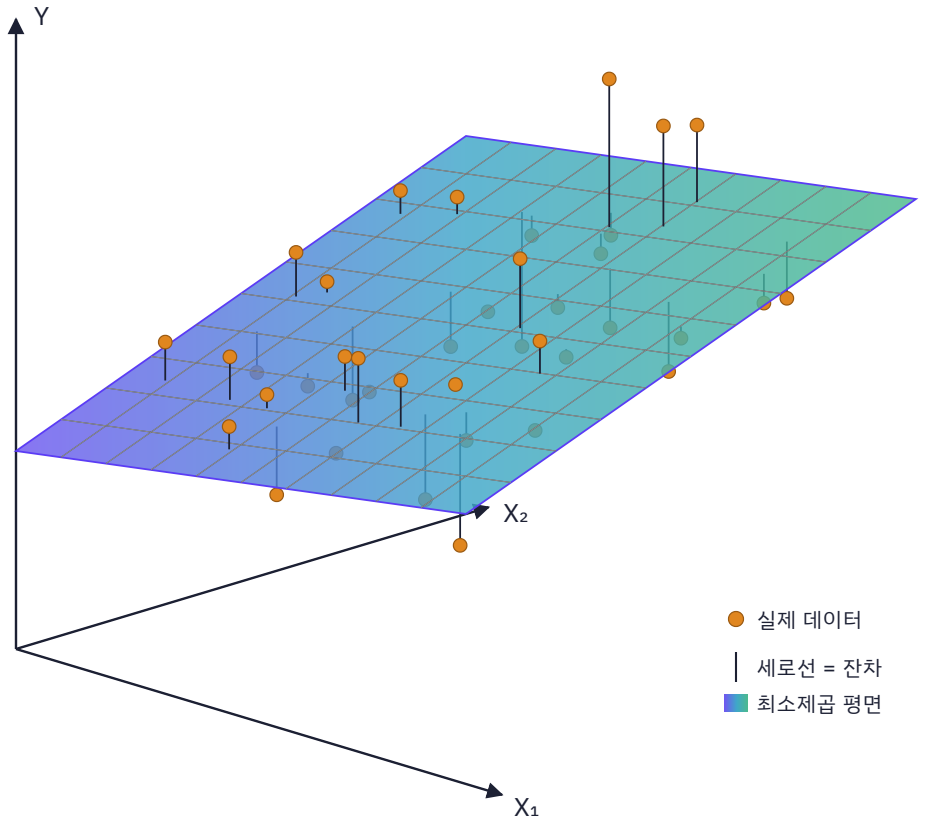
x_{ij}는 i번째 데이터의 j번째 변수입니다(행 = 데이터, 열 = 변수). 데이터 전체를 n × p 행렬로 놓고 행렬 계산으로 한 번에 풉니다.

변수가 2개면 직선 대신 평면

독립변수가 2개면 입력 공간이 평면(X_1, X_2)이고 출력 Y가 높이가 되므로, 맞추는 대상이 직선이 아니라 평면입니다.

빨간 점은 실제 데이터, 검은 세로선은 잔차입니다. **이 선 길이의 제곱합이 최소가 되는 평면**을 찾습니다.

변수가 3개 이상이면 그림으로 그릴 수 없는 **초평면** hyperplane이 됩니다(03의 선 → 면 → 초평면).



다중 선형 회귀 (Multiple Linear Regression)

$\hat{y} = b_0 + b_1x_1 + b_2x_2$ → 3차원에서 평면

09

수정된 결정계수 Adjusted R^2

다중 회귀에서 R^2를 그대로 쓰면 문제가 있습니다. 변수를 하나 더 넣으면, 쓸모없는 변수라도 R^2는 내려가지 않습니다.

최소제곱은 새 변수의 계수를 0으로 두는 선택지도 가지고 있어서 SSE가 커질 수 없기 때문입니다. 그래서 변수를 마구 늘리면 모델이 좋아 보이는 착시가 생깁니다.

$$\text{Adjusted } R^2 = 1 - \frac{SSE / (n - p - 1)}{SST / (n - 1)}$$

n: 표본 크기 sample size · p: 예측변수 개수 number of predictors

- 조정 항 $(n - 1)/(n - p - 1)$이 예측변수 추가에 벌점 penalizes
- 변수를 더 넣었을 때 적합도가 **과대평가되는 것을 막음**

숫자로 보면 벌점이 보입니다 보충

식 읽는 법: R^2의 SSE/SST를 각각 **자유도**로 나눈 "평균" 버전입니다. p가 커지면 분모 n − p − 1이 작아져 SSE/(n − p − 1)이 커지므로, 변수를 넣어서 SSE가 그만큼 줄지 않으면 Adjusted R^2는 오히려 떨어집니다.

n = 20, SST = 100	R^2	Adjusted R^2
변수 2개, SSE = 30	0.700	1 − (30/17)/(100/19) ≈ **0.665**
쓸모없는 변수 1개 추가, SSE = 29.8	0.702 ↑	1 − (29.8/16)/(100/19) ≈ **0.646** ↓

10

회귀계수 해석 Interpreting Regression Coefficients

이상적인 경우 — 균형 설계 balanced design

예측변수끼리 **상관이 없을 때**

- 각 계수를 따로따로 추정하고 검정할 수 있음
- "X_j가 1 변하면, 다른 변수가 그대로일 때 Y가 β_j만큼 변한다"는 해석이 가능

문제 — 예측변수끼리 상관이 있을 때

- 모든 계수의 **분산이 커짐**. 때로는 매우 크게 — 데이터가 조금만 달라져도 계수가 크게 바뀜
- 해석이 위험해짐 — X_j가 변하면 다른 변수도 같이 변하기 때문

예로 보면 + 인과관계 주장은 피하라

TV 광고비를 늘리는 회사가 라디오 광고비도 같이 늘리는 경향이 있다면, 데이터에서 TV만 따로 늘어난 경우를 보기 어렵습니다. 그러면 "TV를 1 늘리고 라디오는 고정"이라는 상황 자체가 데이터에 거의 없어서 β_{TV}를 믿기 어렵습니다.

예측변수끼리 강하게 상관된 상태를 **다중공선성** multicollinearity이라고 부릅니다(보충).

관찰 데이터 observational data로는 인과관계를 주장하지 말아야 합니다. Claims of causality should be avoided for observational data.

교수님 말씀 — 상관관계로 해석해야 함

회귀계수는 상관관계로 해석해야 합니다. 인과관계라고 **단정 지으면 안 됩니다.**

우리가 x → g(x) → y 형태를 배우고 있어서, x를 넣으면 y가 나오니까 "x가 y의 원인"이라고 생각하기 쉽습니다. 하지만 사실은 **x와 y의 상관관계**로 생각해야 합니다.

11

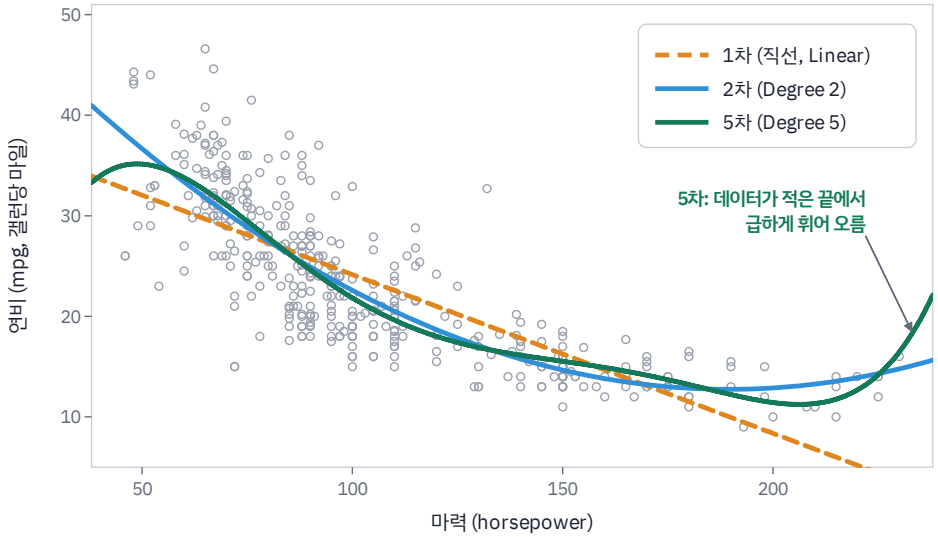
다항 회귀 Polynomial Regression

관계가 직선이 아니면 예측변수의 **제곱 항** 등을 새 변수로 추가합니다 Non-linear effects of predictors.

교수님 말씀 — 잠깐 다뤄본 정도 (편하게 들으라고 하심)

- 회귀가 non-linear할 수도 있구나 정도
- degree 2, degree 5처럼 차수를 올리면 구불구불해질 수 있다 정도
- 이 이상은 심화 과정이라 다루지 않음

$$mpg = \beta_0 + \beta_1 \times horsepower + \beta_2 \times horsepower^2 + \varepsilon$$



다항 회귀 예시 (polynomial regression) — 자동차 392대 (Auto 데이터)

세 곡선 비교 — 연비(mpg)를 마력(horsepower)으로

$$\text{mpg} = \beta_0 + \beta_1 \times \text{horsepower} + \beta_2 \times \text{horsepower}^2 + \varepsilon$$

모델	모양	평가 (보충)
Linear (1차, 주황)	직선	휘어진 추세를 따라가지 못함 — **과소적합**
Degree 2 (2차, 하늘색)	아래로 볼록한 완만한 곡선	데이터 추세를 잘 따라감
Degree 5 (5차, 초록)	구불구불, 끝에서 꺾임	데이터가 적은 양 끝에서 불필요하게 휨 — **과적합** 경향

차수를 올릴수록 훈련 데이터에는 더 잘 맞지만, 데이터가 드문 곳에서 엉뚱한 값을 냅니다.

회귀에서 중요한 질문 4가지 Important Questions in Regression

#	질문	도구
1	예측변수 $X_1, \ldots, X_p$ 중 **적어도 하나는** 반응 예측에 쓸모가 있는가?	개별 계수: **t-검정** 모델 전체: **F-검정**
2	**모든** 예측변수가 필요한가, 일부만 쓸모 있는가?	**전진·후진 선택** Forward/Backward
3	모델이 데이터에 **얼마나 잘 맞는가**?	**R^2, Adjusted R^2**
4	주어진 예측변수 값에서 반응을 얼마로 예측하고, **그 예측은 얼마나 정확한가**?	**신뢰구간** Confidence interval

도구 간단 설명 (보충)

t-검정: 계수 하나가 0인지(그 변수가 효과가 없는지) · **F-검정**: 모든 계수가 동시에 0인지(모델 전체가 쓸모없는지) · **전진 선택**: 변수 없이 시작해 가장 도움 되는 변수를 하나씩 추가 · **후진 선택**: 모두 넣고 가장 쓸모없는 변수를 하나씩 제거 · **신뢰구간**: 예측값을 "95% 확률로 이 범위 안"처럼 구간으로

Part 1 정리

선형 회귀 — 숫자를 예측

- x → model → y. 데이터(점)만 가지고 β_0(절편), β_1(기울기)을 찾는 것이 선형 회귀. 모자(^) = 추정·예측값.
- 잔차 $e_i = y_i - \hat{y}_i$. +와 −가 상쇄되지 않게 **제곱**해서 더한 RSS를 최소로 → **최소제곱법**(편미분 = 0으로 풀이).
- $\hat{\beta}_1 = \sum(x-\bar{x})(y-\bar{y})/\sum(x-\bar{x})^2$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$ — **직접 푸는 문제는 안 나올 것**, 흐름은 이해.
- $R^2 = 1 - SSE/SST = SSR/SST$. 변수가 많으면 **Adjusted R^2**로 벌점.
- 다중 회귀: 선 → 면 → 초평면. 계수는 상관관계로 해석(인과 단정 금지). 다항 회귀는 "구불구불해질 수 있다"까지.

Part 2 · 교안 22–27쪽

로지스틱 회귀 Logistic Regression

13–14 직선으로 분류가 안 되는 이유 | **15** 시그모이드·로그 오즈 | **16** 최대우도 | **17** 0.5 기준 분류

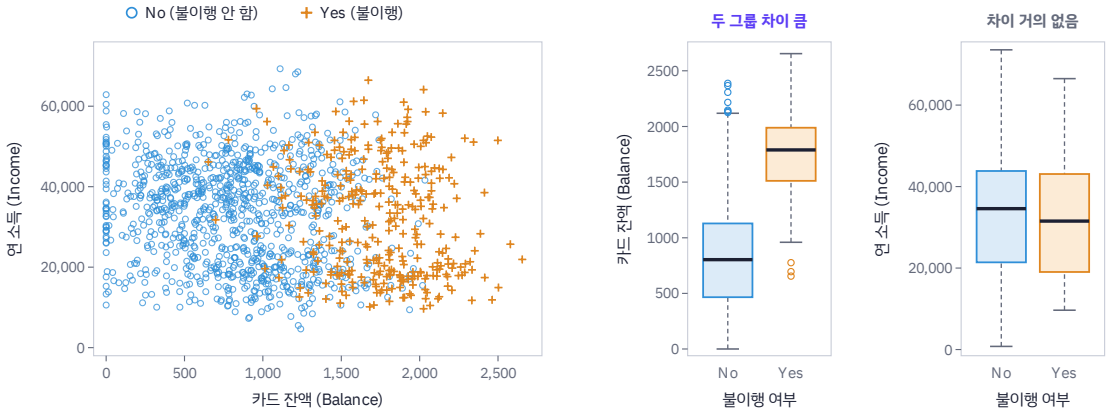
13

이번에는 y가 Yes/No입니다

지금까지 Y는 숫자(판매량, 연비)였습니다. 이번에는 카드 사용자가 **채무불이행** default을 할지 예측하는 **Default 데이터**입니다.

$$Y = 0 \text{ (No)}, \quad 1 \text{ (Yes)}$$

파란 ◯ = No(불이행 안 함), 주황 + = Yes. Yes는 **Balance(카드 잔액)가 큰 오른쪽**에 몰려 있습니다. 상자그림을 보면 Balance는 두 그룹 차이가 크고, Income은 차이가 거의 없습니다.



그냥 선형 회귀 후 $\hat{Y} > 0.5$면 Yes로 하면 안 될까?

그럴듯해 보이는 이유

Y가 0 또는 1이면 Y의 평균(기대값)이 곧 "Y = 1일 확률"입니다.

$$E(Y \mid X = x) = Pr(Y = 1 \mid X = x)$$

평균을 예측하는 회귀가 확률을 예측하는 셈이 됩니다.

$E(Y \mid X = x)$: X = x일 때 Y의 기대값 · $Pr(Y = 1 \mid X = x)$: X = x일 때 Y = 1일 조건부 확률

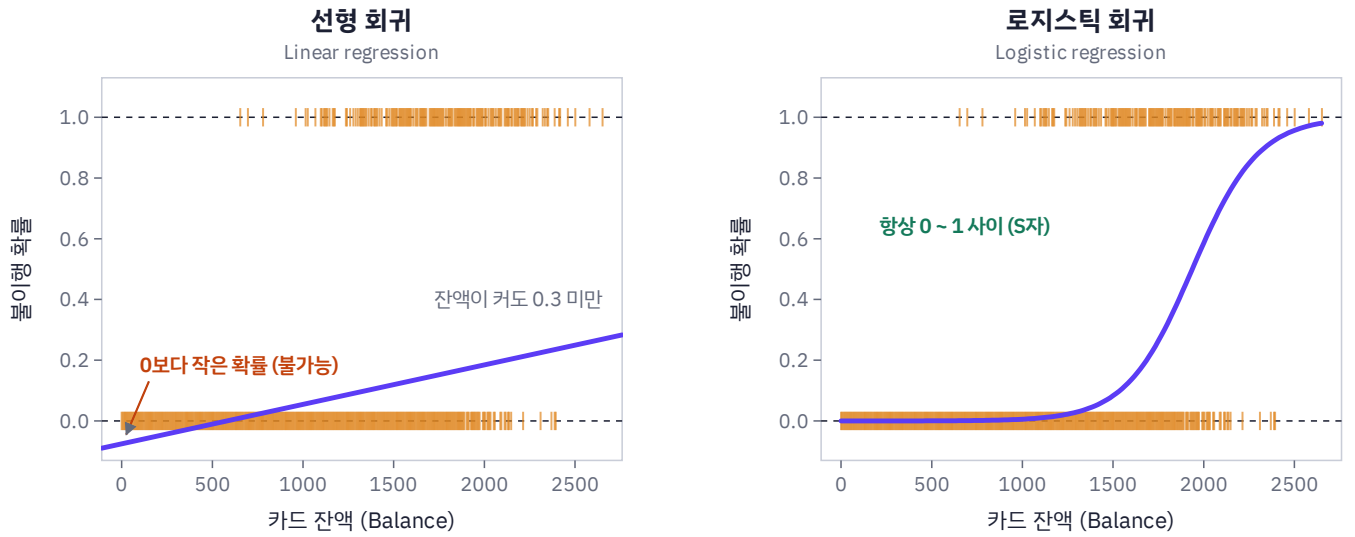
문제

선형 회귀는 직선이라서 0보다 작거나 1보다 큰 "확률"을 낼 수 있습니다.

확률은 반드시 0~1 사이여야 하므로 말이 안 됩니다.

→ 로지스틱 회귀가 더 적절합니다.

선형 회귀 vs 로지스틱 회귀 Linear vs. Logistic Regression



주황 눈금 = 실제 관측(No는 0, Yes는 1 위치) · 왼쪽 선형 회귀, 오른쪽 로지스틱 회귀

	선형 회귀 (왼쪽)	로지스틱 회귀 (오른쪽)
모양	직선	S자 곡선
출력 범위	제한 없음 — Balance가 작으면 **음수**	항상 **0 ~ 1**
데이터 적합	Balance가 커도 0.25 정도에 그침	1500~2000에서 급격히 올라 1에 가까워짐

15

직선을 시그모이드에 넣는다

p(X) = Pr(Y = 1 | X)로 줄여 쓰고, balance로 default를 예측합니다. 로지스틱 회귀는 다음 형태를 씁니다.

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

p(X)는 항상 0과 1 사이입니다. 두 번째 식은 첫 번째 식의 분자·분모를 $e^{\beta_0+\beta_1 X}$로 나눈 것입니다.

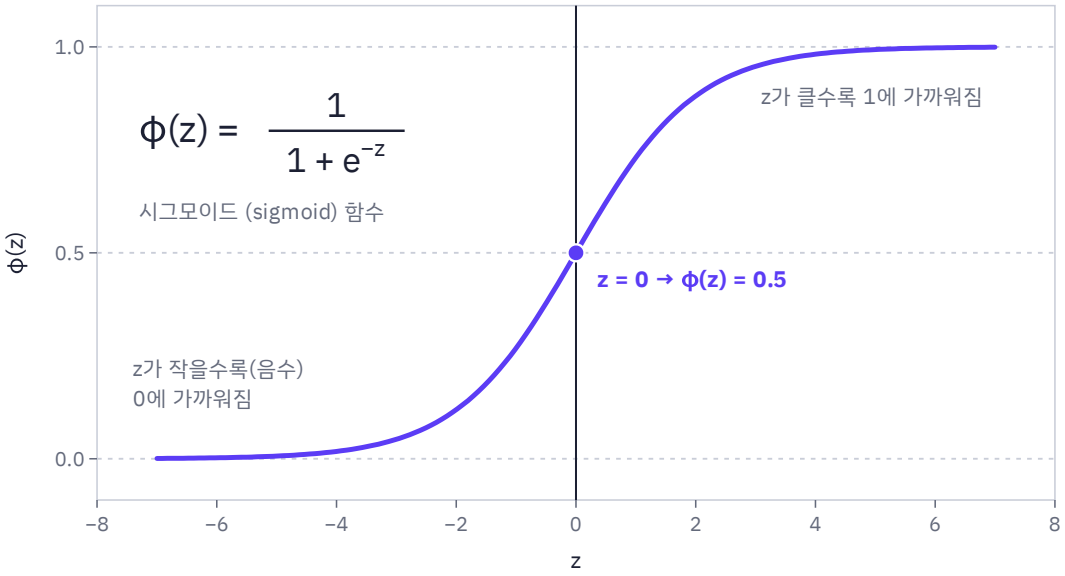
구조 읽기: 괄호 안 $\beta_0 + \beta_1 X$는 선형 회귀와 똑같은 직선입니다. 그 직선 값을 **시그모이드 함수**에 넣어서 0~1 사이로 눌러 준 것이 로지스틱 회귀입니다.

시그모이드 함수 Sigmoid Function

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

- z = 0에서 정확히 0.5
- z가 커지면 1에, 작아지면 0에 가까워짐
- **어떤 실수든 0~1로** 바꿔 줌

로지스틱 회귀에서는 z 자리에 직선 $\beta_0 + \beta_1 X$가 들어갑니다.



로그 오즈 log odds · logit 변환

식을 조금 정리하면:

$$\log\left(\frac{p(X)}{1-p(X)}\right) = \beta_0 + \beta_1 X$$

이 변환을 p(X)의 **로그 오즈** 또는 **로짓** 변환이라 합니다.

즉 로지스틱 회귀는 "로그 오즈가 X에 대해 선형"이라고 가정한 모델입니다. β_1은 X가 1 늘 때 로그 오즈가 늘어나는 양입니다.

교수님 말씀 — 로그 오즈의 분자·분모

p(x)는 y가 1일 확률,

1 − p(x)는 y가 0일 확률입니다.

그래서 p(x) / (1 − p(x))는 "y = 1일 확률 ÷ y = 0일 확률"입니다. Default 예제로 읽으면 "채무불이행(Yes)일 확률 ÷ 아닐(No) 확률"입니다.

오즈와 로그 오즈를 숫자로 보기

p(x) = P(y=1)	1 − p(x)	오즈 p/(1−p)	로그 오즈	뜻
0.5	0.5	1	**0**	1과 0이 반반
0.8	0.2	4	≈ 1.39 (양수)	1일 가능성이 0의 4배
0.2	0.8	0.25	≈ −1.39 (음수)	0일 가능성이 1의 4배

로그 오즈가 **0이면 p = 0.5**, 양수면 p > 0.5(1 쪽), 음수면 p < 0.5(0 쪽). 17의 "0.5 기준 분류"는 결국 "$\beta_0 + \beta_1 X$가 0보다 큰가"와 같은 말입니다.

왜 로그 오즈를 직선과 같다고 놓을 수 있나

오즈 odds = p / (1 − p): 일어날 확률 ÷ 일어나지 않을 확률.

확률 p는 0~1, 오즈는 0~∞, 로그 오즈는 −∞~+∞입니다. 그래서 범위 제한이 없는 직선과 같다고 놓을 수 있습니다.

변형(보충): $z = \beta_0 + \beta_1 X$로 두면 $p = e^z/(1 + e^z)$, $1 - p = 1/(1 + e^z)$ → $p/(1 - p) = e^z$ → 양변에 자연로그 → $\log(p/(1 - p)) = z$

16

최대우도 Maximum Likelihood

선형 회귀의 계수는 RSS 최소로 구했는데, 로지스틱 회귀의 계수는 최대우도로 구합니다.

$$\ell(\beta_0, \beta_1) = \prod_{i:\, y_i=1} p(x_i) \prod_{i:\, y_i=0} (1 - p(x_i))$$

∏는 모두 곱하라는 기호입니다. 실제로 Yes였던 사람($y_i = 1$)에게는 모델이 준 **Yes 확률 $p(x_i)$**를, No였던 사람에게는 **No 확률 $1 - p(x_i)$**를 곱합니다. 이 곱 ℓ이 **우도** likelihood — "현재 계수라면 실제로 관찰된 결과가 나올 확률"입니다.

예: 두 사람, A = Yes, B = No

모델 1: p(A) = 0.9, p(B) = 0.2

$\ell = 0.9 \times 0.8 =$ **0.72**

모델 2: p(A) = 0.6, p(B) = 0.5

$\ell = 0.6 \times 0.5 =$ **0.30**

실제 결과를 더 잘 설명하는 모델 1의 우도가 더 큽니다. 이 값을 최대로 만드는 β_0, β_1을 고릅니다.

추정된 계수로 확률 계산하기

Default 데이터에서 추정된 계수: $\hat{\beta}_0 = -10.6513$, $\hat{\beta}_1 = 0.0055$

Balance $1000의 채무불이행 확률은?

$$\hat{p}(X) = \frac{e^{-10.6513 + 0.0055 \times 1000}}{1 + e^{-10.6513 + 0.0055 \times 1000}} = 0.006$$

지수 $-5.1513 \rightarrow e^{-5.1513} \approx 0.00579 \rightarrow 0.00579 / 1.00579 \approx 0.006$ (0.6%)

Balance $2000이면?

$$\hat{p}(X) = \frac{e^{-10.6513 + 0.0055 \times 2000}}{1 + e^{-10.6513 + 0.0055 \times 2000}} = 0.586$$

지수 $0.3487 \rightarrow e^{0.3487} \approx 1.417 \rightarrow 1.417 / 2.417 \approx 0.586$ (58.6%)

잔액이 두 배가 됐는데 확률은 0.6% → 58.6%로 약 100배 뛰었습니다. 확률이 직선이 아니라 **S자**로 변하기 때문입니다(14의 1500~2000 구간).

로지스틱 회귀로 분류하기 Logistic Regression for Classification

핵심: 로지스틱 회귀는 확률 $\hat{p}(X) = P(Y = 1 \mid X)$를 출력합니다. 분류하려면 확률에 **기준선**을 정합니다.

예측 Y = 1 (Yes, Default) $\hat{p}(X) > 0.5$
예측 Y = 0 (No, Non-default) $\hat{p}(X) \le 0.5$

Balance	$\hat{p}(X)$	0.5와 비교	예측
1000	0.006	≤ 0.5	**No Default**
2000	0.586	> 0.5	**Default**

로지스틱 회귀는 확률을 추정하는 데서 끝나지 않고, 분류 결정까지 내립니다.

4주차와 연결

4주차 2차시 지도 학습 알고리즘 표에서 "로지스틱 회귀는 이름과 달리 분류"라고 했던 이유입니다. 내부에서 확률(연속값)을 회귀로 구해서 이름에 "회귀"가 붙고, 최종 출력은 클래스입니다.

보충: $\hat{p} = 0.5$가 되는 경계는 $\hat{\beta}_0 + \hat{\beta}_1 X = 0$, 즉 $X = 10.6513 / 0.0055 \approx 1937$. 기준 0.5는 바꿀 수 있습니다(채무불이행을 놓치는 게 더 위험하면 0.2처럼 낮춤).

선형 회귀 vs 로지스틱 회귀 한 장 비교

	선형 회귀	로지스틱 회귀
y의 종류	숫자 (판매량 등)	0 / 1 (Yes / No)
출력	$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ (범위 제한 없음)	$\hat{p}(X) = 1 / (1 + e^{-(\hat{\beta}_0 + \hat{\beta}_1 X)})$ (0~1 확률)
직선이 있는 곳	출력 그 자체	로그 오즈 $\log(p/(1-p))$
계수 찾는 기준	RSS 최소 (최소제곱)	우도 최대 (최대우도)
평가·결정	R^2, Adjusted R^2	0.5 기준으로 분류
과제 종류	회귀	분류 (이름만 회귀)

용어 정리 ① — 선형 회귀

독립변수 · 종속변수	입력 x(특징, 예측변수) / 출력 y(반응변수, 목표). x → model → y.
회귀계수 coefficient	β_0, β_1. 데이터로 찾아야 하는 값. 파라미터·learnable parameter·가중치로도 부름.
추정값 (햇)	$\hat{y}$, $\hat{\beta}$. 모자(^)는 데이터에서 추정·예측한 값이라는 표시.
잔차 · 에러텀	$e_i = y_i - \hat{y}_i$ (실제 − 예측). ε는 모델로 설명 못 하는 오차.
잔차 제곱합 RSS (= SSE)	$\sum(y_i - \hat{y}_i)^2$. 부호 상쇄를 막으려고 제곱. 선형 회귀는 이것을 최소화.
목적·손실·비용함수	줄이고자 하는 함수의 여러 이름(objective · loss · cost). 오늘은 RSS.
최소제곱법 least squares	RSS를 최소로 하는 계수를 미분 = 0으로 직접 풀어 구하는 방법.

용어 정리 ② — 평가와 로지스틱 회귀

결정계수 R^2	1 − SSE/SST = SSR/SST. y 변동 중 모델이 설명하는 비율.
수정된 결정계수	변수 개수 p로 벌점을 준 R^2. 쓸모없는 변수를 넣으면 내려간다.
다변수 · 다변량	multivariable: 입력 x가 여러 개 / multivariate: 출력 y가 여러 개. 수업은 variable 위주.
초평면 hyperplane	입력이 3개 이상일 때 회귀가 맞추는 대상. 선 → 면 → 초평면.
시그모이드 sigmoid	$1 / (1 + e^{-z})$. 어떤 실수든 0~1로 바꾼다. z = 0이면 0.5.
오즈 · 로그 오즈	$p/(1-p) = P(y=1)/P(y=0)$. 로그 오즈 = $\log(p/(1-p)) = \beta_0 + \beta_1 X$.
최대우도 추정	관찰된 결과가 나올 확률(우도)을 최대로 하는 계수를 고르는 방법.

확인 필요

아직 답이 필요한 질문

현재 남은 질문은 없습니다.

고친 것 (교안)

1. 교안 5쪽 다항 모델 식 $y = b_0 + b_1x + b_2x_1^2 \rightarrow b_2x^2$

첨자 1은 오타로 보입니다(추측). 수업에서 다르게 설명하셨으면 알려 주세요.

예상 문제 안내

교수님이 "푸는 문제는 안 나올 것 같다"고 하셔서, 계산보다는 **개념·흐름**을 묻는 문제 위주로 만들었습니다.

문제는 예상이며 실제 출제와 다를 수 있습니다. 정답 칸을 눌러야 답이 보입니다.

Q1 · 객관식

광고비 TV·Radio·Newspaper 3개로 판매량 1개를 예측하는 회귀는 무엇에 해당하는가?

1. Univariable
2. Multivariable
3. Multivariate
4. Univariate이면서 Multivariate

정답 ② — variable은 입력(x)의 개수, variate는 출력(y)의 개수를 센다. 입력이 3개, 출력이 1개이므로 multivariable(다변수). Multivariate는 y가 여러 개일 때다.

Q2 · 서술형

RSS를 계산할 때 잔차를 그냥 더하지 않고 제곱해서 더하는 이유를 쓰시오.

모범답안 잔차는 +와 −가 모두 나오므로 그대로 더하면 서로 상쇄되어, 오차가 큰데도 합이 0에 가까워져 오차가 없는 것처럼 계산될 수 있다. 제곱하면 모든 값이 양수가 되어 상쇄가 사라진다. (절댓값이나 루트를 쓰기도 하며, 공통점은 양수로 만든다는 것이다.)

Q3 · 계산

어떤 회귀 모델에서 SST = 50, SSE = 10이다. R^2를 구하고 의미를 쓰시오.

풀이 $R^2 = 1 - SSE/SST = 1 - 10/50 =$ **0.8**. y의 전체 변동 중 80%를 모델이 설명한다는 뜻이다. (SSR = SST − SSE = 40이므로 SSR/SST = 0.8로도 같다.)

Q4 · 서술형

다중 회귀에서 R^2 대신 Adjusted R^2를 쓰는 이유는?

모범답안 R^2는 변수를 추가하면 그 변수가 쓸모없어도 내려가지 않으므로, 변수가 많은 모델을 과대평가한다. Adjusted $R^2 = 1 - [SSE/(n-p-1)] / [SST/(n-1)]$은 변수 개수 p에 벌점을 주어, SSE가 충분히 줄지 않는 변수를 넣으면 값이 떨어진다.

Q5 · 서술형

로지스틱 회귀에서 p(x)와 1 – p(x)는 각각 무엇이며, log(p(x) / (1 – p(x)))는 무엇이라 부르는가? 이 값이 0이면 p(x)는 얼마인가?

모범답안 p(x)는 y가 1일 확률, 1 – p(x)는 y가 0일 확률이다. 둘의 비 p/(1–p)는 오즈, 여기에 로그를 취한 log(p/(1–p))는 **로그 오즈(로짓)**이며 $\beta_0 + \beta_1 X$와 같다. 로그 오즈 = 0이면 오즈 = 1, 즉 p = 1 – p이므로 **p(x) = 0.5**.

Q6 · 서술형

Default 데이터에서 $\hat{\beta}_0 = -10.6513$, $\hat{\beta}_1 = 0.0055$일 때 balance = 2000의 $\hat{p}(X) \approx 0.586$이다. 이 사람을 어떻게 분류하는가? 또 "balance가 커지면 채무불이행이 일어난다"는 해석이 왜 부정확한지 쓰시오.

모범답안 $\hat{p}(X) = 0.586 > 0.5$이므로 **Default(1)**로 분류한다. 회귀계수는 x와 y가 함께 변하는 **상관관계**를 나타낼 뿐, x가 y의 원인이라는 **인과관계**를 보여 주지 않는다. 따라서 "balance가 클수록 채무불이행 확률이 높은 경향이 있다"로 해석해야 한다.

교안에 자주 나오는 단어 ①

regression
/rɪ'greʃn/ n.

회귀 — 입력과 출력의 관계를 식으로 추정해 숫자를 예측하는 방법
We use linear **regression** to predict sales. 판매량을 예측하려고 선형 회귀를 쓴다.

coefficient
/ˌkoʊɪ'fɪʃnt/ n.

회귀계수, 계수 — 변수 앞에 곱해지는 수 (β_0, β_1)
The **coefficient** of TV is 0.05. TV의 회귀계수는 0.05이다.

intercept
/'ɪntərsept/ n.

절편 — x = 0일 때 y의 값 (β_0)
The line has an **intercept** of 7. 이 직선의 절편은 7이다.

slope
/sloʊp/ n.

기울기 — x가 1 늘 때 y가 변하는 양 (β_1)
A positive **slope** means y goes up with x. 기울기가 양수면 x가 커질 때 y도 커진다.

교안에 자주 나오는 단어 ②

residual
/rɪˈzɪdʒuəl/ n.

잔차 — 실제값에서 예측값을 뺀 나머지 ($y_i - \hat{y}_i$)
We square each **residual** and add them. 각 잔차를 제곱해서 더한다.

estimate
v. /ˈestɪmeɪt/ · n. /ˈestɪmət/

추정하다, 추정값 — 데이터로 모르는 값을 계산해 내다 (햇 ^ 표시)
We **estimate** β_0 and β_1 from the data. 데이터로 β_0와 β_1을 추정한다.

odds
/ɑːdz/ n. (복수형)

오즈 — 일어날 확률 ÷ 일어나지 않을 확률, $p / (1 - p)$
If p is 0.8, the **odds** are 4. p가 0.8이면 오즈는 4이다.

likelihood
/ˈlaɪklihʊd/ n.

우도, 가능성 — 현재 계수로 실제 관찰된 결과가 나올 확률
We choose β to maximize the **likelihood**. 우도를 최대로 만드는 β를 고른다.

필기 원문 ① — 수업 중 보내주신 그대로

01 14:07	이거 오늘 수업 내용이야. 6-1 수업이고 10월 8일 목요일(5-2는 휴강. 개천절 대체휴일 휴강)
02 15:18	인공지능 (포함기호) 기계학습(ML) (포함기호) 딥러닝(DL) (포함기호)생성형AI 회기에는 선형회귀와 로지스틱 회기가 있음 저 동그라미들을 가장 잘 설명할 수 있는 파란색 선을 찾고 싶은거임(실제로 우리가 알고 있는건 그저 동그라미(데이터)들 뿐 (참고로 비선형은 수업에서 다루지 않을거임) 매체끼리 시너지 어떻게 하는지는 다루지는 않음(그냥 이런 질문을 던질 수 있다 정도) 용어정리 x → system(model) → y 이런 형식임 변수 표기법 순서대로 각각 스칼라 백터 확률변수 행렬 이다.(무조건 지켜지지는 않지만 알고는 있어야 좋음) feature 특성 말고 특징으로 하자 그리고 보낸 사진 보고 다시 재구성해줘.(4섹션)
03 15:25	3 . 회귀란 회구의 분류 쪽 필기 이어갈게 coefficients는 회귀계수로 번역해줘 왼쪽 네비게이션 닫을 수 있는 버튼도 추가하자(분할화면 쓸 때 차지가 커서 불편) 단순 회귀는 x 다중 회귀는 x = [x_1, x_2, ..., x_N] 비선형회귀는 다루지 않음(훑어만 보고 넘어감) 수업에서는 linear만! 선 → 면 → 초평면(3차원 이상부터) 이렇게 되는거임

필기 원문 ② — 04 15:41

4번 섹션
우리는 variable 위주로 공부할 예정
단순 선형 회귀는 input 하나, 아웃풋 하나
$Y = \beta_0 + \beta_1 X + \varepsilon$
y = ax + b랑 매치해서 생각해도 됨. ε는 에러텀
베타제로 베타원은
parameter
(learnable)parameter
weight
이렇게 표기 법이 다양함
우리가 가지고 있는건 데이터 X
Y는 학습 결과
선형회귀를 만들겠다는건 결국에 베타제로랑 베타원을 찾겠다는거임
X랑 Y를 여러개 보면서 찾아보겠다는 것임
햇 심볼 : 예측하는 값
단순선형회귀에서 직접 식을 풀어서 구하는것 정도만 해볼거임
(경사하강법도 할거지만 이거는 뒤쪽에서)
우리는 x, y를 가지고 있음

RS는 왜 제곱을 하는가
혹은 절댓값으로 합하기도 함
혹은 루트
그러나 공통점은 양수로만 한다는 것
이유 : 오차가 +2일수도 있는데 -2가 있을 수도 있고. 근데 오차를 더했는데 오차가 없는것처럼 계산이 돼버리기 때무ㅐ ㄴ에 양수값으로 취급하는것임
목적함수 objective
손실함수 loss
비용함수 cost
이런식으로 표기법이 많음(내가 줄여고자 하는 함수를 어떻게 정의할지)
(Step2에 해당)
$C(\beta_0, \beta_1) = \min_{\beta_0, \beta_1} \sum_{i=1}^{n} \{ y_i - (\beta_0 + \beta_1 x_i) \}^2$ $(\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{\beta_0, \beta_1} C(\beta_0, \beta_1)$
→
$C(\beta_0, \beta_1) = \min_{\beta_0, \beta_1} \sum_{i=1}^{n} \{ y_i - (\beta_0 + \beta_1 x_i) \}^2$
$(\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{\beta_0, \beta_1} C(\beta_0, \beta_1)$
x바, y바는 평균을 의미함
푸는 문제는 안나올거같음(그냥 이런시긍로 푼다 까지는 이해가 필요)

필기 원문 ③

05 15:56 예시 그래프에서 회색선은 에러텀을 의미
(어디까지 최적 최선을 찾는거임. 완벽하게 해도 새로운 데이터가 들어온다면 그게 100% 맞지 않을 수도 있음)
섹션별로 교안 상 몇페이지인지 써주면 내가 수업 가기 따라가기에 되게 좋을거같아. 참고로 이번 수업은 27페이지까지 있고 회귀계수 해석은 19페이지에 해당돼

06 16:07 회기계수 해석에서 상관관계로 해야함(인과관계라고 단정지으면 안된다고 함)
우리가 x----g(x)---→y 를 배우고 있는데 y가 나오니까 인과간계라고 생각하지만 사실은 x,y 상관관계로 생각해야함
11다항회귀
Non-linear 할 수도 있구나 정도. degree 2, degree 5 이렇게 되면 구불구불해질 수 있다 정도 알고있기(이 이상은 심화과정이라 안다룸)
그래서 이 페이지에서는 그냥 잠깐 다뤄본 정도.
편하게 들으라고 하심

07 16:14 로그 오즈에서
p(x)는 y가 1일 확률
1 - p(x)는 y가 0일 확률
수업 끝. 이해하기 쉽게 정리해줘. 진짜 내가 잘 못하는 분야라서 선생님이 말해주듯이 정리가 필요해

끝

다음 차시 · 6주차 2차시

서포트 벡터 머신 SVM

오늘의 "모델 → 오차 재기 → 계수 찾기" 흐름이 그대로 반복됩니다 M 키로 목차