07·2

인공지능 · 7주차 2차시

질문을 몇 번 던져서 정답을 맞히기 — 결정 트리

2026.10.19 (월) 강은송 교수님 교안 Decision Tree 1–35쪽 전체

이 자료는 결정 트리 교안 한 권을 끝까지 담았습니다

"특징 ≤ 기준값? 질문을 몇 번 해서 정답을 맞히려면, 어떤 질문을 먼저 해야 할까?"

Part 1 · 01–09

분류 트리와 불순도

트리 읽기, 결정 경계, 지니·엔트로피, 규제, CART 지니 예제

Part 2 · 10

ID3 엔트로피 예제

정보 이득으로 특징 고르기 — 14명 데이터로 끝까지

Part 3 · 11–17

회귀 트리와 한계

리프 = 평균, MSE, 계단 예측, 선형 vs 트리, 한계

7주차 2차시 수업은 군집화 DBSCAN(26–35쪽)과 결정 트리 1–15쪽이었습니다. 시험 준비용으로 챕터별로 나눠 DBSCAN은 7주차 1차시 자료로 옮겼고, 이 자료는 결정 트리만 담았습니다. 결정 트리 16–35쪽은 8주차 1차시 수업 내용이지만, 차시마다 한 챕터로 공부할 수 있게 이 자료에 이어서 넣었습니다(8주차 1차시 자료는 앙상블 학습만). **모두 시험 범위**입니다.

왜 배우고, 어디에 힘을 줄까

다시 **지도 학습**(x와 정답 y가 있음)입니다. 결정 트리는 규칙을 사람이 그대로 읽을 수 있어서(해석하기 쉬움) 배웁니다. 대신 정확도는 최고 수준보다 떨어져, 나중에 트리를 여러 개 합치는 방법(배깅·랜덤 포레스트·부스팅)으로 이어집니다.

구분 (추측)	교안 쪽	섹션	무엇을 할 수 있으면 되나
꼭 이해	1–10	01–08	트리 노드를 읽을 수 있다. 지니·엔트로피가 0이면 무슨 뜻인지. 규제 방향(max ↓, min ↑)
계산 연습	11–15	09	식에 숫자를 넣어 지니와 지니 감소량(ΔG)을 계산하고 가장 큰 분할을 고른다
계산 연습	16–28	10	엔트로피와 정보 이득을 계산해 가장 큰 특징을 고른다. CART와 같은 점·다른 점
꼭 이해	29–35	11–17	회귀 트리: 리프 예측 = 평균, MSE 최소 분할, 계단 모양 예측. 선형 vs 트리, 한계 두 가지

이 차시는 진도만 받았고 심화·시험 범위에 대한 교수님 말씀은 받지 못해, 구분은 제 추측입니다. 6주차에 "식은 형태를 안내해 준다"고 하셨으니 식은 **각 부분의 뜻**을 보는 대상으로 읽으면 됩니다.

미리 짚고 갈 1학기 개념

자료구조 — 트리	루트(맨 위), 자식, 리프(자식 없는 노드), 깊이(루트에서 몇 칸 내려왔나)를 그대로 씁니다. 결정 트리는 대부분 **이진 트리**(자식이 둘)이고, ID3만 범주 수만큼 갈라질 수 있습니다.
로그 $\log_2$	$\log_2 1 = 0$, $\log_2(1/2) = -1$. 엔트로피 계산은 이 두 값만 알아도 감을 잡을 수 있습니다.
비율과 가중평균	"노드 안에서 클래스 k가 차지하는 비율 p_k", "샘플 수 비율로 가중평균"이 계속 나옵니다. 5명 중 4명 = 0.8, (2/7)·0 + (5/7)·0.32처럼 계산합니다.

Part 1 · 교안 1–15쪽 · 7주차 2차시 수업

분류 트리와 불순도

01–04 트리란·용어·경계 | **05–07** 지니·엔트로피 | **08** 규제 | **09** CART 예제

트리 기반 방법 Tree-based Methods

입력 변수들이 이루는 공간(**예측 변수 공간** predictor space)을 여러 개의 단순한 영역으로 쪼개는 방법입니다.

공간을 쪼개는 데 쓴 **분할 규칙**(예: "꽃잎 길이 ≤ 2.45cm?")들을 **나무 모양**으로 정리할 수 있어서 **결정 트리** decision tree라고 부릅니다.

결정 트리는 분류와 회귀를 모두 할 수 있고, 출력이 여러 개인 과제(multi-output)도 할 수 있습니다.

정확히 말하면

"스무고개"라고 흔히 설명하지만 정확히는: 각 단계에서 **특징 하나와 기준값 하나**로 데이터를 둘(또는 여러 개)로 나누고, 나뉜 각 부분에서 같은 일을 반복합니다. 마지막에 남은 각 영역마다 **하나의 예측값**(분류면 클래스, 회귀면 숫자)을 정합니다.

트리 기반 방법의 장단점

장점

단순하고 해석하기 쉽다

규칙을 그대로 읽을 수 있음. simple and useful for interpretation.

단점

예측 정확도는 최고 수준이 아니다

not competitive with the best supervised learning approaches.

그래서 **배깅** bagging, **랜덤 포레스트** random forests, **부스팅** boosting을 다룹니다. 트리를 여러 개 키워 하나의 합의된 예측으로 합칩니다. 정확도는 크게 좋아지지만 해석하기 쉬운 장점은 일부 잃습니다(트리 수백 개의 다수결은 한 번에 읽을 수 없음).

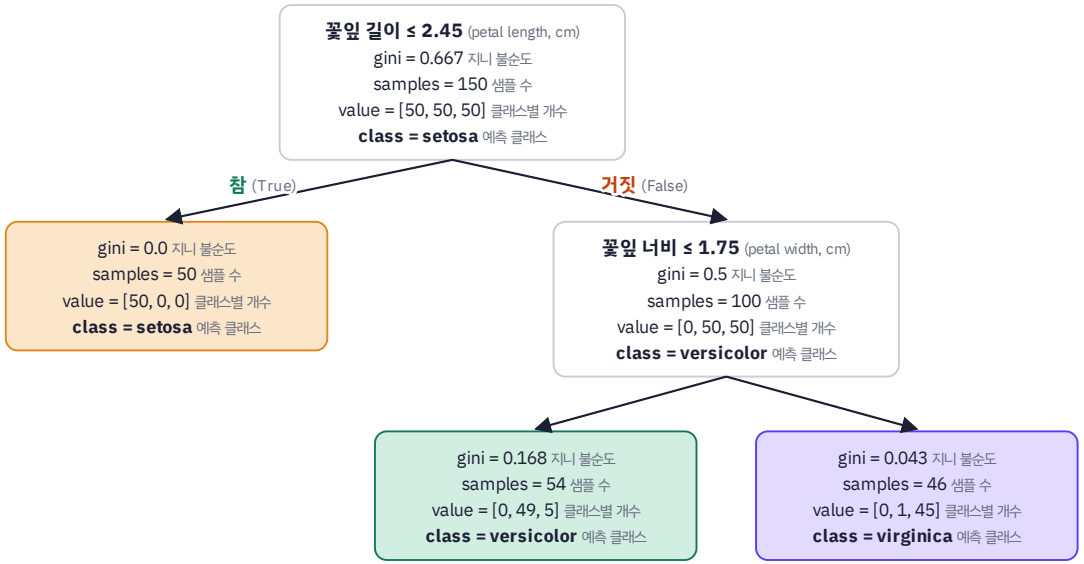
이번 교안에는 세 방법의 내용이 없어 뒤 수업에서 다룰 것으로 보입니다(추측).

결정 트리 용어 — Iris 트리

루트 노드 Root	맨 위 노드, 깊이 0
자식 노드 Child	부모 바로 아래에 연결된 노드
리프 노드 Leaf	자식이 없는 끝 노드. 여기서 최종 예측

왼쪽 화살표 = 조건 참(True), 오른쪽 = 거짓(False). 색 = 다수 클래스, 진할수록 한 클래스만 있음(순수).

질문 두 번으로 150송이를 분류합니다: 꽃잎 길이 ≤ 2.45 → setosa / 아니면 꽃잎 너비 ≤ 1.75 → versicolor, 아니면 virginica.



붓꽃(Iris) 결정 트리 — 리프 색 = 예측 클래스

노드 한 칸 읽는 법

줄	뜻 (루트 노드 기준)
`petal length ≤ 2.45`	이 노드의 **분할 규칙**. 참이면 왼쪽, 거짓이면 오른쪽 (리프에는 없음)
`gini = 0.667`	이 노드의 불순도 — 클래스가 얼마나 섞였나 (05)
`samples = 150`	이 노드에 도달한 학습 샘플 수
`value = [50, 50, 50]`	클래스별 샘플 수 [setosa, versicolor, virginica]
`class = setosa`	여기서 멈춘다면 낼 예측(가장 많은 클래스, 동점이면 앞의 것)

예측해 보기 (보충)

꽃잎 길이 5cm, 너비 1.5cm: 5 ≤ 2.45 거짓 → 오른쪽. 1.5 ≤ 1.75 참 → 왼쪽 리프 → **versicolor**. 이 리프 54개 중 49개가 versicolor라 맞을 확률을 49/54 ≈ 91%로 추정할 수도 있습니다.

특징 스케일링이 필요 없다

"특징 하나 ≤ 기준값"만 묻기 때문입니다. cm → mm로 바꾸면 기준값도 2.45 → 24.5로 바뀔 뿐 나뉘는 방식은 같습니다. 거리로 판단하는 SVM·K-평균과 반대입니다.

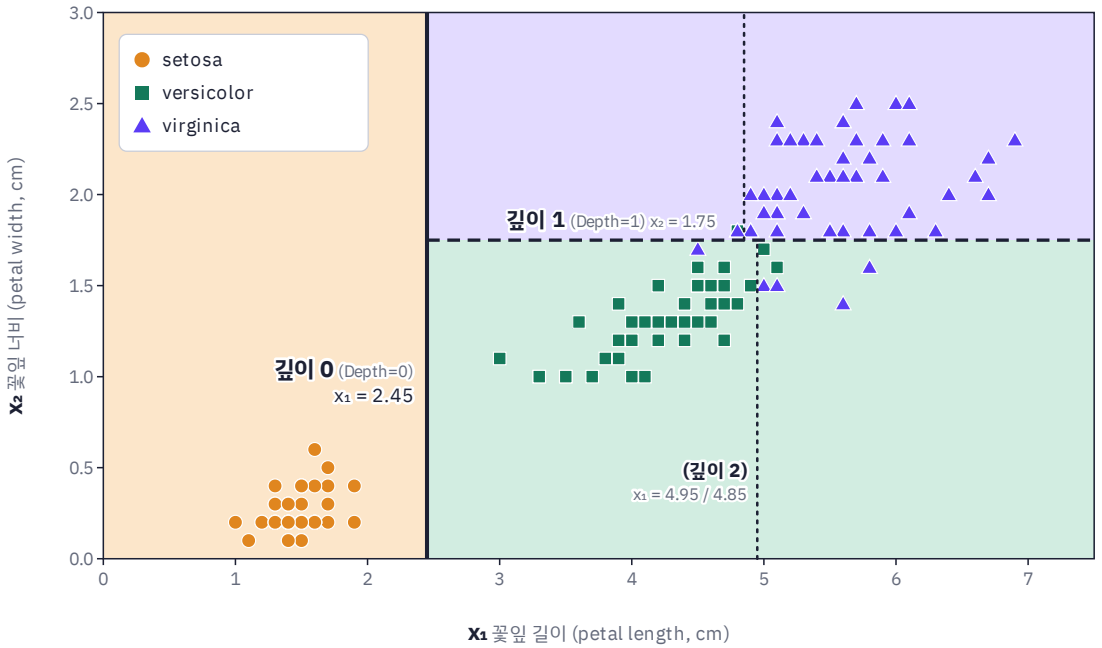
결정 트리의 결정 경계 Decision Boundary

앞의 트리를 평면에 그린 것입니다. x_1 = 꽃잎 길이, x_2 = 꽃잎 너비.

- **굵은 실선** $x_1 = 2.45$ — 루트(Depth=0) 분할, 왼쪽 setosa를 떼어 냄
- **파선** $x_2 = 1.75$ — 깊이 1 분할
- **점선** — 트리를 더 깊게 키우면 생기는 분할 (Depth=2)

리프 하나 = 직사각형 영역 하나, 경계는 항상 축에 평행한 직선입니다. 한 번에 특징 하나만 보고 나누기 때문입니다.

파선 근처에서 파랑과 초록이 섞여 있어 리프의 gini가 0이 아니었던 것(0.168, 0.043)입니다.



좋은 분할 = 나눈 뒤 깨끗해지는 분할

각 노드에서 "어떤 특징을, 어느 기준값으로 나눌까"를 정해야 합니다. 좋은 분할은 나눈 뒤 각 자식이 **한 클래스 위주로 깨끗해지는** 분할입니다. 이 깨끗하지 않은 정도가 불순도 impurity입니다.

척도	쓰는 곳
지니 다양성 지수 Gini	분류 — scikit-learn 기본값
엔트로피 entropy	분류 — criterion을 entropy로 바꾸면
분산 (MSE)	회귀 (12)

$$G_i = 1 - \sum_k p_{i,k}^2 , \quad p_{i,k} = \frac{N_{k,i}}{N_i}$$

읽는 법: 클래스 비율을 제곱해 더한 값을 1에서 뺍니다. 한 클래스만 있으면 $1 - 1^2 = 0$ (완전히 순수). 고르게 섞일수록 커집니다.

범위: 0(100% 순수) ~ **1 − 1/클래스 수**(매우 불순). 2클래스 0.5, 3클래스 0.667.

Iris 노드의 지니를 직접 계산하기

노드	value	계산	G
루트	[50, 50, 50]	$1 - 3 \times (1/3)^2$	**0.667** (3클래스 최대)
setosa 리프	[50, 0, 0]	$1 - 1^2$	**0**
versicolor 리프	[0, 49, 5]	$1 - (49/54)^2 - (5/54)^2 = 1 - 0.8234 - 0.0086$	**0.168**
virginica 리프	[0, 1, 45]	$1 - (1/46)^2 - (45/46)^2$	**0.043**

그림에 적힌 값과 같습니다. versicolor가 대부분이라 0에 가깝고, 루트는 세 클래스가 똑같이 섞여 최대입니다.

엔트로피 Entropy — 불확실성

$$H_i = -\sum_{k,\, p_{i,k}\neq 0} p_{i,k} \log(p_{i,k})$$

- 한 클래스만 있으면 확실성 ↑ → 엔트로피 = 0
- 클래스가 고르게 섞이면 불확실성 ↑ → 엔트로피 ↑
- 비율이 0인 클래스는 합에서 뺌(log 0은 정의 안 됨)

앞의 마이너스: p는 0~1이라 log p ≤ 0. −를 붙여 엔트로피를 0 이상으로 만듭니다.

계산 예 (보충, $\log_2$)

반반 [5, 5]: $-(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = \mathbf{1}$

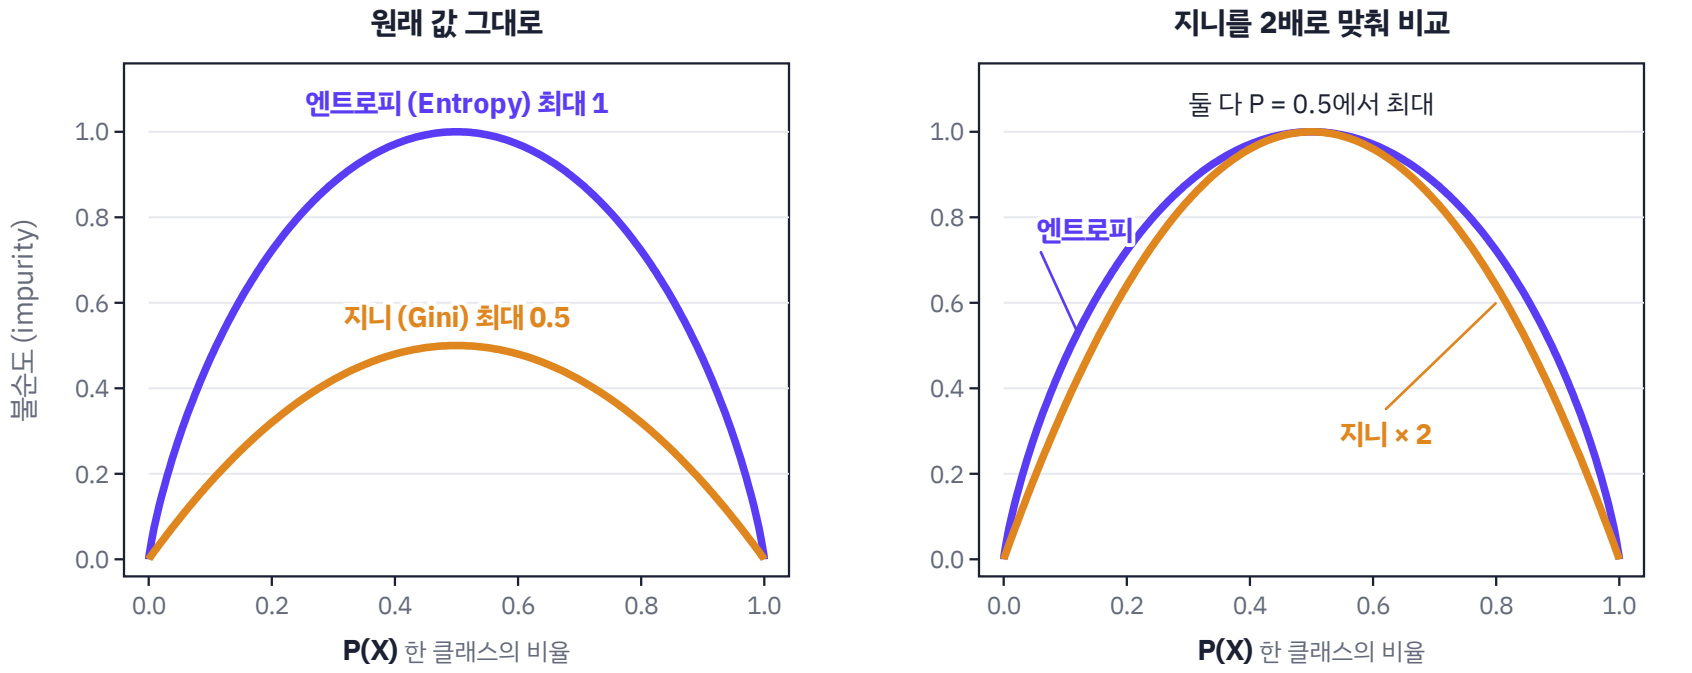
순수 [10, 0]: **0**

Iris 루트 [50, 50, 50]: $\log_2 3 \approx \mathbf{1.585}$

14명 중 구매 9·비구매 5: $\approx \mathbf{0.940}$ (10에서 다시)

교안 7쪽은 log의 밑을 적지 않았지만 뒤 예제는 $\log_2$를 씁니다.

지니 vs 엔트로피



출처: Quantdare

이진 분류에서 한 클래스 비율 P(X)에 따른 불순도. 둘 다 순수(0 또는 1)에서 0, **반반(0.5)에서 최대**(Gini 0.5, Entropy 1). 오른쪽처럼 Gini를 2배로 맞추면 거의 겹칩니다.

지니	엔트로피
계산이 조금 더 빠름 → 기본값으로 무난	소수 클래스에 더 민감하게 반응

사전 가지치기 Pre-pruning — 규제 하이퍼파라미터

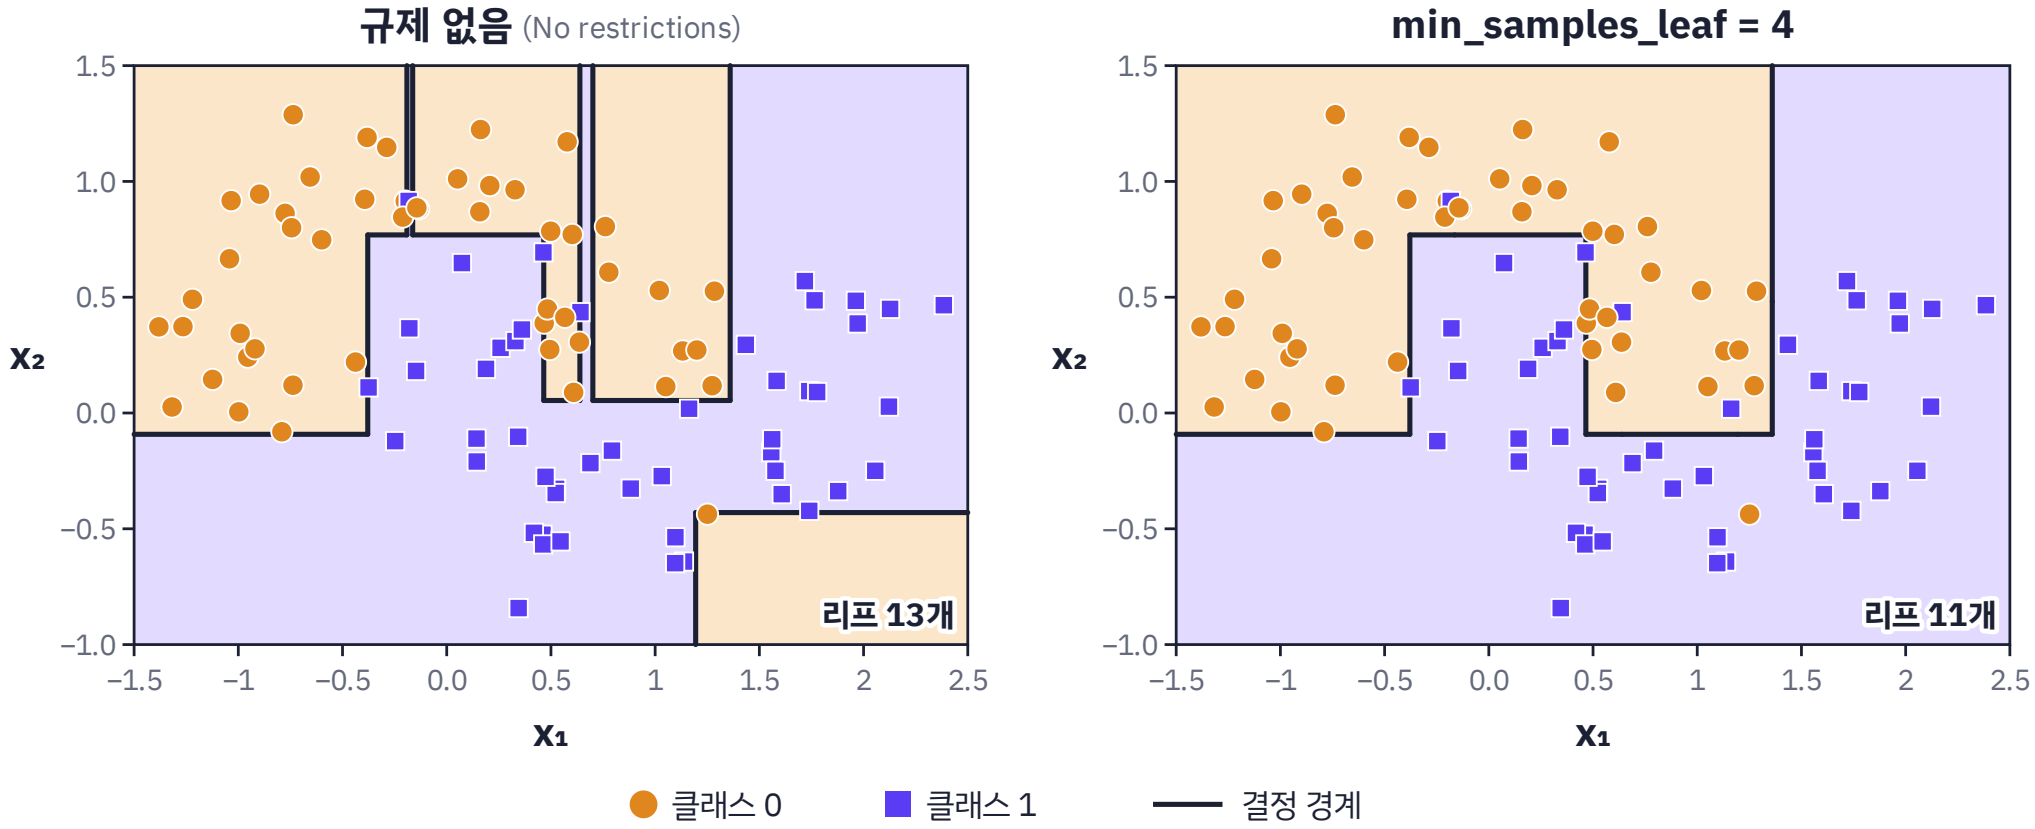
결정 트리는 학습 데이터에 대한 **가정이 거의 없습니다**(선형 모델은 "직선 관계"를 가정). 그래서 제약 없이 두면 트리가 학습 데이터에 맞춰 계속 자라 과대적합할 가능성이 큽니다. 학습 중에 트리의 자유를 제한하는 것이 **규제**이고, 다 자라기 전에 막는다는 뜻에서 **사전 가지치기**입니다.

6주차 SVM의 C처럼 이 값들도 교차 검증으로 고르는 하이퍼파라미터입니다.

하이퍼파라미터	제한하는 것
`max_depth`	트리의 최대 깊이. **줄이면** 규제 ↑
`min_samples_split`	노드를 나누기 위한 최소 샘플 수
`min_samples_leaf`	리프가 가져야 하는 최소 샘플 수

max_ 는 줄이고, min_ 은 늘리면 규제 ↑

min_samples_leaf로 규제하면



왼쪽(규제 없음): 점 하나하나를 맞추려고 좁은 띠·작은 상자가 생겨 경계가 복잡합니다 = 과대적합. **오른쪽**: 리프마다 최소 4개를 요구하면 경계가 단순해집니다. 몇 점은 반대 영역에 남지만 새 데이터에는 더 잘 맞을 가능성이 큽니다.

09

CART — 지니 감소량이 가장 큰 분할

CART Classification and Regression Trees는 분류에서 지니를 쓰고, 불순도 감소량이 가장 큰 이진(두 갈래) 분할을 고릅니다.

예제: 고객 7명, 특징 4개, 구매 여부 라벨 하나.

1. 나누기 전 G(D)
2. 후보 분할마다 자식 지니를 샘플 수 비율로 가중평균
3. ΔG = G(D) − 가중평균, 가장 큰 분할 선택
4. 자식마다 반복, G = 0이면 멈춤(리프)

ID	나이 (x_{i1})	소득 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 (y_i)
1	청소년 (Adolescent)	높음 (High)	아니오 (No)	양호 (Good)	비구매 (No Purchase)
2	청소년	높음	아니오	우수 (Excellent)	비구매
3	청년 (Young Adult)	높음	아니오	양호	구매 (Purchase)
4	중년 (Middle-aged)	중간 (Medium)	아니오	양호	구매
5	중년	낮음 (Low)	예 (Yes)	양호	구매
6	중년	낮음	예	우수	비구매
7	청년	낮음	예	우수	구매

1·2단계 — 부모 지니와 불순도 감소량

1단계: 부모 D = 구매 4, 비구매 3

$$G(D) = 1 - \left(\frac{4}{7}\right)^2 - \left(\frac{3}{7}\right)^2 = \frac{24}{49} \approx 0.490$$

2단계: 불순도 감소량

$$\Delta G(D, s) = G(D) - \left(\frac{|D_L|}{|D|} G(D_L) + \frac{|D_R|}{|D|} G(D_R) \right)$$

s = 후보 이진 분할, $D_L \cdot D_R$ = 나눈 뒤 왼쪽·오른쪽. 괄호 안은 자식 지니의 샘플 수 가중평균. 감소량이 가장 큰 분할을 고릅니다.

3단계 — Age의 후보 분할 비교

후보	왼쪽 D_L	오른쪽 D_R	가중 지니	ΔG
s_1: Adolescent vs 나머지	2명 (0, 2) → G = 0	5명 (4, 1) → 1 − 0.64 − 0.04 = 0.320	(2/7)·0 + (5/7)·0.320 ≈ 0.229	**0.26**
s_2: Adolescent·Young Adult vs Middle-aged	4명 (2, 2) → 1/2	3명 (2, 1) → 4/9	(4/7)(1/2) + (3/7)(4/9) ≈ 0.476	0.014

s_1은 왼쪽 자식이 **완전히 순수**(비구매만)해져서 감소량이 큽니다. s_2는 나눈 뒤에도 양쪽이 거의 반반이라 감소량이 거의 없습니다.

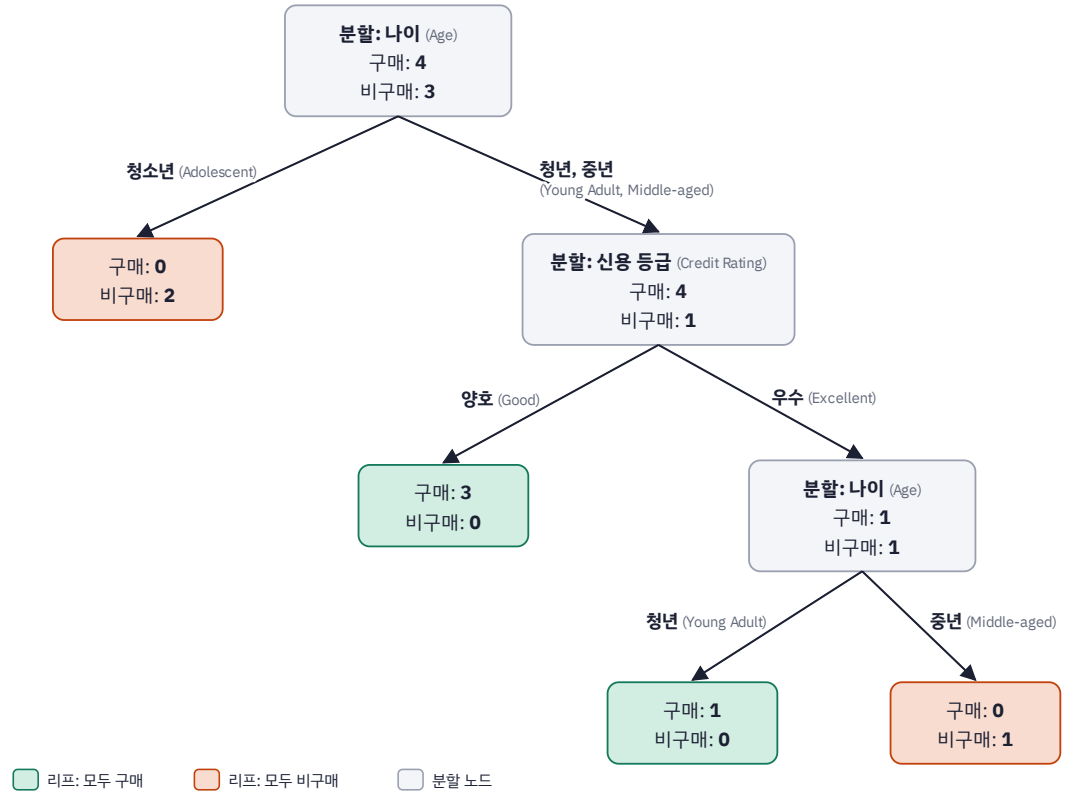
4단계: Income, Student Status, Credit Rating도 같은 방법으로. 보충(Python 계산) — 루트 후보 ΔG: Age{Adolescent} 0.261 > Age{Young Adult} 0.147 > Income{High}·Credit 0.085 > Income{Medium} 0.061 > 나머지 0.014 → 루트는 Age. 오른쪽 자식(G = 0.32)에서는 Credit Rating(0.120)이 최대.

CART가 만든 최종 트리 (교안 15쪽)

1. 루트: **Age = Adolescent?** → 왼쪽 2명은 모두 비구매(리프)
2. 오른쪽 5명(구매 4·비구매 1)은 **Credit Rating**으로 → Good 3명은 모두 구매(리프)
3. Excellent 2명(ID 6, 7)은 Income·Student가 같아 **Age**로만 나뉨 → Young Adult 구매, Middle-aged 비구매

모든 리프가 한 클래스만 남은 순수 노드(gini 0)입니다.

여기까지가 7주차 2차시 수업 범위입니다(교안 15쪽).



Part 1 정리 — 7주차 2차시 수업 범위

- 결정 트리 = "특징 ≤ 기준값?" 분할 규칙으로 공간을 단순한 영역들로 쪼갬. 분류·회귀 모두. 해석 쉬움, 정확도는 최고 수준 아님.
- 노드 = 분할 규칙 + gini + samples + value + class. 리프 = 직사각형 영역, 경계는 축에 평행. 스케일링 불필요.
- 지니 $G = 1 - \sum p_k^2$, 엔트로피 $H = -\sum p_k \log p_k$: 0 = 한 클래스뿐, 고르게 섞일수록 큼(2클래스 최대 0.5 / 1).
- 규제(사전 가지치기): max_depth ↓, min_samples_split·min_samples_leaf ↑.
- CART: ΔG = 부모 지니 − 자식 지니 가중평균, 가장 큰 이진 분할 선택. 예: 0.490 → Age = Adolescent?(ΔG ≈ 0.26).

Part 2 · 교안 16–28쪽

엔트로피 예제 — ID3와 정보 이득

10 엔트로피 · 정보 이득 계산 | **10** 14명 데이터로 트리를 끝까지 | **10** CART vs ID3

ID3 Iterative Dichotomiser 3

엔트로피로 정보 이득 information gain을 계산하고, 정보 이득이 가장 큰 속성(특징)을 고릅니다. CART와 달리 이진 분할이 아니라 **특징의 범주 수만큼** 가지를 나눕니다.

예제는 고객 14명입니다. 앞의 7명에 7명을 더했고, Age 이름이 Adolescent → **Youth**, Credit 값이 Good → **Fair**로 바뀌었습니다.

계산 순서는 CART와 같고 잣대만 지니 → 엔트로피, 감소량 이름만 ΔG → 정보 이득입니다.

ID	나이 (x_{i1})	소득 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 (y_i)
1	청소년 (Youth)	높음 (High)	아니오 (No)	보통 (Fair)	아니오
2	청소년	높음	아니오	우수 (Excellent)	아니오
3	청년 (Young adult)	높음	아니오	보통	예 (Yes)
4	중년 (Middle-aged)	중간 (Medium)	아니오	보통	예
5	중년	낮음 (Low)	예	보통	예
6	중년	낮음	예	우수	아니오
7	청년	낮음	예	우수	예
8	청소년	중간	아니오	보통	아니오
9	청소년	낮음	예	보통	예
10	중년	중간	예	보통	예
11	청소년	중간	예	우수	예
12	청년	중간	아니오	우수	예
13	청년	높음	예	보통	예
14	중년	중간	아니오	우수	아니오

1·2단계 — 부모 엔트로피와 정보 이득

1단계: 구매 9명, 비구매 5명

$$H(D) = -\frac{9}{14}\log_2\frac{9}{14} - \frac{5}{14}\log_2\frac{5}{14} \approx 0.940$$

2단계: 정보 이득

$$\text{Gain}(D, A) = H(D) - \sum_{v \in V_A} \frac{|D_v|}{|D|} H(D_v)$$

A = 후보 특징, V_A = 그 특징의 범주들, D_v = A = v인 샘플들. 뒤쪽은 **나눈 뒤 엔트로피의 가중평균**. 정보 이득 = "그 특징으로 나누면 불확실성이 얼마나 줄어드나". CART의 ΔG와 같은 구조입니다.

3단계 ① — Age의 정보 이득을 끝까지 계산 (교안 18쪽)

(가) 범주마다 엔트로피 — Age로 나누면 세 그룹이 생깁니다.

$$H(\text{Youth}) = -\frac{2}{5}\log_2\frac{2}{5} - \frac{3}{5}\log_2\frac{3}{5} \approx 0.971$$

$$H(\text{Young adult}) = -\frac{4}{4}\log_2\frac{4}{4} = 0$$

$$H(\text{Middle-aged}) = -\frac{3}{5}\log_2\frac{3}{5} - \frac{2}{5}\log_2\frac{2}{5} \approx 0.971$$

Youth(구매 2 : 비구매 3)와 Middle-aged(3 : 2)는 비율이 뒤집혔을 뿐이라 엔트로피가 같습니다. 엔트로피는 어느 클래스가 많은지가 아니라 **비율이 얼마나 고른지**만 봅니다.

(나) 그룹 크기 비율로 가중평균 — 나눈 뒤의 엔트로피

$$\frac{5}{14}(0.971) + \frac{4}{14}(0) + \frac{5}{14}(0.971) \approx 0.694$$

(다) 정보 이득 = 나누기 전 − 나눈 뒤

$$\text{Gain}(D, \text{Age}) = 0.940 - 0.694 \approx \mathbf{0.247}$$

가중평균을 쓰는 이유: 그룹마다 샘플 수가 다르므로, 샘플이 많은 그룹의 엔트로피를 더 크게 반영해야 나눈 뒤 전체의 불순도가 됩니다.

3단계 ② — 나머지 세 특징도 같은 순서로 (교안 19–21쪽)

특징	(가) 범주별 엔트로피	(나) 가중평균	(다) 이득
Income	High (2, 2) → 1 · Medium (4, 2) → 0.918 · Low (3, 1) → 0.811	$\frac{4}{14}(1) + \frac{6}{14}(0.918) + \frac{4}{14}(0.811) \approx 0.911$	0.029
Student	Yes (6, 1) → 0.592 · No (3, 4) → 0.985	$\frac{7}{14}(0.592) + \frac{7}{14}(0.985) \approx 0.789$	0.151
Credit	Fair (6, 2) → 0.811 · Excellent (3, 3) → 1	$\frac{8}{14}(0.811) + \frac{6}{14}(1) \approx 0.892$	0.048

괄호는 (구매, 비구매) 수입니다. 두 클래스가 **같은 수**면 엔트로피 = 1(최대), **한쪽만** 있으면 0입니다.

Student의 정확한 값은 0.9403 − 0.7885 = 0.1518이라 0.152로도 나옵니다. 교안은 반올림한 값끼리 빼서 0.151로 적었습니다.

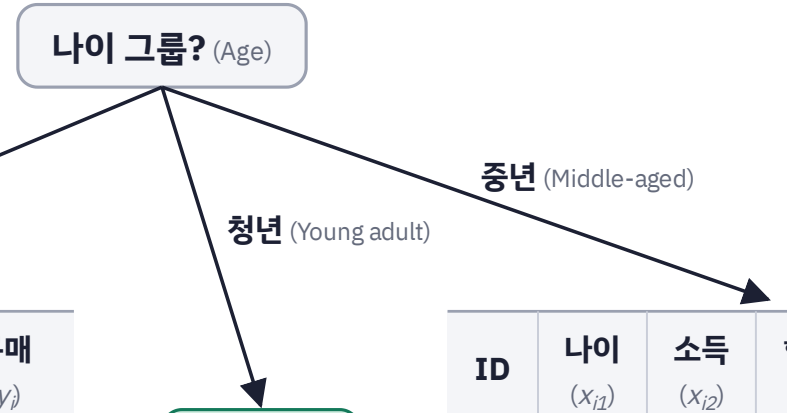
3단계 ③ — 네 특징 비교, 가장 큰 것을 고른다

특징	범주별 (구매, 비구매)	나눈 뒤 가중 엔트로피	정보 이득
Age	Youth 5 (2, 3) · Young adult 4 (4, 0) · Middle-aged 5 (3, 2)	(5/14)(0.971) + (4/14)(0) + (5/14)(0.971) = 0.694	**0.247** (최대)
Income	High 4 (2, 2) · Medium 6 (4, 2) · Low 4 (3, 1)	0.911	0.029
Student	Yes 7 (6, 1) · No 7 (3, 4)	0.789	0.151
Credit	Fair 8 (6, 2) · Excellent 6 (3, 3)	0.892	0.048

Age의 정보 이득이 가장 크므로 ID3는 Age를 첫 분할 속성으로 고릅니다. Young adult 4명은 모두 구매라 바로 리프입니다.

교안 18쪽은 0.246, 22쪽은 0.247 — 반올림한 값끼리 빼면 0.246, 반올림 전(0.9403 − 0.6935)이면 0.247. 순위는 같습니다.

ID3 1단계 — Age로 세 갈래 (교안 23쪽)



ID	나이 (x_{i1})	소득 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 (y_i)
1	청소년	높음 (High)	아니오 (No)	보통 (Fair)	아니오
2	청소년	높음	아니오	우수 (Excellent)	아니오
8	청소년	중간 (Medium)	아니오	보통	아니오
9	청소년	낮음 (Low)	예 (Yes)	보통	예
11	청소년	중간	예	우수	예

구매 = 예

4명 모두 구매
→ 바로 리프

ID	나이 (x_{i1})	소득 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 (y_i)
4	중년	중간	아니오	보통	예
5	중년	낮음	예	보통	예
6	중년	낮음	예	우수	아니오
10	중년	중간	예	보통	예
14	중년	중간	아니오	우수	아니오

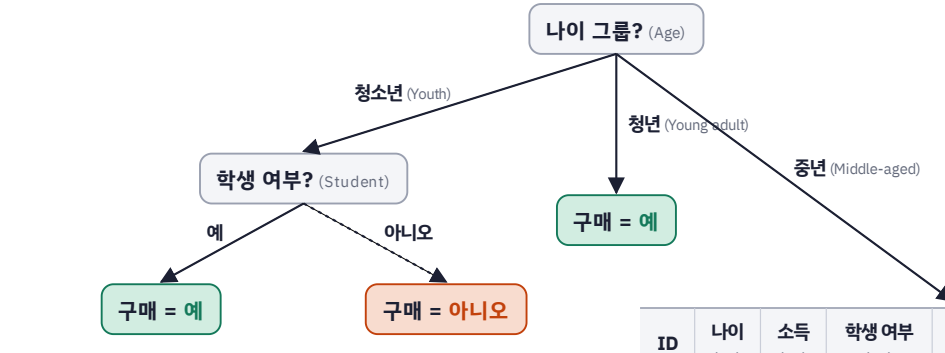
Young adult(3·7·12·13번)는 모두 Yes라 바로 리프 **"Buys = Yes"**. Youth(초록)와 Middle-aged(보라)는 Yes(파랑)·No(빨강)가 섞여 있어 각자 다시 정보 이득을 계산해 나눕니다.

4단계 — Youth 그룹은 Student로 (교안 25쪽)

Youth 5명: 구매 2, 비구매 3, H = 0.971

특징	범주별	이득 (보충)
Income	Low 1 (1,0) · Medium 2 (1,1) · High 2 (0,2)	0.571
Student	Yes 2 (2,0) · No 3 (0,3) → 양쪽 순수	**0.971**
Credit	Excellent 2 (1,1) · Fair 3 (1,2)	0.020

Student = Yes인 9·11번은 모두 Yes, No인 1·2·8번은 모두 No → 두 리프 모두 순수.



청소년 그룹 — 학생 여부로 깨끗이 나뉨

ID	나이 (x_{i1})	소득 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 (y_i)
1	청소년	높음 (High)	아니오 (No)	보통 (Fair)	아니오
2	청소년	높음	아니오	우수 (Excellent)	아니오
8	청소년	중간 (Medium)	아니오	보통	아니오
9	청소년	낮음 (Low)	예 (Yes)	보통	예
11	청소년	중간	예	우수	예

ID	나이 (x_{i1})	소득 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 (y_i)
4	중년	중간	아니오	보통	예
5	중년	낮음	예	보통	예
6	중년	낮음	예	우수	아니오
10	중년	중간	예	보통	예
14	중년	중간	아니오	우수	아니오

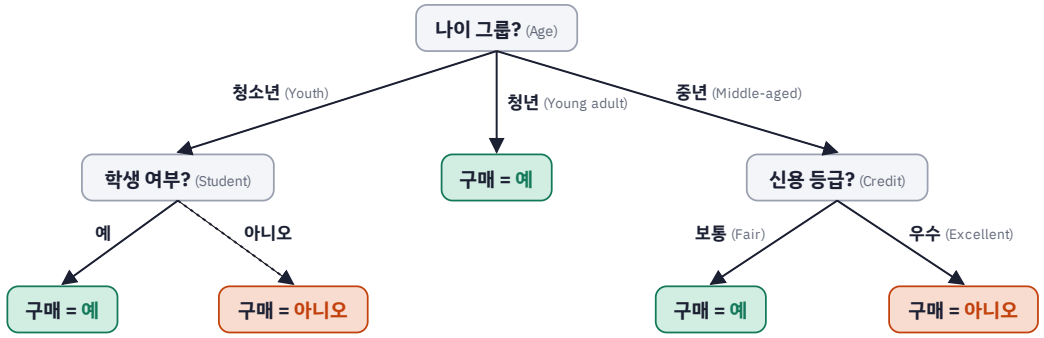
중년 그룹 — 다음 단계에서 분할

5단계 — Middle-aged 그룹은 Credit으로 (교안 28쪽)

Middle-aged 5명: 구매 3, 비구매 2, H = 0.971

특징	범주별	이득
Income	Low 2 (1,1) · Medium 3 (2,1)	0.02
Student	No 2 (1,1) · Yes 3 (2,1)	0.02
Credit	Excellent 2 (0,2) · Fair 3 (3,0)	**0.971**

Fair인 4·5·10번은 모두 Yes, Excellent인 6·14번은 모두 No. 모든 리프가 순수하고, 이 트리로 14명 모두 맞힙니다(Python으로 확인).



모든 리프가 순수(한 클래스만)
→ 14명 모두 맞게 분류

중년 그룹 — 신용 등급으로 깨끗이 나뉨

ID	나이 (x_{i1})	소득 (x_{i2})	학생 여부 (x_{i3})	신용 등급 (x_{i4})	구매 (y_i)
4	중년	중간 (Medium)	아니오 (No)	보통	예 (Yes)
5	중년	낮음 (Low)	예	보통	예
6	중년	낮음	예	우수	아니오
10	중년	중간	예	보통	예
14	중년	중간	아니오	우수	아니오

CART와 ID3 — 같은 점과 다른 점

	CART (교안 11–15쪽)	ID3 (교안 16–28쪽)
불순도 잣대	지니 G	엔트로피 H
고르는 기준	지니 감소량 ΔG가 가장 큰 분할	정보 이득 Gain이 가장 큰 특징
가지 수	항상 2개 (이진 분할, "≤ 기준값?")	특징의 범주 수만큼 (Age → 3갈래)
같은 점	① 나누기 전 불순도를 구하고 ② 후보마다 나눈 뒤 불순도를 **샘플 수 가중평균**으로 구해 ③ **얼마나 줄었나**를 비교해 가장 많이 줄인 것을 고르고 ④ 순수하지 않은 자식에서 반복	

방향 주의

지니·엔트로피(불순도)는 **작을수록** 좋고, ΔG·정보 이득(줄어든 양)은 **클수록** 좋습니다.

Part 3 · 교안 29–35쪽

회귀 트리와 결정 트리의 한계

11–14 회귀 트리 | **15** 야구 연봉 예제 | **16** 선형 vs 트리 | **17** 한계

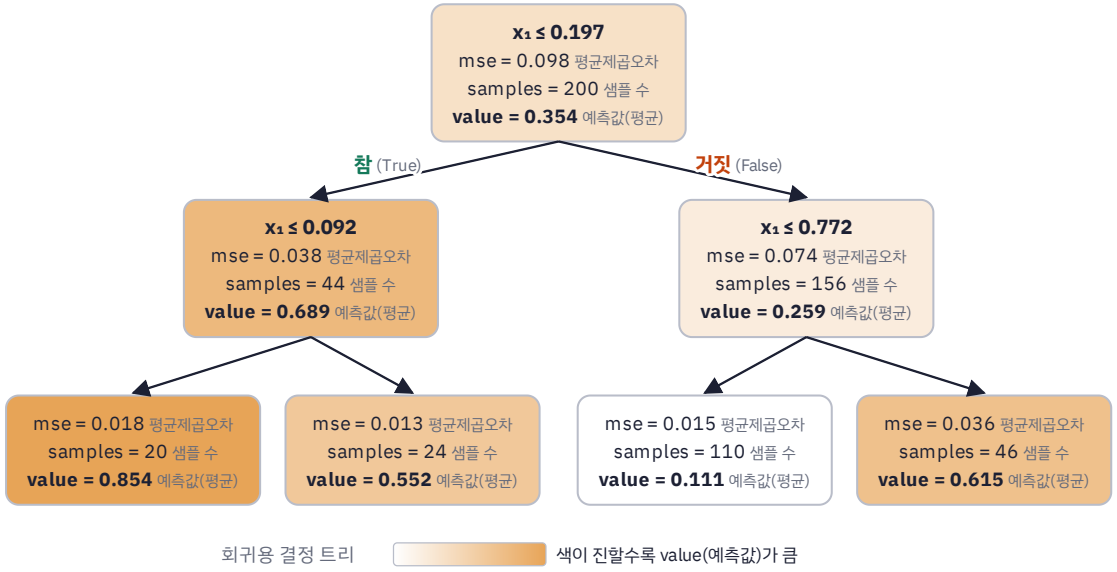
회귀 트리 Decision Tree Regression

구조는 분류 트리와 같고, 리프가 클래스 대신 숫자 값을 예측합니다.

value	노드 학습 샘플 y값의 평균 = 그 노드의 예측값
mse	노드 안 y값이 평균에서 얼마나 흩어졌나 (분류의 gini 자리)

예: $x_1 = 0.6 \rightarrow 0.197$ 초과 $\rightarrow 0.772$ 이하 → 예측값 **0.111**.

부모 value = 자식 value의 샘플 수 가중평균: $(44 \times 0.689 + 156 \times 0.259)/200 \approx 0.354$.



회귀용 CART — MSE를 최소로 나누기

분류에서는 불순도를 최소로 나눴는데, 회귀에서는 MSE(평균제곱오차)를 최소로 하도록 나눕니다.

$$J(k, t_k) = \frac{m_{left}}{m} MSE_{left} + \frac{m_{right}}{m} MSE_{right}$$

$$MSE_{node} = \frac{1}{m_{node}} \sum (\hat{y}_{node} - y^{(i)})^2 , \quad \hat{y}_{node} = \frac{1}{m_{node}} \sum y^{(i)}$$

- **k, t_k**: 나눌 특징과 기준값 ("$x_k \le t_k$?")
- **m_{left}, m_{right}, m**: 왼쪽·오른쪽·부모 샘플 수
- **J**: 두 자식 MSE의 가중평균 → 모든 후보 중 J가 가장 작은 것

분류용 CART의 "가중 지니" 자리에 MSE가 들어간 형태입니다.

교안 30쪽 식 주의

MSE_{node}에 $1/m_{node}$가 빠져 있어 실제로는 제곱오차의 **합**입니다. 위처럼 $1/m_{node}$가 있어야 앞 그림의 기준값 0.197이 나옵니다(슬라이드 식대로면 0.255, Python 확인).

회귀용 CART를 손으로 한 번 (보충)

점 4개 (x, y) = (1, 1), (2, 2), (3, 6), (4, 7). 기준값 후보는 이웃한 x의 가운데 1.5, 2.5, 3.5입니다.

t	왼쪽 (평균, MSE)	오른쪽 (평균, MSE)	J
1.5	{1} → (1, 0)	{2, 6, 7} → (5, 4.667)	3.5
2.5	{1, 2} → (1.5, 0.25)	{6, 7} → (6.5, 0.25)	**0.25**
3.5	{1, 2, 6} → (3, 4.667)	{7} → (7, 0)	3.5

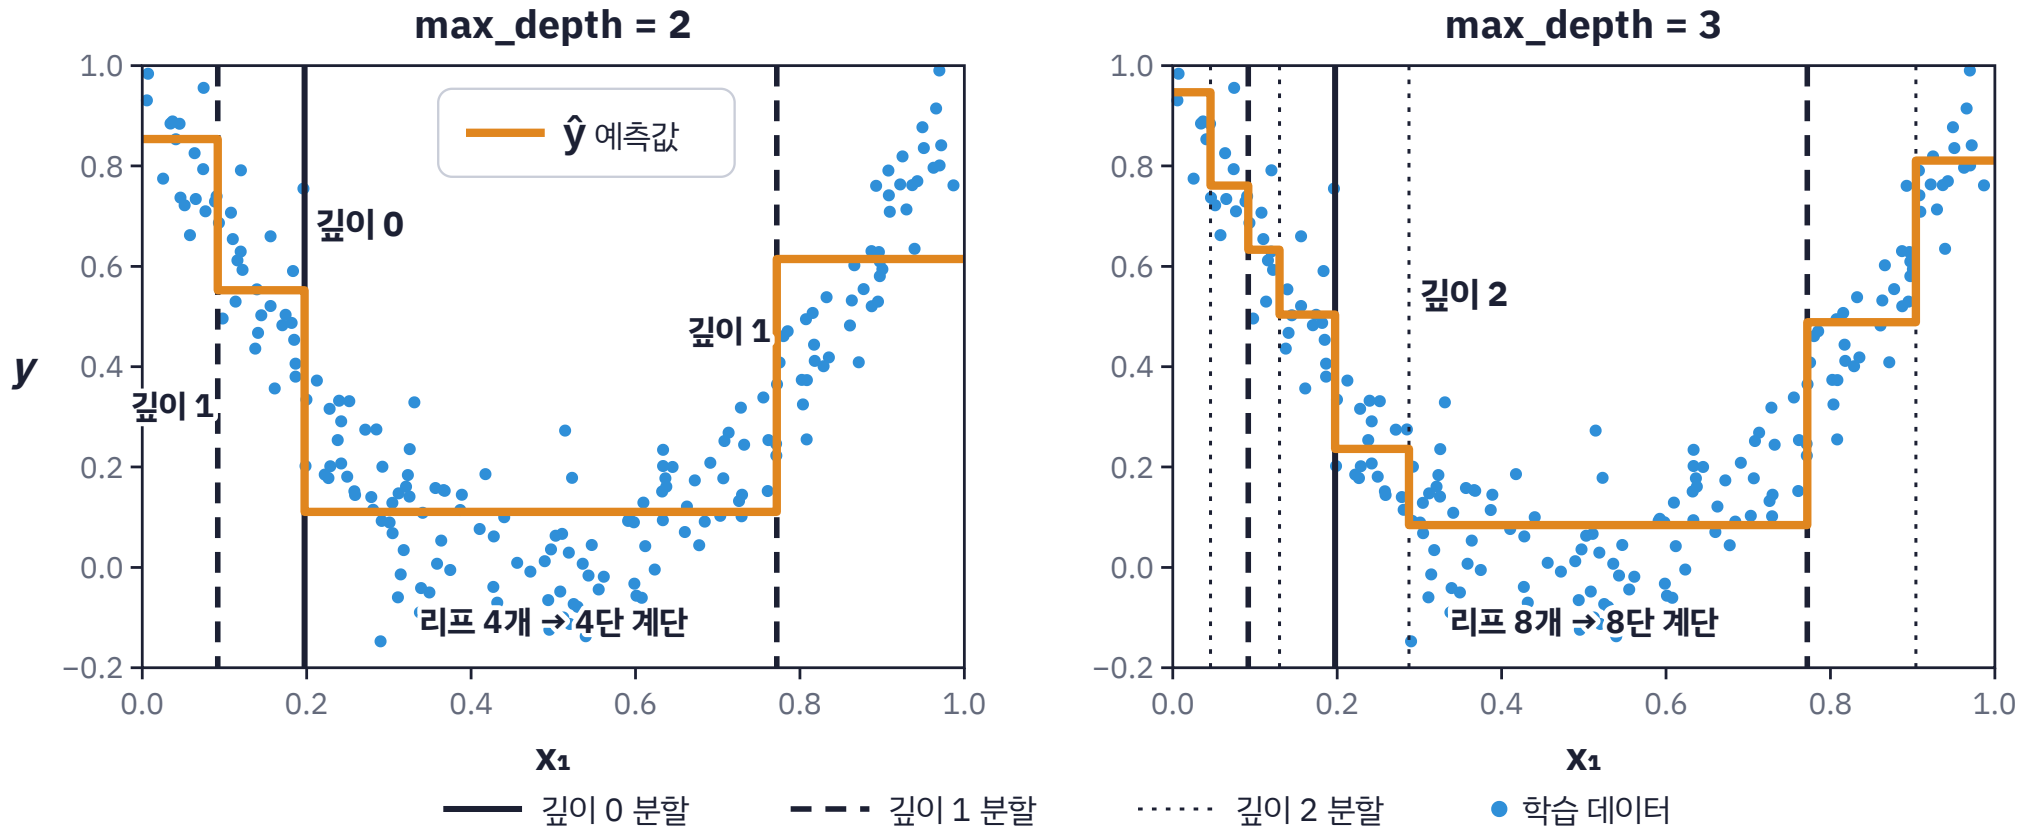
예: t = 1.5이면 $J = \frac{1}{4} \cdot 0 + \frac{3}{4} \cdot 4.667 = 3.5$

J가 가장 작은 **x ≤ 2.5**로 나눕니다. 리프 예측값은 왼쪽 **1.5**, 오른쪽 **6.5**(각 구간 y의 평균)입니다.

계산 순서

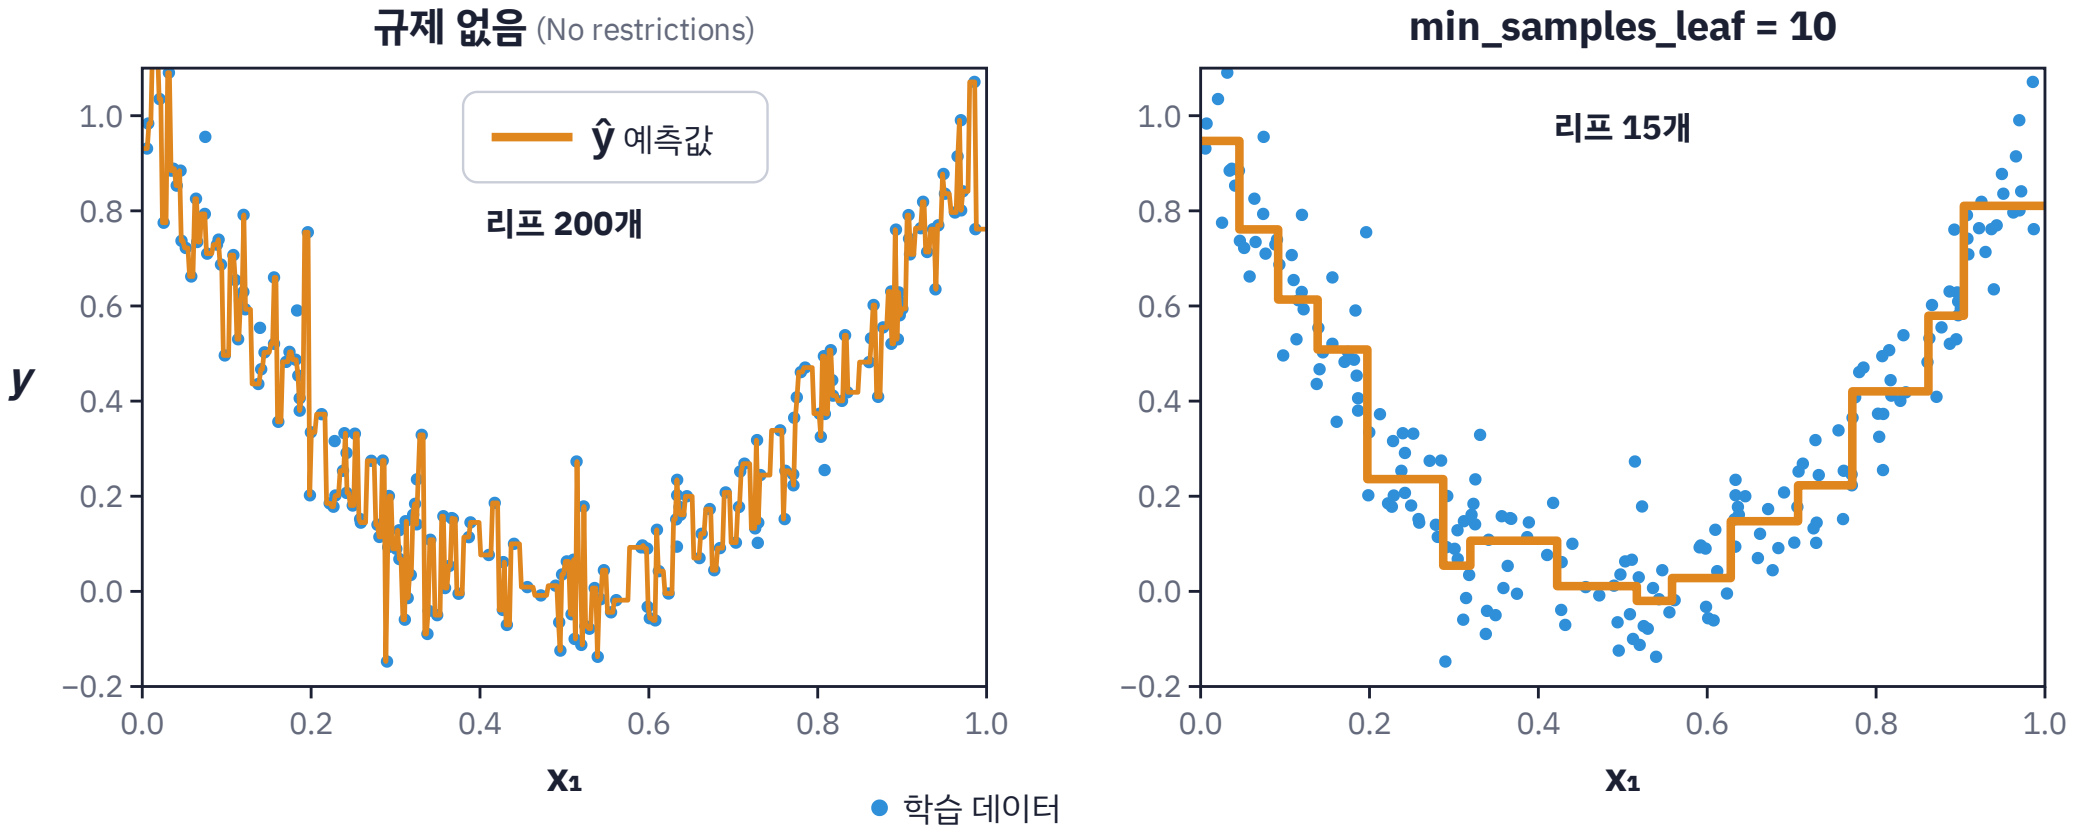
1. 후보 기준값마다 왼쪽·오른쪽으로 나눈다
2. 각 쪽의 평균 $\hat{y}$과 MSE = $(\hat{y} - y)^2$ 의 평균
3. J = 샘플 수 비율로 가중평균
4. J가 가장 작은 기준값 선택

회귀 트리의 예측은 계단 모양



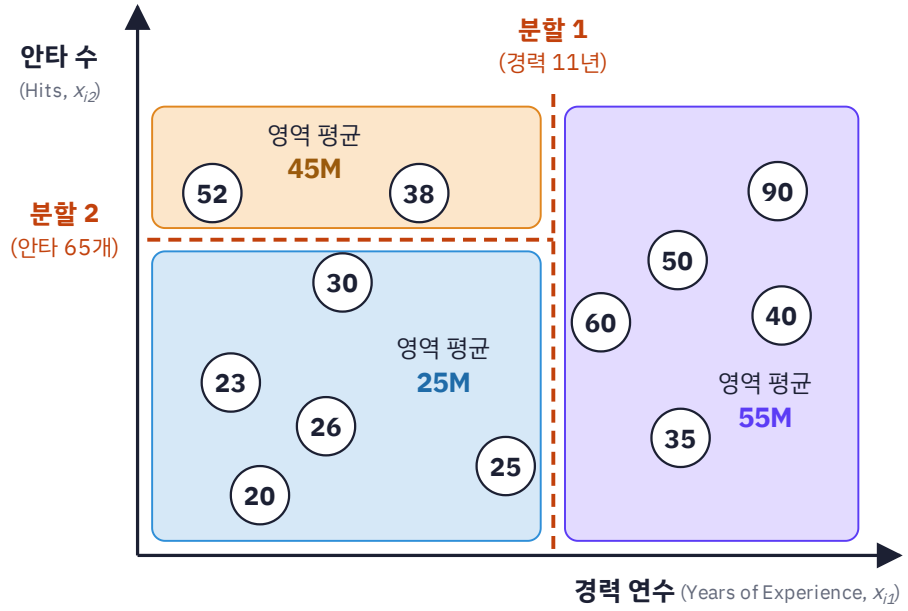
파란 점 = 학습 데이터(U자), 빨간 계단 = 예측값 ŷ. 리프 하나가 x_1의 구간 하나를 맡고, 그 구간에서는 항상 같은 값(그 구간 y의 평균)을 냅니다. 깊이 2면 리프 4개 → 4단, **깊이가 1 늘면 구간이 2배**(8단)가 되어 곡선을 더 촘촘히 따라갑니다.

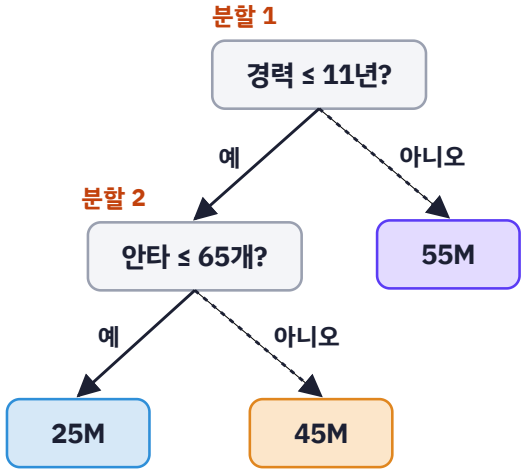
회귀 트리도 규제하지 않으면 과대적합



왼쪽: 끝까지 자라면 리프가 샘플마다 하나가 되어 예측선이 모든 점을 지나며 들쭉날쭉합니다 = 과대적합. **오른쪽**: 리프마다 최소 10개를 요구하면 계단 몇 개로 U자를 매끄럽게 따라갑니다(08과 같은 규제).

회귀 트리 예제 — 야구 선수 연봉





원 안 숫자 = 선수 연봉 (M = 백만)

원 안 숫자 = 연봉(M, 백만). 경력 **11년**으로 먼저 나누고(Split 1), 11년 이하만 안타 **65개**로 다시 나눕니다(Split 2). 각 영역의 예측값 = 그 영역 연봉의 평균: (52 + 38)/2 = 45, (30 + 23 + 26 + 20 + 25)/5 ≈ 25, (90 + 50 + 60 + 40 + 35)/5 = 55.

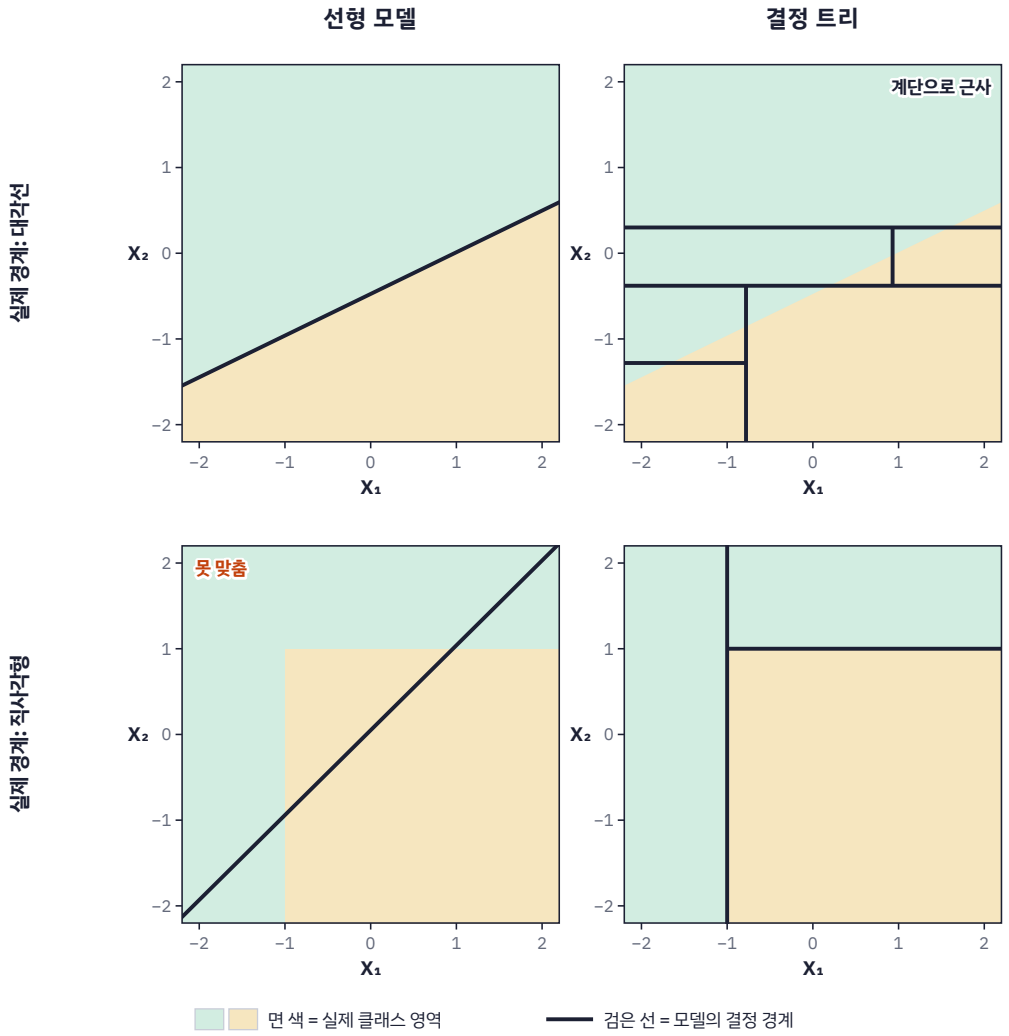
예: 경력 5년·안타 40개 신인 → 25M. 교안 그림은 오른쪽 트리의 25M·45M 칸 색이 왼쪽 영역 색과 서로 바뀌어 있습니다(숫자에는 영향 없음).

선형 모델 vs 트리 모델

배경 색 = 실제 클래스 영역, 검은 선 = 모델의 경계. 왼쪽 열 = 선형 모델, 오른쪽 열 = 트리.

참 경계	선형 모델	트리
대각선 (위 줄)	잘 맞음 — 직선 하나	축 평행 선분의 계단으로 근사
축 평행 직사각형 (아래 줄)	대각선 하나로밖에 못 나눔	잘 맞음 — 두 번 분할

어느 모델이 낫다고 정해져 있지 않고, 데이터의 실제 구조가 어떤 모양이냐에 달려 있습니다.



결정 트리의 한계 Limitations

이해·해석이 쉽고, 쓰기 편하고, 분류·회귀 모두 되는 강력한 방법이지만 한계가 있습니다.

한계	설명
① **직교 경계만 → 회전에 민감**	모든 분할이 축에 수직이라, 데이터를 회전시키기만 해도 결과가 크게 달라진다
② **작은 변화에 민감**	학습 데이터가 조금만 바뀌어도 트리 구조가 크게 바뀔 수 있다

①의 예(보충): $x_1 = 0$ 세로선으로 나뉘는 데이터는 분할 한 번이면 되지만, 45° 돌리면 경계가 대각선이 되어 계단을 여러 개 만들어야 합니다(16 위쪽 그림). ②는 루트에서 고른 특징이 바뀌면 그 아래 전체가 바뀌기 때문입니다. 트리를 여러 개 합치는 랜덤 포레스트 등이 이 불안정성을 줄이며, 바로 다음 8주차 1차시 앙상블 학습에서 다룹니다.

결정 트리 전체 정리 — 말로 설명할 수 있게

- "특징 ≤ 기준값?" 질문을 반복, 나눈 뒤 불순도가 가장 많이 줄어드는 질문을 먼저 고름. 리프 = 영역, 경계는 축에 평행.
- 지니 $G = 1 - \sum p_k^2$ / 엔트로피 $H = -\sum p_k \log p_k$: 0 = 한 클래스뿐. 지니는 빠르고 기본값, 엔트로피는 소수 클래스에 민감.
- **CART**: 지니, 이진 분할, ΔG 최대 / **ID3**: 엔트로피, 범주 수만큼 분할, 정보 이득 최대(Age 0.247 → Youth는 Student, Middle-aged는 Credit).
- 과대적합 규제: max_depth ↓, min_samples_split·min_samples_leaf ↑.
- 회귀 트리: 리프 예측 = 구간 y의 **평균**, MSE 최소 분할, 예측은 계단 모양.
- 선형 vs 트리는 데이터 구조에 달림. 한계: 회전에 민감, 작은 변화에 민감.

용어 정리 ① — 분류 트리

결정 트리	"특징 ≤ 기준값?" 분할 규칙으로 예측 변수 공간을 단순한 영역들로 쪼개는 지도 학습 모델.
루트 · 자식 · 리프	맨 위(깊이 0) / 부모 바로 아래 / 자식 없는 끝 노드(예측을 냄).
불순도 impurity	노드에 클래스가 섞인 정도. 0이면 한 클래스뿐(순수).
지니 다양성 지수	$G = 1 - \sum p_k^2$. 0(순수) ~ 1 − 1/클래스 수.
엔트로피	$H = -\sum p_k \log p_k$. 순수하면 0, 고르게 섞이면 최대(2클래스·$\log_2$면 1).
CART	지니 감소량 ΔG가 가장 큰 이진 분할을 고르는 알고리즘.
지니 감소량 ΔG	부모 지니 − 자식 지니의 샘플 수 가중평균.
사전 가지치기 · 규제	트리가 다 자라기 전에 자유를 제한해 과대적합을 막음. max ↓, min ↑.

용어 정리 ② — ID3와 회귀 트리

ID3	엔트로피로 정보 이득을 계산, 이득이 가장 큰 특징으로 범주 수만큼 분할.
정보 이득 information gain	H(D) − 나눈 뒤 엔트로피의 가중평균. 불확실성이 얼마나 줄었나.
회귀 트리	리프가 숫자를 예측. 예측값 = 리프 샘플 y의 평균.
MSE (노드)	노드 y값이 평균에서 흩어진 정도. 회귀 CART는 자식 MSE 가중평균 J를 최소로.
직교 경계 orthogonal	축에 수직인 경계. 트리의 모든 분할이 이 모양 → 회전에 민감.

확인 필요 · 교안 주의

질문

결정 트리 16–35쪽(10–17)은 8주차 1차시 수업 내용입니다. 수업 필기를 받으면 교수님 말씀을 반영하겠습니다.

이 차시의 시험 범위·심화 여부에 대한 교수님 말씀은 아직 받지 못했습니다.

고친 것 · 주의 (교안)

- 5쪽 "Variance (or MSE) for regression **entropy**" — 끝의 entropy는 불필요한 단어로 보임
- 18쪽 Age 정보 이득 0.246 vs 22쪽 0.247 — 반올림 순서 차이, 정확한 값 0.2467
- 23·25쪽 "adolescent group" = 표·그림의 Youth 그룹
- 26–27쪽 아래첨자 "middel-aged" → middle-aged
- 30쪽 MSE_{node} 식에 $1/m_{node}$가 빠짐 → 그대로면 제곱오차의 합(12)
- 33쪽 왼쪽 영역 색과 오른쪽 리프 박스 색(25M·45M)이 서로 바뀌어 있음(15)

예상 문제 안내

Q1–Q4는 7주차 2차시 수업 범위(1–15쪽), Q5–Q6은 8주차 1차시에 배울 범위(16–35쪽, 수업 후 보완)입니다. 식은 시험에서 형태를 안내해 준다는 앞 주차 말씀에 맞춰, 식을 주고 숫자를 넣는 형태로 냈습니다.

문제는 예상이며 실제 출제와 다를 수 있습니다. 정답 칸을 눌러야 답이 보입니다.

Q1 · 서술형

Iris 트리(루트: petal length ≤ 2.45, 오른쪽 자식: petal width ≤ 1.75)에서 꽃잎 길이 5cm, 너비 1.5cm인 꽃은 어느 클래스로 예측되는가? 지나가는 노드를 순서대로 쓰시오. 또 결정 트리에 특징 스케일링이 필요 없는 이유를 쓰시오.

모범답안 루트에서 5 ≤ 2.45 거짓 → 오른쪽 자식, 1.5 ≤ 1.75 참 → 왼쪽 리프 → **versicolor**. 결정 트리는 한 번에 특징 하나를 기준값과 비교만 하므로 단위를 바꾸면 기준값만 같이 바뀔 뿐 나뉘는 방식이 같다. 그래서 거리 기반 모델(SVM, K-평균)과 달리 스케일링이 필요 없다.

Q2 · 계산

지니 지수 $G = 1 - \sum p_k^2$를 이용해 value = [0, 1, 45]인 노드(46개)의 지니를 소수 셋째 자리까지 구하시오. 또 클래스가 3개일 때 지니의 최댓값은?

풀이 $G = 1 - (1/46)^2 - (45/46)^2 = 1 - 0.00047 - 0.95699 \approx$ **0.043**. 최댓값은 세 클래스가 1/3씩일 때 $1 - 3 \times (1/3)^2 = 1 - 1/3 \approx$ **0.667**.

Q3 · 계산

부모 노드에 구매 4명·비구매 3명이 있다. 분할 s로 왼쪽 2명(비구매 2), 오른쪽 5명(구매 4·비구매 1)이 되었다. $\Delta G(D, s) = G(D) - (|D_L|/|D| \cdot G(D_L) + |D_R|/|D| \cdot G(D_R))$를 구하시오.

풀이 $G(D) = 1 - (4/7)^2 - (3/7)^2 = 24/49 \approx 0.490$. $G(D_L) = 0$, $G(D_R) = 1 - (4/5)^2 - (1/5)^2 = 0.32$. 가중평균 $= (2/7)(0) + (5/7)(0.32) \approx 0.229$. $\Delta G \approx 0.490 - 0.229 = \mathbf{0.261}$.

Q4 · 객관식

결정 트리가 학습 데이터에 과대적합되었다. 다음 중 규제를 강하게 하는 조정이 아닌 것은?

1. max_depth를 줄인다.
2. min_samples_leaf를 늘린다.
3. min_samples_split을 늘린다.
4. max_depth를 늘린다.

정답 ④ — max_로 시작하는 값은 줄이고, min_으로 시작하는 값은 늘려야 규제가 강해진다. max_depth를 늘리면 트리가 더 깊어져 과대적합이 심해진다.

Q5 · 계산

14명(구매 9, 비구매 5)의 엔트로피 H(D) ≈ 0.940이다. Age로 나누면 Youth 5명(2, 3), Young adult 4명(4, 0), Middle-aged 5명(3, 2)이고, 각 엔트로피는 0.971, 0, 0.971이다. Gain(D, Age)를 구하고, Young adult 가지가 바로 리프가 되는 이유를 쓰시오.

풀이 가중 엔트로피 = (5/14)(0.971) + (4/14)(0) + (5/14)(0.971) ≈ 0.694. Gain = 0.940 − 0.694 ≈ **0.247**(반올림 순서에 따라 0.246). Young adult는 4명 모두 구매라 엔트로피가 0(순수)이므로 더 나눌 필요가 없다.

Q6 · 서술형

회귀 트리의 리프 예측값은 어떻게 정해지는가? 야구 연봉 예제에서 경력 ≤ 11년·안타 ≤ 65 영역의 연봉이 30, 23, 26, 20, 25(M)일 때 예측값을 구하고, 회귀 트리 예측 그래프가 계단 모양인 이유를 쓰시오.

모범답안 리프 예측값은 그 리프(영역)에 속한 학습 샘플 y값의 평균이다. (30 + 23 + 26 + 20 + 25)/5 = 24.8 ≈ **25M**. 리프 하나가 입력의 한 구간을 맡고 그 구간에서는 항상 같은 값(평균)을 내므로 예측이 구간마다 일정한 계단 모양이 된다.

교안에 자주 나오는 단어

segment v. / n.	**나누다, 부분** — Trees **segment** the predictor space into simple regions. 트리는 예측 변수 공간을 단순한 영역들로 나눈다.
split n. / v.	**분할, 나누다** — CART selects the binary **split** with the largest reduction. CART는 감소량이 가장 큰 이진 분할을 고른다.
impurity n.	**불순도** — The Gini index measures a node's **impurity**. 지니 지수는 노드의 불순도를 잰다.
entropy n.	**엔트로피** — **Entropy** is zero when the node contains only one class. 노드에 한 클래스만 있으면 엔트로피는 0이다.
terminal adj.	**끝의** — A leaf is a **terminal** node with no children. 리프는 자식이 없는 끝 노드이다.
constrain v.	**제한하다** — If left un**constrained**, the tree will overfit. 제한하지 않으면 트리는 과대적합된다.
gain n.	**이득** — ID3 selects the attribute with the highest information **gain**. ID3는 정보 이득이 가장 큰 속성을 고른다.
orthogonal adj.	**직교하는** — Decision trees love **orthogonal** decision boundaries. 결정 트리는 직교하는 결정 경계를 만든다.

필기 원문 — 보내주신 그대로

7-2 · 01 14:13	7-2 수업 (결정 트리 교안 마크다운 첨부)
7-2 · 02 15:07	이거야 피디에프 (결정 트리 교안 PDF 첨부)
7-2 · 04 15:26	결정트리 교안에 있는 이미지 순서대로 캡쳐했어
7-2 · 05 16:04	너무 어려워. 왜 배우는지 뭘 알아야하는지 뭘 이해해야하는지 모르겠어. 강사가 얘기해주듯이 이해할 수 있게 만들어줘. 너~무 어려워
7-2 · 06 16:10	T15페이지 까지(앤트로피 예제부터 다음 시간 수업) 수업 끝
10.22 02:11	7-2 의사결정트리(DBSCAN부터 7-2에서 한건 맞지만 7-1에서 마무리하자. 7-2는 의사결정트리내용. 수업내용은 그랬지만 지금은 챕터별 시험준비자료 만드는거니까 그래)

7-2 · 03 "군집화 26페이지부터 있는 이미지 다 가져왔어"는 7주차 1차시(군집화) 자료의 필기 원문으로 옮겼습니다.

끝

다음 · 8주차 1차시

결정 트리 이어서 (16쪽~)

엔트로피 예제 · 회귀 트리 · 한계 — 수업 후 이 자료에 보완 M 키로 목차