1. 선형회귀(Linear Regression)에 대한 설명으로 가장 적절한 것은?

① 입력 데이터의 특성을 기반으로 데이터를 여러 그룹으로 분류하는 방법이다.

② **입력 변수와 종속 변수 사이의 관계를 선형 함수로 모델링하여 연속적인 값을 예측하는 방법이다.**

③ 입력 데이터의 유사성을 기반으로 정답 레이블 없이 군집을 형성하는 방법이다.

④ 여러 개의 결정 트리를 결합하여 예측 성능을 향상시키는 방법이다.

2. 머신러닝 모델이 훈련 데이터에 지나치게 맞춰져 훈련 데이터에서는 좋은 성능을 보이지만, 새로운 데이터에서는 예측 성능이 저하되는 현상을 무엇이라고 하는가?

답 : **과적합 (Overfitting)**

---

3. 로지스틱(Logistic) 회귀에서 사용하는 시그모이드(Sigmoid) 함수에 대한 설명으로 가장 적절한 것은?

① 입력값을 0 또는 1로만 변환하여 출력한다.

② **입력값을 0과 1 사이의 값으로 변환하여 클래스에 속할 확률을 표현할 수 있도록 한다.**

③ 입력값과 출력값 사이의 관계를 직선으로 표현하여 연속적인 값을 예측한다.

④ 입력 데이터의 유사도를 계산하여 여러 군집으로 구분한다.

4. 회귀 모델의 성능 지표인 결정계수(Coefficient of Determination, R^2)에 대한 설명으로 옳은 것을 모두 고르시오.

① **R^2는 모델이 데이터(종속 변수)의 변동을 얼마나 설명하는지 나타내는 지표이다.**

② **R^2 = 1이면 모델의 예측값이 모든 실제값과 일치한다.**

③ R^2 = 0이면 모델의 예측값이 모든 실제값과 일치한다.

④ **R^2가 음수이면 모델의 예측 성능이 실제값의 평균만 예측하는 기준 모델보다 낮다는 의미이다.**

5. 다음 모델을 지도학습(Supervised Learning)과 비지도학습(Unsupervised Learning)으로 구분하시오.

SVM / DBSCAN / Random Forest / K-means / Linear Regression / Logistic Regression

지도학습 : **SVM, Random Forest, Linear Regression, Logistic Regression**

비지도학습 : **DBSCAN, K-means**

---

6. 소프트 마진 SVM(Soft Margin SVM)에서 C 값을 지나치게 크게 설정했을 때 나타날 수 있는 현상으로 가장 적절한 것은?

① 마진 위반에 대한 페널티가 작아져 더 많은 위반을 장려한다.

② 훈련 데이터의 마진 위반을 강하게 억제하여 과적합 위험이 커질 수 있다.

③ 어떤 데이터든 반드시 선형 분리가 가능해진다.

④ 서포트 벡터가 더 이상 필요하지 않다.

7. **[O/X]** 전통적인 프로그래밍 방식은 데이터와 정답을 이용하여 규칙을 도출하는 반면, 머신러닝 방식은 사람이 정의한 규칙을 데이터에 적용하여 결과를 예측한다.

O X

8. **[O/X]** 커널 SVM은 원래 입력 공간에서 선형적으로 분리하기 어려운 데이터에 대해 비선형 결정 경계를 표현할 수 있다.

O X

9. 서포트 벡터 머신(Support Vector Machine, SVM)에 대한 설명으로 옳지 않은 것은?

① SVM은 결정 경계를 찾을 때 마진(Margin)을 최소화하는 것을 목표로 한다.

② 서포트 벡터는 결정 경계의 위치를 결정하는 데 중요한 역할을 하는 데이터 샘플이다.

③ Hard Margin SVM은 모든 훈련 데이터를 올바르게 분류하는 결정 경계를 찾는다.

④ Soft Margin SVM은 일부 마진 위반이나 오분류를 허용한다.

10. K-means의 한계에 해당하는 설명을 모두 고르시오.

① 군집 수 K를 사전에 정해야 한다.

② 복잡한 형태를 가진 군집을 구분하는 데 어려움이 있을 수 있다.

③ 크기와 밀도가 크게 다른 군집을 구분할 때 어려움이 있을 수 있다.

④ 데이터에 이상치가 있어도 중심점은 전혀 영향을 받지 않는다.

11. K-means에서는 각 데이터가 가장 가까운 중심점(centroid)에 할당된 뒤 중심점을 다시 계산한다. 이때 새로운 중심점은 해당 군집 데이터들의 어떤 값으로 계산하는가?

답 : **평균 (mean)**

12. **[O/X]** 실루엣 스코어(Silhouette Score)는 군집 내 데이터 간의 응집도와 서로 다른 군집 간의 분리도를 함께 평가하는 지표로, 군집 내 데이터가 서로 가깝고 군집 간 거리가 멀수록 낮은 값을 가진다.

O　　X

13. DBSCAN에 대한 설명으로 가장 적절한 것은?

① 데이터의 밀도를 이용하고, 군집에 속하지 않는 노이즈를 구분할 수 있다.

② 항상 군집 수 K를 사전에 정해야 한다.

③ 모든 데이터를 반드시 하나의 군집에 할당한다.

④ 각 군집의 평균 중심점을 반복적으로 갱신한다.

14. K-means는 군집 수(K)를 사전에 지정해야 한다. 반면 DBSCAN은 군집을 형성하기 위해 두 가지 주요 하이퍼파라미터를 설정해야 한다. 이 두 가지 하이퍼파라미터의 이름을 쓰시오.

답 : **ε (입실론), MinPts**

---

15. **[O/X]** 회귀 의사결정트리(Regression Tree)는 연속적인 값을 예측하며, 각 리프 노드(Leaf Node)에 속한 훈련 샘플들의 타깃값 평균을 예측값으로 사용할 수 있다.

O　　X

16. 분류 의사결정트리(Decision Tree)에서 좋은 분할(Split)에 대한 설명으로 옳은 것을 모두 고르시오.

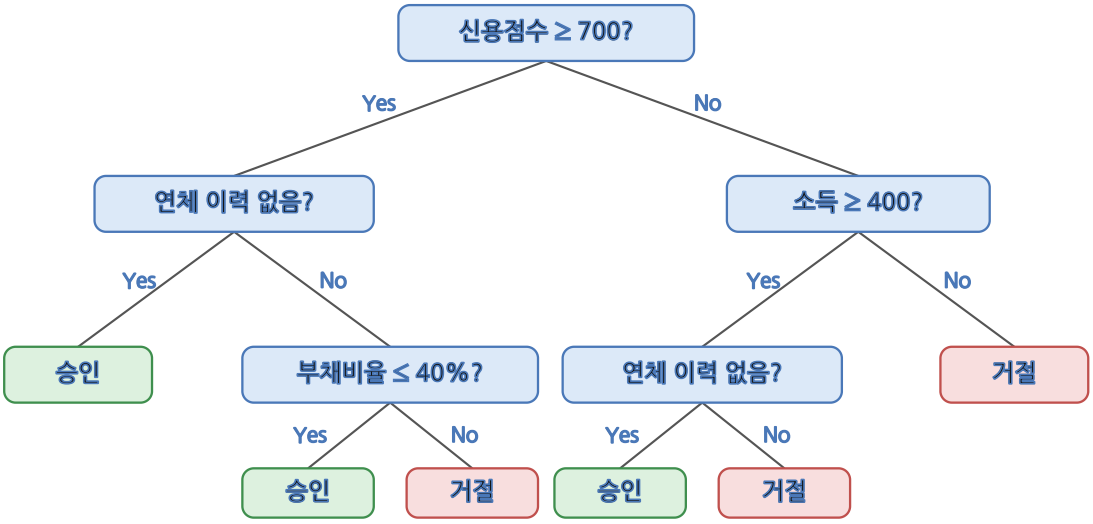
① 분할 후 자식 노드의 불순도(Impurity)가 높아지는 방향을 우선한다.

② 지니(Gini) 불순도의 감소량이 큰 분할을 우선한다.

③ 엔트로피(Entropy)를 기반으로 계산한 정보이득이 큰 분할을 우선한다.

④ 분할할 때 클래스 레이블은 이용하지 않는다.

17. 다음은 고객의 대출 승인 여부를 예측하기 위해 학습된 의사결정트리(Decision Tree)이다. 의사결정트리와 고객 정보를 참고하여, 옳지 않은 설명을 고르시오.



① 의사결정트리의 최대 깊이(Max Depth)는 3이다.

② 고객 A(신용점수 680 / 월 소득 450만원 / 연체 이력 있음 / 부채 비율 30%)는 최종적으로 대출이 거절되는 것으로 예측된다.

③ 의사결정트리에서 좋은 분할은 일반적으로 자식 노드의 지니 불순도(Gini Impurity) 또는 엔트로피(Entropy)를 감소시키는 방향으로 이루어진다.

④ 이 의사결정트리의 모든 리프 노드(Leaf Node)는 동일한 깊이에 위치한다.

18. 랜덤 포레스트(Random Forest)에 대한 설명으로 옳은 것을 모두 고르시오.

① 여러 결정트리를 결합하며, 분할 시 사용할 특성의 후보를 무작위로 제한할 수 있다.

② 배깅(Bagging)을 이용하여 훈련 데이터에서 복원추출한 서로 다른 데이터 샘플로 각 트리를 학습시킨다.

③ Out-of-Bag 샘플은 각 트리의 학습에 사용되지 않은 데이터이다.

④ 여러 결정트리의 예측 결과를 결합하면 개별 결정트리에 비해 일반적으로 예측의 분산이 증가한다.

19. **다음은 앙상블 학습(Ensemble Learning)의 여러 방법에 대한 설명이다. 각 설명에 해당하는 학습 방법을 쓰시오.**

Hard voting / Soft voting / Bagging / Boosting

1. 훈련 데이터에서 복원추출한 샘플로 여러 모델을 독립적으로 학습시키고, 각 모델의 예측 결과를 결합한다.
   (**Bagging**)
2. 여러 모델이 예측한 클래스 중 가장 많은 표를 얻은 클래스를 최종 예측 결과로 선택한다.
   (**Hard voting**)
3. 이전 모델의 예측 오류를 보완하도록 여러 모델을 순차적으로 학습시킨다.
   (**Boosting**)
4. 여러 모델이 예측한 클래스별 확률을 평균하여 최종 예측 클래스를 결정한다.
   (**Soft voting**)

20. Permutation Importance**에 대한 설명으로 가장 적절한 것은?**

① **특정 특성(Feature)의 값을 무작위로 섞었을 때 모델의 예측 성능이 얼마나 감소하는지를 이용하여 특성 중요도를 평가한다.**

② 특정 특성(Feature)의 값이 클수록 해당 특성의 중요도가 높다고 판단한다.

③ 모델에서 가장 많이 사용된 특성을 항상 가장 중요한 특성으로 평가한다.

④ 특정 특성(Feature)의 값을 무작위로 섞었을 때 모델의 예측 성능이 향상되면 해당 특성의 중요도가 높다고 판단한다.