인공지능 중간고사

1. 선형회귀(Linear Regression)에 대한 설명으로 가장 적절한 것은?

   ① 입력 데이터의 특성을 기반으로 데이터를 여러 그룹으로 분류하는 방법이다.

   ② 입력 변수와 종속 변수 사이의 관계를 선형 함수로 모델링하여 연속적인 값을 예측하는 방법이다.

   ③ 입력 데이터의 유사성을 기반으로 정답 레이블 없이 군집을 형성하는 방법이다.

   ④ 여러 개의 결정 트리를 결합하여 예측 성능을 향상시키는 방법이다.

2. 머신러닝 모델이 훈련 데이터에 지나치게 맞춰져 훈련 데이터에서는 좋은 성능을 보이지만, 새로운 데이터에서는 예측 성능이 저하되는 현상을 무엇이라고 하는가?

   과적합 (Overfitting)

3. 로지스틱(Logistic) 회귀에서 사용하는 시그모이드(Sigmoid) 함수에 대한 설명으로 가장 적절한 것은?

   ① 입력값을 0 또는 1로만 변환하여 출력한다.

   ② 입력값을 0과 1 사이의 값으로 변환하여 클래스에 속할 확률을 표현할 수 있도록 한다.

   ③ 입력값과 출력값 사이의 관계를 직선으로 표현하여 연속적인 값을 예측한다.

   ④ 입력 데이터의 유사도를 계산하여 여러 군집으로 구분한다.

4. 회귀 모델의 성능 지표인 결정계수(Coefficient of Determination, R^2)에 대한 설명으로 옳은 것을 모두 고르시오.

   ① R^2는 모델이 데이터(종속 변수)의 변동을 얼마나 설명하는지 나타내는 지표이다.

   ② R^2 = 1이면 모델의 예측값이 모든 실제값과 일치한다.

   ③ R^2 = 0이면 모델의 예측값이 모든 실제값과 일치한다.

   ④ R^2가 음수이면 모델의 예측 성능이 실제값의 평균만 예측하는 기준 모델보다 낮다는 의미이다.

5. 다음 모델을 지도학습(Supervised Learning)과 비지도학습(Unsupervised Learning)으로 구분하시오.

SVM / DBSCAN / Random Forest / K-means / Linear Regression / Logistic Regression

지도학습 : **SVM, Random Forest, Linear Regression, Logistic Regression**

비지도학습 : **DBSCAN, K-means**

6. 소프트 마진 SVM(Soft Margin SVM)에서 C 값을 지나치게 크게 설정했을 때 나타날 수 있는 현상으로 가장 적절한 것은?

① 마진 위반에 대한 페널티가 작아져 더 많은 위반을 장려한다.

② **훈련 데이터의 마진 위반을 강하게 억제하여 과적합 위험이 커질 수 있다.**

③ 어떤 데이터든 반드시 선형 분리가 가능해진다.

④ 서포트 벡터가 더 이상 필요하지 않다.

7. **[O/X] 전통적인 프로그래밍 방식은 데이터와 정답을 이용하여 규칙을 도출하는 반면, 머신러닝 방식은 사람이 정의한 규칙을 데이터에 적용하여 결과를 예측한다.**

X

8. **[O/X] 커널 SVM은 원래 입력 공간에서 선형적으로 분리하기 어려운 데이터에 대해 비선형 결정 경계를 표현할 수 있다.**

O

9. 서포트 벡터 머신(Support Vector Machine, SVM)에 대한 설명으로 옳지 않은 것은?

① SVM은 결정 경계를 찾을 때 마진(Margin)을 최소화하는 것을 목표로 한다.

② 서포트 벡터는 결정 경계의 위치를 결정하는 데 중요한 역할을 하는 데이터 샘플이다.

③ Hard Margin SVM은 모든 훈련 데이터를 올바르게 분류하는 결정 경계를 찾는다.

④ Soft Margin SVM은 일부 마진 위반이나 오분류를 허용한다.

10. K-means의 한계에 해당하는 설명을 모두 고르시오.

① 군집 수 K를 사전에 정해야 한다.

② 복잡한 형태를 가진 군집을 구분하는 데 어려움이 있을 수 있다.

③ 크기와 밀도가 크게 다른 군집을 구분할 때 어려움이 있을 수 있다.

④ 데이터에 이상치가 있어도 중심점은 전혀 영향을 받지 않는다.

11. K-means에서는 각 데이터가 가장 가까운 중심점(centroid)에 할당된 뒤 중심점을 다시 계산한다. 이때 새로운 중심점은 해당 군집 데이터들의 어떤 값으로 계산하는가?

평균 (mean)

---

12. **[O/X]** 실루엣 스코어(Silhouette Score)는 군집 내 데이터 간의 응집도와 서로 다른 군집 간의 분리도를 함께 평가하는 지표로, 군집 내 데이터가 서로 가깝고 군집 간 거리가 멀수록 낮은 값을 가진다.

X

13. DBSCAN에 대한 설명으로 가장 적절한 것은?

① 데이터의 밀도를 이용하고, 군집에 속하지 않는 노이즈를 구분할 수 있다.

② 항상 군집 수 K를 사전에 정해야 한다.

③ 모든 데이터를 반드시 하나의 군집에 할당한다.

④ 각 군집의 평균 중심점을 반복적으로 갱신한다.

14. K-means는 군집 수(K)를 사전에 지정해야 한다. 반면 DBSCAN은 군집을 형성하기 위해 두 가지 주요 하이퍼파라미터를 설정해야 한다. 이 두 가지 하이퍼파라미터의 이름을 쓰시오.

ε (입실론), MinPts

---

15. **[O/X]** 회귀 의사결정트리(Regression Tree)는 연속적인 값을 예측하며, 각 리프 노드(Leaf Node)에 속한 훈련 샘플들의 타깃값 평균을 예측값으로 사용할 수 있다.

O

16. 분류 의사결정트리(Decision Tree)에서 좋은 분할(Split)에 대한 설명으로 옳은 것을 모두 고르시오.

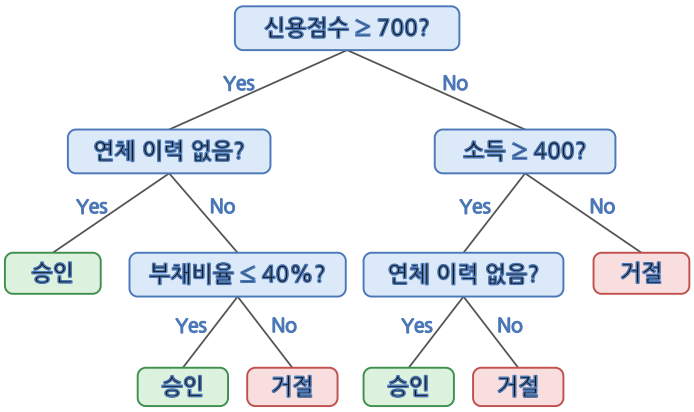
① 분할 후 자식 노드의 불순도(Impurity)가 높아지는 방향을 우선한다.

② 지니(Gini) 불순도의 감소량이 큰 분할을 우선한다.

③ 엔트로피(Entropy)를 기반으로 계산한 정보이득이 큰 분할을 우선한다.

④ 분할할 때 클래스 레이블은 이용하지 않는다.

17. 다음은 고객의 대출 승인 여부를 예측하기 위해 학습된 의사결정트리(Decision Tree)이다. 의사결정트리와 고객 정보를 참고하여, 옳지 않은 설명을 고르시오.



① 의사결정트리의 최대 깊이(Max Depth)는 3이다.

② 고객 A(신용점수 680 / 월 소득 450만원 / 연체 이력 있음 / 부채 비율 30%)는 최종적으로 대출이 거절되는 것으로 예측된다.

③ 의사결정트리에서 좋은 분할은 일반적으로 자식 노드의 지니 불순도(Gini Impurity) 또는 엔트로피(Entropy)를 감소시키는 방향으로 이루어진다.

④ 이 의사결정트리의 모든 리프 노드(Leaf Node)는 동일한 깊이에 위치한다.

18. 랜덤 포레스트(Random Forest)에 대한 설명으로 옳은 것을 모두 고르시오.

① 여러 결정트리를 결합하며, 분할 시 사용할 특성의 후보를 무작위로 제한할 수 있다.

② 배깅(Bagging)을 이용하여 훈련 데이터에서 복원추출한 서로 다른 데이터 샘플로 각 트리를 학습시킨다.

③ Out-of-Bag 샘플은 각 트리의 학습에 사용되지 않은 데이터이다.

④ 여러 결정트리의 예측 결과를 결합하면 개별 결정트리에 비해 일반적으로 예측의 분산이 증가한다.

19. **다음은 앙상블 학습(Ensemble Learning)의 여러 방법에 대한 설명이다. 각 설명에 해당하는 학습 방법을 쓰시오.**

Hard voting / Soft voting / Bagging / Boosting

1. 훈련 데이터에서 복원추출한 샘플로 여러 모델을 독립적으로 학습시키고, 각 모델의 예측 결과를 결합한다.
   (**Bagging**)
2. 여러 모델이 예측한 클래스 중 가장 많은 표를 얻은 클래스를 최종 예측 결과로 선택한다.
   (**Hard voting**)
3. 이전 모델의 예측 오류를 보완하도록 여러 모델을 순차적으로 학습시킨다.
   (**Boosting**)
4. 여러 모델이 예측한 클래스별 확률을 평균하여 최종 예측 클래스를 결정한다.
   (**Soft voting**)

20. Permutation Importance**에 대한 설명으로 가장 적절한 것은?**

① **특정 특성(Feature)의 값을 무작위로 섞었을 때 모델의 예측 성능이 얼마나 감소하는지를 이용하여 특성 중요도를 평가한다.**

② 특정 특성(Feature)의 값이 클수록 해당 특성의 중요도가 높다고 판단한다.

③ 모델에서 가장 많이 사용된 특성을 항상 가장 중요한 특성으로 평가한다.

④ 특정 특성(Feature)의 값을 무작위로 섞었을 때 모델의 예측 성능이 향상되면 해당 특성의 중요도가 높다고 판단한다.