



인공지능시대의 윤리

인공지능의 책무성



1

책임과
책무성
개념의 구분

책임의 개념

- 사고나 오류 발생 이후 결과에 대해 귀속 주체를 묻는 **사후적 개념**임
- 법적 · 제도적 기준에 따라 **잘못의 주체를 특정**하는 데 초점이 있음

책무성의 개념

- 책무성은 판단과 행위가 **왜 그렇게 이루어졌는지**를 설명하고 정당화할 의무임
- 사고 이후가 아니라 사고 이전의 예방과 윤리적 설계를 포함하는 **사전적 개념**임

2

자율 시스템의
발전과 책임
구조 변화

전통적 자동 시스템과의 차이

기존 기계 시스템

- ▶ 설계자, 제조자, 사용자 중 책임 주체가 비교적 명확했음

인공지능

- ▶ 스스로 학습하고 판단하여 기존 책임 구조가 적용되기 어려움

자율성 수준에 따른 책임 변화

- 보조형 인공지능은 인간이 최종 판단권을 가지므로 **책임이 인간에게 귀속**됨
- 고도 자율 시스템은 인간과 AI의 판단 경계가 모호해져 책임이 **복합화**됨



3

인간 -
인공지능
결합과
책임의 확장

인간 - AI 통합 시스템의 등장

- 인공지능 의수 · 의족처럼 **뇌신경과 직접 연결된 시스템**이 등장함
- AI가 인간의 신체 일부처럼 작동하며 **판단 주체를 분리하기 어려워짐**

책임의 성격 변화

- AI의 고장이 단순한 기계 손상이 아닌 **인간의 신체적 피해**로 해석될 가능성이 있음
- 책임은 기계의 결함이 아니라 **인간 - 기계 융합체의 행위**로 간주됨

4

투명성과
책임성을
위한 설계
조건

책임 확보를 위한 기본 조건

- ① AI의 사용 목적을 명확히 규정해야 함
- ② 데이터 출처와 품질을 기록해 편향 여부를 검증해야 함
- ③ 알고리즘 구조와 판단 절차를 설명 가능하게 설계해야 함
- ④ 데이터 처리 과정과 활동 로그를 체계적으로 기록해야 함

책임성 검토를 위한 점검 항목

- ① 판단 기준과 우선순위 설정 근거를 명확히 해야 함
- ② 데이터 선택 기준과 한계를 인식하고 공개해야 함
- ③ 의도하지 않은 사회적 · 정치적 편향을 지속적으로 점검해야 함
- ④ 불확실성과 예측 불가능성을 고려한 운영 체계를 마련해야 함