



인공지능시대의 윤리

인공지능의 신뢰성과 공정성



1

AI 신뢰성과
공정성의
사회적
중요성

AI가 사회적 판단자로 작동하는 현실

- AI가 채용, 대출, 의료 등 **핵심 의사결정에 활용**됨
- AI 판단은 개인의 삶과 미래에 중대한 영향을 미침

신뢰성과 공정성 논의의 필요성

- 데이터 왜곡과 알고리즘 불투명성으로 **오류 가능성이 존재**함
- 책임 구조가 모호할 경우 사회적 위험이 확대됨

2

AI 신뢰성의
핵심 요소와
한계

AI 신뢰성을 구성하는 네 가지 요소

정확성

- AI 판단 결과가 현실과 얼마나 일치하는가의 문제임

안전성

- 동일한 조건에서 일관된 결과를 도출하는지의 여부임

예측가능성

- 판단 기준과 원리를 사람이 이해할 수 있는지의 문제임

견고성

- 외부 공격이나 미세한 오류에도 안정적으로 작동하는지의 문제임

신뢰성 결여가 초래하는 위험

- 네 요소 중 하나라도 부족하면 사회적 활용이 어려움
- 신뢰성 없는 AI는 사회 시스템의 위험 요소가 됨
- 고위험 분야일수록 **신뢰성 확보가 필수적**임

AI 공정성의 개념

공정성

특정 집단에 체계적 불이익이 발생하지 않는 상태를 의미함

- ▶ AI의 공정성은 의도가 아니라 **결과를 기준으로 판단**해야 함
- ▶ 데이터와 알고리즘이 **사회에 미치는 영향**을 검증해야 함

데이터 편향과 실제 사례

인종 편향

- ▶ 범죄 예측 AI가 흑인을 과도하게 위험군으로 분류함

성별 편향

- ▶ 채용 AI가 여성 지원자를 불리하게 평가함

지역 · 계층 편향

- ▶ 대출 AI가 특정 지역 주민을 구조적으로 배제함

AI와 불평등의 관계

- AI는 기존 사회 편향을 제거하지 못하며 오히려 **불평등을 빠르고 대규모로 재생산**할 수 있음
- 공정성 문제는 기술이 아닌 **사회 구조 문제와 연결**됨



4

투명성 ·
설명가능성과
인간의
판단 오류

알고리즘 불투명성과 설명가능성

- 딥러닝 AI는 판단 과정이 블랙박스화되기 쉬움
- 설명가능성은 신뢰와 책임 판단의 핵심 요소임

자동화 편향과 인간 판단의 위험

- 인간이 AI 판단을 과도하게 신뢰하는 현상이 발생함
- 고위험 의사결정 영역에서 오류가 증폭될 수 있음

5

책임 ·
안정성 ·
제도적 관리의
필요성

책임 구조와 사회적 신뢰 문제

- AI 사고 발생 시 책임 주체가 불명확해질 가능성이 큼
- 책임 공백은 AI 시스템의 사회적 신뢰를 약화시킴

안정성 확보와 제도적 관리

- ① Data Drift로 인해 지속적 점검과 재학습이 필요함
- ② 법 · 제도적 규제가 신뢰받는 AI 운영의 기반임

