

데이터 분석 프로그래밍

강원대학교 컴퓨터공학과

Prof. Kyeongpil Kang

데이터의 이해

- Sample (Instance)

- 데이터의 각각의 표본 ($d_1, d_2, \dots$). 테이블에서 행 (Row)

- Feature (Attributes)

- 각 표본의 특성. 테이블의 열 (Column)

- 정형 데이터

- 각 특성이 정해진 데이터 타입과 카테고리, 크기로만 구성
- 테이블 데이터 Ex) 학생 성적, 키-몸무게 데이터

- 비정형 데이터

- 정형 데이터가 아닌 데이터. 타입과 크기 등이 가변적일 수 있음
- 분석하기 위해서 가공이 필요하지만, 대부분의 원형 데이터는 비정형 데이터로 존재
- Ex) 뉴스 데이터, 이미지 데이터, 음성 데이터
- 일반적으로 정형 데이터에 비해 정제 및 처리하기가 어려움.

	<i>Name</i>	<i>Team</i>	<i>Number</i>	<i>Position</i>	<i>Age</i>
0	Avery Bradley	Boston Celtics	0.0	PG	25.0
1	John Holland	Boston Celtics	30.0	SG	27.0
2	Jonas Jerebko	Boston Celtics	8.0	PF	29.0
3	Jordan Mickey	Boston Celtics	NaN	PF	21.0
4	Terry Rozier	Boston Celtics	12.0	PG	22.0
5	Jared Sullinger	Boston Celtics	7.0	C	NaN
6	Evan Turner	Boston Celtics	11.0	SG	27.0

데이터의 이해

• 정형 데이터

- 각 특성이 정해진 데이터 타입과 카테고리, 크기로만 구성
- 테이블 데이터
- Ex) 학생 성적, 키-몸무게 데이터

• 비정형 데이터

- 정형 데이터가 아닌 데이터. 타입과 크기 등이 가변적일 수 있음
- Ex) 뉴스 데이터, 이미지 데이터, 음성 데이터
- 텍스트 데이터
 - 길이가 가변적, 텍스트의 최소 정보 단위를 규정하기 힘들
- 이미지, 음성 데이터는 왜 비정형 데이터일까?
- 비정형 데이터의 경우에는 컴퓨터가 이해할 수 있게 정형 데이터 형식으로 가공해야 한다.
=> 숫자(행렬, 벡터)로 표현

GDP (million US\$) by country

	Country/Territory ↕	IMF ^{[1][13]}		World Bank ^[14]		United Nations ^[15]	
		Forecast ↕	Year ↕	Estimate ↕	Year ↕	Estimate ↕	Year ↕
	World	109,529,216	2024	105,435,540	2023	100,834,796	2022
1	United States	28,781,083	2024	27,360,935	2023	25,744,100	2022
2	China	18,532,633	^[n 1] 2024	17,794,782	^[n 3] 2023	17,963,170	^[n 1] 2022
3	Germany	4,591,100	2024	4,456,081	2023	4,076,923	2022
4	Japan	4,110,452	2024	4,212,945	2023	4,232,173	2022
5	India	3,937,011	2024	3,549,919	2023	3,465,541	2022
6	United Kingdom	3,495,261	2024	3,340,032	2023	3,089,072	2022
7	France	3,130,014	2024	3,030,904	2023	2,775,316	2022
8	Brazil	2,331,391	2024	2,173,666	2023	1,920,095	2022
9	Italy	2,328,028	2024	2,254,851	2023	2,046,952	2022
10	Canada	2,242,182	2024	2,140,086	2023	2,137,939	2022
11	Russia	2,056,844	2024	2,021,421	2023	2,240,422	2022
12	Mexico	2,017,025	2024	1,788,887	2023	1,463,323	2022
13	Australia	1,790,348	2024	1,723,827	2023	1,776,577	2022
14	South Korea	1,760,947	2024	1,712,793	2023	1,673,916	2022
15	Spain	1,647,114	2024	1,580,695	2023	1,415,874	2022
16	Indonesia	1,475,690	2024	1,371,171	2023	1,319,100	2022
17	Netherlands	1,142,513	2024	1,118,125	2023	1,008,027	2022
18	Turkey	1,113,561	2024	1,108,022	2023	907,118	2022
19	Saudi Arabia	1,106,015	2024	1,067,583	2023	1,108,148	2022
20	Switzerland	938,458	2024	884,940	2023	818,426	2022
21	Poland	844,623	2024	811,229	2023	688,125	2022
	Taiwan	802,958	^[n 4] 2024	—		—	

데이터의 이해

- 반정형 데이터 (Semi-structured data)
 - 정형 데이터와 비정형 데이터가 혼재되어 있음
 - Ex) 영화 리뷰: 리뷰 텍스트와 평점이 같이 존재

ratings_train

id	label	label
9976970	아 더빙.. 진짜 짜증나네요 목소리	0
3819312	흠...포스터보고 초딩영화줄....오버연기조차 가볍지 않구나	1
10265843	너무재밌었다그래서보는것을추천한다	0
9045019	교도소 이야기구먼 ..솔직히 재미는 없다..평점 조정	0
6483659	사이몬페그의 익살스런 연기가 돋보였던 영화!스파이더맨에서 늙어보이기만 했던 커스틴 던스트가 너무나도 이뻐보였다	1
5403919	막 걸음마 떼ن 3세부터 초등학교 1학년생인 8살용영화.ㅋㅋㅋ...별반개도 아까움.	0
7797314	원작의 긴장감을 제대로 살려내지못했다.	0
9443947	별 반개도 아깝다 욕나온다 이응경 길용우 연기생활이몇년인지..정말 발로해도 그것보단 낫겠다 납치.감금만반복반복..이드라마는 가족도없다 연기못하는	0
7156791	액션이 없는데도 재미 있는 몇안되는 영화	1
5912145	왜케 평점이 낮은건데? 꽤 볼만한데.. 헐리우드식 화려함에만 너무 길들여져 있나?	1


컴퓨터가 이해할 수 있게 데이터를 “표현”

- Data Representation

- 데이터를 설명 혹은 사용 가능하게 표현하는 것
- 컴퓨터를 사용하여 데이터를 분석하기 위해서는 컴퓨터가 이해할 수 있게 표현해야 함.
- 또한 무수히 많은 데이터에 대해서 서로 다른 데이터는 서로 다르게 표현할 수 있어야 함.
- 따라서 각 sample 혹은 feature들을 숫자, 특히 vector/matrix로 표현 하는 것이 중요함.



이름: 김철수
나이: 25
성별: 남
국적: 대한민국
키: 170
몸무게: 75
...



Vectorization

$$\begin{pmatrix} 0.3331 \\ 0.2323 \\ 1.0093 \\ -1.2322 \\ -0.4431 \\ 2.3331 \\ 0.3571 \\ 0.3315 \\ 0.9961 \end{pmatrix}$$


텍스트와 이미지 데이터의 표현

• 텍스트 데이터 표현

- 텍스트 데이터를 표현하는 방법에는 여러 가지가 있음.
- Bag-of-words, Embedding, 모델 기반 표현
- Ex) Bag-of-words

"나는 학교에 간다" → '나', '는', '학교', '에', '간다' →


나	1
너	0
집	0
에	1
간다	1
먹다	0
학교	1
를	0
...	...


$$\begin{pmatrix} 0.3331 \\ 0.2323 \\ 1.0093 \\ -1.2322 \\ -0.4431 \\ 2.3331 \\ 0.3571 \\ 0.3315 \\ 0.9961 \end{pmatrix}$$

텍스트와 이미지 데이터의 표현

- 이미지 데이터 표현



- 이미지는 픽셀 단위로 숫자를 표현함
- RGB (Red, Green, Blue) - 빛의 삼원색처럼 섞을수록 밝아짐. 디스플레이에 활용
- CMYK (Cyan, Magenta, Yellow, Black) - 물감처럼 섞을수록 어두어짐. 인쇄물에 활용



텍스트와 이미지 데이터의 표현

• 이미지 데이터 표현

- 이미지는 픽셀 단위로 숫자를 표현함
- 이미지 데이터를 표현할 때는 주로 RGB 방법을 사용
- 가로, 세로 사이즈가 6, 6인 사진의 예)



Machine Learning


$$\begin{pmatrix} 0.3331 \\ 0.2323 \\ 1.0093 \\ -1.2322 \\ -0.4431 \\ 2.3331 \\ 0.3571 \\ 0.3315 \\ 0.9961 \end{pmatrix}$$

대규모 데이터의 표현

- 여러 데이터(multiple samples and features)의 경우
 - 벡터(Vector)들을 통합하여 행렬(Matrix)로 표현
 - 아래는 각 열이 각 샘플을 의미함 (행 단위로 표현하는 경우도 있음)

$$\begin{pmatrix} 0.3331 \\ 0.2323 \\ 1.0093 \\ -1.2322 \\ -0.4431 \\ 2.3331 \\ 0.3571 \\ 0.3315 \\ 0.9961 \end{pmatrix} \quad \begin{pmatrix} 0.3723 \\ 0.7343 \\ -1.0093 \\ 1.0013 \\ 0.9631 \\ 0.1313 \\ 0.9971 \\ 0.5415 \\ 0.9611 \end{pmatrix} \quad \begin{pmatrix} 0.7871 \\ 1.2323 \\ 0.0093 \\ -1.0002 \\ -1.4671 \\ 0.3331 \\ 1.3571 \\ 0.3315 \\ 0.0196 \end{pmatrix} \quad \dots$$

$d_1 \quad d_2 \quad d_3 \quad \dots$


$$\begin{pmatrix} 0.3331 & 0.3723 & 0.7871 \\ 0.2223 & 0.7343 & 1.2323 \\ 1.0093 & -1.0093 & 0.0093 \\ -1.2322 & 1.0013 & -1.0002 \\ -0.4431 & 0.9631 & -1.4672 \dots \\ 2.3331 & 0.1313 & 0.3331 \\ 0.3571 & 0.9971 & 1.3571 \\ 0.3315 & 0.5415 & 0.3315 \\ 0.9961 & 0.9611 & 0.0196 \end{pmatrix}$$

$d_1 \quad d_2 \quad d_3$


대규모 데이터의 표현

- 여러 개의 데이터(multiple)의 경우

- 벡터(Vector)들을 통합하여 행렬(Matrix)로 표현
- 각 데이터는 벡터 공간 상에 위치할 수 있음. 비슷한 특성의 데이터끼리 비슷한 곳에 위치

$$\begin{pmatrix} 0.3331 & 0.3723 & 0.7871 \\ 0.2223 & 0.7343 & 1.2323 \\ 1.0093 & -1.0093 & 0.0093 \\ -1.2322 & 1.0013 & -1.0002 \\ -0.4431 & 0.9631 & -1.4672 \dots \\ 2.3331 & 0.1313 & 0.3331 \\ 0.3571 & 0.9971 & 1.3571 \\ 0.3315 & 0.5415 & 0.3315 \\ 0.9961 & 0.9611 & 0.0196 \end{pmatrix}$$


d_1 d_2 d_3



데이터 공간 (space)



대규모 데이터의 표현

- 대규모 데이터를 벡터로 표현하여 데이터 시각화를 통해 분석할 수 있음



대규모 데이터의 표현

- 대규모 데이터를 벡터로 표현하여 데이터 시각화를 통해 분석할 수 있음
- 이를 통해 각각의 데이터를 확인하지 않고 데이터 분포를 관찰하고 인사이트를 얻을 수 있음



TopicLens - <https://youtu.be/hooTAah7j2o?si=5WyQ5FsLTxeftf3o>



데이터 분석 과정

STEP
01



데이터 수집 및 탐색

- 대상 데이터를 수집하여 저장
- 일부 데이터를 직접 살펴보며 개략적 특성 파악


STEP
02



기초 통계 분석

평균, 분산 등을 살펴보고, 이상 데이터나 편향이 있는지 파악

STEP
03



데이터 전처리

데이터의 중복 제거
이상 데이터 필터링
데이터 파싱
벡터화
...

STEP
04



데이터 시각화/ ML 적용

- 데이터를 시각화하여 전체적인 데이터 분포 파악
- ML 기법들을 적용하여 고차원 수준의 분석을 진행하고, 잠재적 특성 도출

STEP
05



지식/인사이트 도출

데이터로부터 지식과 인사이트를 도출하고 문제를 해결

각 스텝에서 도출한 결과를 기반으로 이전 스텝으로 돌아가서 분석 과정을 반복적으로 수행하며 개선할 수 있음




데이터 수집 및 탐색

- 데이터를 여러 소스로부터 수집
 - 오픈 소스 데이터
 - 직접 수집 (크롤링 등)


표 1-7. 공공기관 홈페이지의 인터넷 주소

기관명	인터넷 주소
ACKIS(문화 예술 지식 정보 시스템)	https://policydb.kcti.re.kr/main.do
AI 허브	https://aihub.or.kr/
Kaggle (세계의 다양한 주제의 데이터)	https://www.kaggle.com/datasets
Quandl(경제, 의료, 부동산 등)	https://www.quandl.com
SGIS(통계 지리 정보 서비스)	http://sgis.kostat.go.kr/
TAAS(교통 사고 분석 시스템)	http://taas.koroad.or.kr/
Uniprot(염기서열)	https://www.uniprot.org
건축데이터 민간개방 시스템	https://open.eais.go.kr/
경기도 공공데이터 개방포털	https://data.gg.go.kr/portal/mainPage.do
경기버스정보	http://www.gbis.go.kr/


그림 참고 - 데이터 분석을 위한 전처리와 시각화 with 파이썬




AIHub



Kaggle Datasets



모두의 말뭉치 (국립국어원)




HuggingFace Datasets

데이터 수집 및 탐색

- 데이터를 여러 소스로부터 수집

- 오픈 소스 데이터
- 직접 수집 (Web Crawling/Scraping)
 - 주의) 서버에 무리를 주지 않을 정도로 요청을 보내야 함!
 - robots.txt를 준수하는 것을 권장



데이터 수집 및 탐색

- 수집된 데이터에 대해 탐색
 - 랜덤하게 샘플링해서 직접 살펴보는 것은 매우 중요

1. Become one with the data

The first step to training a neural net is to not touch any neural net code at all and instead **begin by thoroughly inspecting your data. This step is critical. I like to spend copious amount of time (measured in units of hours) scanning through thousands of examples**, understanding their distribution and looking for patterns. Luckily, your brain is pretty good at this. One time I **discovered that the data contained duplicate examples**. Another time I **found corrupted images / labels**. I look for **data imbalances and biases**. I will typically also pay attention to **my own process for classifying the data, which hints at the kinds of architectures we'll eventually explore**. As an example - are very local features enough or do we need global context? How much variation is there and what form does it take? What variation is spurious and could be preprocessed out? Does spatial position matter or do we want to average pool it out? How much does detail matter and how far could we afford to downsample the images? How noisy are the labels?

In addition, since the neural net is effectively a compressed/compiled version of your dataset, you'll be able to look at your network (mis)predictions and understand where they might be coming from. And if your network is giving you some prediction that doesn't seem consistent with what you've seen in the data, something is off.


Once you get a qualitative sense it is also a good idea to write some simple code to search/filter/sort by whatever you can think of (e.g. type of label, size of annotations, number of annotations, etc.) and **visualize their distributions and the outliers along any axis. The outliers especially almost always uncover some bugs in data quality or preprocessing.**




기초 통계 분석

- 데이터에 대해서 여러 기초 통계량을 계산


- Mean, Median, Min, Max, Quantile
- Histogram
- 이를 통해 데이터가 편향되었는지, 이상 데이터가 있는지 간단히 확인해 볼 수 있음
 - Left-skewed vs Right-skewed



(a) Right-skewed distribution



(b) Left-skewed distribution




이상 데이터 (Outlier data)

- 데이터 분석의 품질을 높이고, ML 및 시각화를 위해 전처리를 수행
 - 데이터 중복 제거 (Deduplication)
 - 이상 데이터 필터링 (Filtering outlier/anomaly data)
 - 데이터 파싱 (Parsing), 형태소 분석 (PoS Tagging)
 - 정규화 (Normalization)
 - 벡터화 (Vectorization)
 - ...

데이터 전처리

- 데이터 분석의 품질을 높이고, ML 및 시각화를 위해 전처리를 수행
 - 데이터 중복 제거 (Deduplication)
 - 정확히 같은 중복 데이터의 제거 뿐만 아니라 의미론적으로 거의 비슷한 데이터의 제거도 포함될 수 있음
 - 필터링 후 통계 분포가 달라질 수 있으므로 목적에 맞게 수행



나는 오후에 강의를 듣는다.
나는 오후 강의를 듣는다.
난 오후 강의를 듣는다.

→ 나는 오후 강의를 듣는다.

데이터 전처리




- 데이터 분석의 품질을 높이고, ML 및 시각화를 위해 전처리를 수행

- 정규화 (Normalization)

- 각 피처별 단위가 다르기 때문에 값의 범위가 다를 수 있음. 각 피처별로 고르게 분포를 조정이 필요
- Outlier에 따라서 왜곡이 발생할 수 있으므로 이상치 제거가 중요.
- 정규화 방식에는 Min-max scaling, Normal scaling, Robust scaling 등 여러 가지 방법이 있음

- 이상 데이터 필터링 (Filtering outlier/anomaly data, Data Cleaning)

- 분석에 필요한 특성이 없는 데이터, 분포와 너무 멀리 떨어져 있는 데이터 등 필터링





Filtering outlier/anomaly data

데이터 전처리

- 데이터 분석의 품질을 높이고, ML 및 시각화를 위해 전처리를 수행




- 데이터 파싱 (Parsing), 형태소 분석 (PoS Tagging)
 - 파싱은 키워드 분석 및 벡터화를 위한 과정
 - 키워드 분석 같은 경우에는 조사, 접미사 등은 불필요 할 수 있음
- 불용어 (Stopwords) 제거
 - 대명사, 관사, 지시어 등 너무 흔하거나 의미가 없는 단어는 분석에서 제거

"나는 학교에 간다"



데이터 전처리

- 데이터 분석의 품질을 높이고, ML 및 시각화를 위해 전처리를 수행
 - 시각화 및 기계학습 적용을 위해 벡터화 수행
 - 벡터의 크기를 균일하게 맞추기 위해 normalization 수행 (추후 다시 배울 예정)



데이터 시각화 / ML 적용

- Data Visualization


- 데이터 분포를 시각적으로 표현함으로써 직관적으로 분포를 이해 (인간의 인지 능력은 2D가 제일 효율적)
- 다른 사람들에게도 쉽게 결과물로 공유

- Machine Learning for Data analysis

- 고차원의 차원을 저차원으로 줄여 (Dimension Reduction) 인간이 이해할 수 있게 표현하거나,
- 예측하지 못한 특성을 예측(Classification, Regression)하여 분석하거나,
- 수많은 데이터에 대해서 그룹화(Clustering)하여 체계적으로 분석하는 등,
- 다방면으로 기계학습을 활용하여 데이터를 분석할 수 있음




그림 출처 - <https://thenewstack.io/7-best-practices-for-data-visualization/>



Dimension reduction using t-SNE (<https://www.youtube.com/watch?v=e2w-kOVHNQ4>)

지식 및 인사이트 도출

- 데이터 (Data) -> 정보 (Information) -> 지식 (Knowledge) -> 인사이트 (Insight / Wisdom)
 - 데이터 자체만으로는 유용하게 사용하기 힘들
 - 데이터를 가공하고 분석하여 정보를 추출
 - 정보를 이해하고 더 심층적으로 분석하여 지식과 인사이트를 얻고, 문제를 해결



DIKW Pyramid

데이터 분석을 통한 문제 해결 사례 – 서울시 심야버스 노선 수립

활용 데이터

- 서울시에서 발생한 1개월 간의 콜데이터에 기반한 KT 유동인구 데이터를 분석하였고, 7일간의 택시승·하차데이터를 분석하였다.

구분	KT 유동인구 데이터(1차 검증)	택시승·하차 데이터(2차 검증)
데이터	 KT고객의 통화 기지국 위치 및 청구지 주소	 스마트카드사(KSCC)의 택시 iDTG* 정보
OD구분 (O:출발지 D:도착지)	• O : 통화 시 기지국 위치 • D : 거주지 주소	• O : 승차 위치정보 • D : 하차 위치정보
기간	• 1개월치(3/1 ~ 3/31) • 약 1억 건/1일, 약 30억 건	• 7일치(3/18 ~ 3/24) • 1일 약 70~80만 건
요일 기준	• 주중 · 토요일 · 일요일 : 00시 ~ 05시	


* 통합형 디지털운행기록계(iDTG, Integrated Digital Tachograph) : 기존 택시미터기에 비해 GPS 위치정보, 주행거리, 요금 관련 사항 등의 정보 수집이 가능하다

분석방법

01 유동인구 데이터 처리

- 유동인구 데이터는 KT로부터 요약/실적데이터를 제공받아 심야버스 노선과 정류장, 도로정보를 가상화 서버에 적재한 후 분석하였으며, 서울시 지도포털도 활용하였다.


[유동인구 데이터 처리 흐름도]



02 택시 iDTG 데이터 처리

- 택시 iDTG 데이터는 분석용 레이어와 테이블을 생성하여 시각화와 노선검증 기능을 구현하였다.

[택시 iDTG 데이터 처리 흐름도]




03 공간패턴 분석을 위한 존(구역) 설정

- ① Hexagon(서울시)과 ② 동 이하 블록단위(KT)의 2개 안으로 확정하였다.

데이터 분석을 통한 문제 해결 사례 - 서울시 심야버스 노선 수립


04 데이터 별 유동인구 분포 패턴 비교

- KT유동인구 데이터(A)와 택시 승·하차 데이터(B) 각각으로부터 유동인구 분포 패턴과 택시 승·하차 분포 패턴을 분석하였고, 두 패턴 결과를 비교하였다.




05 노선검증 및 평가

- 통행량 분석으로 노선 수요를 파악하고 노선별 수요에 따른 가중치를 부여하였다.



06 노선 최적화 및 배차간격 조정

- 노선 부근의 유동인구 가중치를 적용하여 노선을 최적화한 후, 심야버스 정류장 단위로 통행량을 추정하여 요일별로 배차 간격을 조정하였다.




데이터 분석을 통한 문제 해결 사례 – 서울시 심야버스 노선 수립

분석결과

- 기존 노선안의 경우 자치구 단위 택시 OD데이터를 활용하여 분석한 주요 밀집지역의 분석결과는 양호하여 이를 제외하고 일부 보완이 필요한 밀집지역을 도출하였다.

보완 필요 지역



결과 활용

- 노선 검증, 통행량, 방향성 등 조건별 분석결과를 확인하여 심야버스 노선 수립 등에 활용할 수 있는 “버스노선 수립 지원 시스템”을 구축 활용하고 있다,


심야버스 노선 수립 지원 시스템 화면 예시



정책반영

- 심야버스 담당부서에서는 분석결과로 제시한 변경안 중 많은 부분을 반영하여 노선을 확정하였다.

심야버스 확대노선 최종(안)



서울특별시

서울시, 빅데이터 활용 정책 사례로 대통령상 수상



뉴스 제공
서울특별시청
2013-09-25 11:53

가

데이터 수집 - 데이터 플랫폼

표 1-7. 공공기관 홈페이지의 인터넷 주소

기관명	인터넷 주소
ACKIS(문화 예술 지식 정보 시스템)	https://policydb.kcti.re.kr/main.do
AI 허브	https://aihub.or.kr/
Kaggle (세계의 다양한 주제의 데이터)	https://www.kaggle.com/datasets
Quandl(경제, 의료, 부동산 등)	https://www.quandl.com
SGIS(통계 지리 정보 서비스)	http://sgis.kostat.go.kr/
TAAS(교통 사고 분석 시스템)	http://taas.koroad.or.kr/
Uniprot(염기서열)	https://www.uniprot.org
건축데이터 민간개방 시스템	https://open.eais.go.kr/
경기도 공공데이터 개방포털	https://data.gg.go.kr/portal/mainPage.do
경기버스정보	http://www.gbis.go.kr/





AIHub - <https://www.aihub.or.kr/>

모두의 말뭉치 - <https://kli.korean.go.kr/corpus/main/requestMain.do>

그림 참고 - 데이터 분석을 위한 전처리와 시각화 with 파이썬

Trending Datasets



Kaggle Datasets - <https://www.kaggle.com/datasets>

HuggingFace Datasets - <https://huggingface.co/datasets>

공공데이터 포털 - <https://www.data.go.kr/index.do>



Q&A