

데이터분석프로그래밍

강원대학교 컴퓨터공학과

Prof. Kyeongpil Kang

Prof. Kyeongpil Kang

Academic Background

- B.S - Computer Science, Korea University
(Mar. 2012-Feb. 2016)
- Ph.D - Computer Science, Korea University
(Mar. 2016-Feb. 2020, Directed by Prof. Jaegul Choo)

Careers


- Machine Learning Researcher, SKT AI Center
(Aug. 2019-Jan. 2020)
- Machine Learning Researcher, ScatterLab
(Dec. 2020-Dec. 2023)
- Machine Learning Researcher, Liner
(Jan. 2024-Aug. 2024)

Contact


- 학부연구생, 대학원 진학 및 진로/학업 상담이 필요하다면
편하게 연락주시기 바랍니다 ☺
- Email: rudvlf0413@gmail.com



Derive Insight Via Hyper Intelligence




Sequential Recommender System




Recommender System Using Sequential and Global Preference via Attention Mechanism and Topic Modeling, 2019

Image Topic Modeling





See, caption, cluster: Large-scale image analysis using captioning and topic modeling, 2024



Analyzing Historical Documents

- Restoring damaged characters using Retrieval-Augmented Large Language Models




Damaged Text	吏曹判書[D1][D2][D3]初度呈辭. 入啓. [D4]由.	(from JRS, 12/6/1654, King Hyojong)
BERT-Res	吏曹判書李壽恒初度呈辭. 入啓. 給由.	
Gemini-2.5-Pro	吏曹判書沈之源初度呈辭. 入啓. 給由.	
ARI-32B	吏曹判書李厚源初度呈辭. 入啓. 給由.	
Damaged Text	上詣敬奉閣行禮, 仍御承文院, 誦<[D1][D2]><下泉>詩, 命三學士及諸忠[D3][D4]係錄用.	(from AJD, 10/6/1770, King Yeongjo)
BERT-Res	上詣敬奉閣行禮, 仍御承文院, 誦<詩鑑><下泉>詩, 命三學士及諸忠臣子孫錄用.	
Gemini-2.5-Pro	上詣敬奉閣行禮, 仍御承文院, 誦<匪風><下泉>詩, 命三學士及諸忠臣之孫錄用.	
ARI-32B	上詣敬奉閣行禮, 仍御承文院, 誦<匪風><下泉>詩, 命三學士及諸忠臣後孫錄用.	
Damaged Text	全羅道監司書狀, 去九月間, [D1][D2]池水變赤色十餘日, 魚蝦浮出盡死事.	(from AJD, 17/11/1588, King Seonjo)
BERT-Res	全羅道監司書狀, 去九月間, 大山池水變赤色十餘日, 魚蝦浮出盡死事.	
Gemini-2.5-Pro	全羅道監司書狀, 去九月間, 海南池水變赤色十餘日, 魚蝦浮出盡死事.	
ARI-32B	全羅道監司書狀, 去九月間, 光州池水變赤色十餘日, 魚蝦浮出盡死事.	

Leveraging External Knowledge for Historical Document Restoration via Retrieval-Augmented Large Language Models, ACL Findings, 2026


Analyzing Historical Documents

- Translating Hanja to English using Retrieval-augmented pseudo-labeling

	BLEU	METEOR	chrF++	Cost \$
Baseline	15.720	0.421	43.971	0.213
+ Glossary	23.747	0.504	51.478	0.236
+ Korean	25.457	0.520	52.637	0.255
+ RAG (K : 12)				
• Static shots	30.387	0.565	56.385	0.981
• Dynamic shots (Hanja)	36.223	0.604	60.354	1.115
• Dynamic shots (Kor)	36.430	0.606	60.545	1.254
• Dynamic shots (Hanja + Kor)	35.945	0.602	60.219	1.272
RAG (Dynamic Shots, Kor, K : 64)	37.905	0.616	61.534	5.646
+ FusioN (K : 12, D : 4)				
Proposer (Kor) Fusor (Kor)	36.869	0.614	61.474	2.713
Proposer (Kor) Fusor (Eng)	36.901	0.613	61.420	2.475
Proposer (Kor) Fusor (Hanja)	36.985	0.614	61.538	2.537
Proposer (Kor) Fusor (Hanja + Eng)	37.017	0.614	61.504	2.642
Proposer (Kor) Fusor (Hanja + Kor + Eng)	36.926	0.614	61.499	2.806
K_{Proposer} : 64, K_{Fusor} : 12, D : 5				
Proposer (Kor) Fusor (Hanja + Eng)	38.462	0.625	62.501	7.059



Training Large Language Models



Step 1

Collect demonstration data, and train a supervised policy.

A prompt is sampled from our prompt dataset.

Explain the moon landing to a 6 year old

A labeler demonstrates the desired output behavior.

Some people went to the moon...

This data is used to fine-tune GPT-3 with supervised learning.

SFT

Step 2

Collect comparison data, and train a reward model.

A prompt and several model outputs are sampled.

Explain the moon landing to a 6 year old

A Explain gravity... B Explain why... C Moon is natural satellite of... D People went to the moon...

A labeler ranks the outputs from best to worst.

D > C > A = B

This data is used to train our reward model.

RM

Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.

Write a story about frogs

The policy generates an output.

PPO

Once upon a time...

The reward model calculates a reward for the output.

RM

The reward is used to update the policy using PPO.

r_k




그림 출처: OpenAI InstructGPT

<https://tech.scatterlab.co.kr/luda-rlhf/>

<https://blog.getliner.com/신뢰성-있는-문서를-골라주기-위한-liner-ranker>

강의계획




- 수업 중에는 데이터 분석과 관련한 이론과 실습을 병행하여 배웁니다. (파이썬 기초를 배우는 수업이 아닙니다!)
- 팀프로젝트를 통해 데이터 분석 프로젝트를 진행합니다.
 - 특정 문제 및 데이터를 선택하고 여러 분석 기법 등을 적용하고 분석하여 인사이트를 발굴합니다.
 - 파이썬 기초 문법 지식이 부족하거나 팀프로젝트를 원치 않는 학생들은 다른 수업을 수강하기 바랍니다.

주차	강의 내용
1주차	- 오리엔테이션, 데이터 분석 소개
2주차	- 데이터 분석을 위한 파이썬 기초 및 (자료구조, 정규표현식, 병렬처리 등)
3주차	- Numpy, Panda, Matplotlib 소개
4주차	- Git / Github 소개 및 실습
5주차	- 데이터 시각화
6주차	- 프로젝트 계획 발표
7주차	- 크롤링을 통한 데이터 수집 실습 - 데이터 정제 및 분석
8주차	- 중간고사

주차	강의 내용
9주차	- 데이터 분석을 위한 통계
10주차	- 기계학습 1 (Supervised learning)
11주차	- 기계학습 2 (Unsupervised learning)
12주차	- 딥러닝 기초 및 실습 - 기초 통계
13주차	- LLM 및 프롬프트 엔지니어링을 이용한 데이터 분석
14주차	- 프로젝트 최종 발표
15주차	- 기말고사

다음의 학생들은 다른 강의를 수강하기 바랍니다.



팀플을 원하지 않는 학생

- 팀프로젝트 과제는 전체 성적에서 높은 비중을 차지합니다. (35%)
- 팀프로젝트를 원하지 않거나 적극적으로 참여하지 않을 학생들은 해당 강의를 듣지 않기 바랍니다.
- 팀프로젝트 과제는 결과, 참여도 등을 기반으로 정량적/정성적으로 복합적으로 공정하게 평가할 예정입니다.

파이썬 기초 지식이 없는 학생

- 수업에서 파이썬 기초 문법은 빠르게 복습하고 넘어갈 예정이므로 파이썬 문법 및 기초 프로그래밍 지식이 없는 학생은 다른 강의를 듣기 바랍니다.

수업에 적극적으로 참여하지 않거나 수업 예절이 부족한 학생

- 수업에서 많은 것을 배워가기 위해 적극적으로 참여 바랍니다. (적극성은 사회에서 중요한 소양!)
- 수업에 매너있게 적극적으로 참여할 준비가 부족한 학생은 수강하지 않기 바랍니다.
- 기타 점수로 **수업참여 5점(좋은 질문에 가산점)**, **실습 태도 5점(태도 불량한 경우 점수 차감)**이 있습니다.

Team Project?



- ChatGPT를 통해 단순히 풀 수 있는 문제가 아닌 **복잡하고 창의적인 실전 경험**이 중요합니다.
 - 그렇기 때문에 프로젝트 과제(**Semester-long Hackathon**)를 진행합니다.
 - 이를 통해 포트폴리오를 쌓고 더 발전된 프로젝트를 진행할 수 있는 능력을 배양할 수 있습니다.
- 실제 회사에서 하는 대부분의 일이 팀 단위로 이루어집니다.

팀은 매번 조정될 수 있고 매 분기마다 새로운 사람들과 업무를 진행할 수도 있습니다.

 - 그렇기 때문에 **커뮤니케이션 및 협업 능력**이 중요합니다.
 - 좋은 조직(회사)은 협업을 원치 않는 지원자는 전혀 뽑지 않습니다.
- “**팀프로젝트 하면 열심히 하는 사람만 고생이고 남들은 열심히 안하던데...**”
 - 과연 역할 분배 및 팀원 관리를 잘 했나요?
 - 무임승차는 슬랙 및 깃헙 기여도 등을 고려해서 탐지할 예정이고, 강한 패널티(감점)가 있을 예정임

강의계획



- 수업 진도 및 실습 강의실 상황 등에 따라 수업 계획이 변경될 수 있습니다.
- 휴강이 생기는 경우 (연휴 등) 녹화 강의 또는 강의 보충 기간에 보강할 계획입니다.
- **과제는 팀프로젝트로** 진행할 예정입니다. (추후 공지 예정)
 - 공정성 및 협업 경험을 위해 랜덤하게 팀을 구성(3~5명 예상)할 예정입니다.
 - 무임승차 금지! 팀내 참여도도 성적에 반영할 예정입니다.
 - 팀프로젝트에 성실히 참여하지 않을 학생은 수강하지 않기 바랍니다.
- **상대평가**
 - 출석: 5%
 - 과제물: 35% (프로젝트 기획 10%, 최종 과제 25%)
 - 중간: 20%
 - 기말: 30%
 - 기타: 실습태도(5점), 수업참여(5점)

지켜주세요!




출석은 중요합니다! 💪

- 학칙 제71조 : 총 수업시간의 1/3 초과 결석한 경우 「F」등급 또는 「부」 부여
- 무단 결석의 경우 1점, 수업의 1/2 초과 지각의 경우 0.5점을 출석 점수에서 감점
- 예비군, 법정 인정 질병 등의 경우 공결 신청서 및 증빙 서류 제출
 - 소속 대학장이 공결 인정 여부를 판단
 - 감기 등의 단순 질병은 인정하지 않을 예정입니다.
 - 수업 자료를 보고 공부한 내용 및 궁금한 사항들을 정리하여 제출하면 대체출석 인정

과제 및 시험과 관련하여 부정행위(표절 및 커닝)이 적발될 경우 F 등급 부여 및 징계 예정 🚫

- 시험은 오프라인으로 필기시험 형태로 진행할 예정입니다. (전자기기 사용 금지)
- 성숙한 지성인의 모습을 보여주세요.

도와주세요!



수업 예절을 지켜주세요 🚫

- 수업에 피해가 가는 행동(떠드는 행위, 과도한 스마트폰 사용 등)은 절대 하지 말아주세요. 🚫
- 밤을 새서 잘 것 같으면 뒷자리로...
- 수업에 방해가 되거나 예절이 없는 행위를 한 경우 해당 수업 결석처리 예정

도와주세요! 🙏

- 적극적으로 수업에 참여해주세요! 질문은 언제나 환영입니다.
적극성은 실제 취업 등 사회에서 필수 덕목입니다.
- 좋은 강의가 될 수 있도록 여러분들의 참여와 도움 많이 부탁드립니다!

데이터 분석의 이해



- 데이터 분석 정의

- 데이터 (Data)

- 객관적 사실(Fact) 혹은 정보를 표현(Representation)한 것
 - 숫자, 문자, 이미지, 오디오, 동영상 등의 형식으로 나타낸 모든 것을 의미
 - 데이터의 가공과 분석을 통해 인사이트(Insight)를 도출하고, 이를 통해 문제를 해결하거나 의사 결정에 참고

- 데이터와 정보의 차이는?

- 데이터 분석이란?

- 문제 해결 또는 인사이트 도출을 위한 목적으로 데이터 수집, 전처리 (가공) 및 정형화를 통해 현상을 분석하는 과정
 - 다양한 기술을 조합하여 서로 다른 비즈니스, 과학, 사회과학 등 다양한 분야에 사용
 - 최근 의사 결정을 더욱 과학적이고 효율적으로 운영할 수 있도록 도와주는 중요한 역할

"Big" Data

- 데이터는 지속적으로 가파른 속도로 생산되고 저장되고 있음
- SNS, 사물인터넷, 자율주행 자동차의 출현은 그 데이터의 양을 증폭시킬 것
- 자율주행 자동차는
 - 하루 8 시간 마다 약 40 TB 데이터 생성
 - 평균적 보통 사람은 하루에 인터넷 사용으로 약 650MB 데이터를 생산, 2020 년 1.5GB생산
 - 자율 주행 차량 하루 생산 데이터는 2,666명의 인터넷 사용자와 동일




그림 - IDC Datasphere growth

컴퓨팅 파워의 발전

- 매우 빠르게 증가하고 있는 데이터를 처리하기 위해 컴퓨터의 계산 속도도 매우 빠르게 발전 중
- 이를 통해 이전에는 불가능했던 빅데이터의 분석이 가능해짐

□ 기상청 슈퍼컴퓨터 1~5호기 성능 비교

구분	1호기	2호기	3호기	4호기	5호기
계약일	1999.2.24.	2004.4.27.	2009.9.7.	2014.6.20.	2019.7.26.
설치일	2000.9.27.	2005.12.5.	2010.12.13.	2015.12.14.	2021.6.21.
시스템	NEC SX-5/28	CRAY X1E	CRAY XE6	CRAY XC40	LENOVO SD650
이론 성능 (TF, PF ²)	0.224TF	18.5TF	초기분: 37TF 최종분: 758TF	초기분: 0.4PF 최종분: 5.8PF	초기분: 1.9PF 최종분: 51PF
CPU 수	28	1,024	초기분: 3,392 최종분: 90,240	초기분: 10,752 최종분: 139,392	초기분: 20,448 최종분: 612,864
전지구 모델	해상도 55km	해상도 30km	해상도 25km	해상도 10km	해상도 8km~
운영현황	불용 폐기	불용 폐기	일부 무상양여 및 관리전환, 일부 불용 폐기	현업 운영 중	초기분 운영 중 최종분 운영준비
장비 도입가 (계약 금액)	166억원 (1,300만달러+10억원) (1\$=1,203.00원)	485억원 (4,238만달러+12.6억원) (1\$=1,114.00원)	541억원 (4,102만달러+39.4억원) (1\$=1,234.50원)	552억원 (5,051만달러+37.2억원) (1\$=1,018.30원)	628억원 (4,469만달러+100.6억원) (1\$=1,179.80원)

그림 출처
(한국경제)




그림 출처 - AMD





그림 출처 - AppleInsider

인공지능의 발전

- 빠르게 쌓이는 데이터의 양과 컴퓨팅 리소스 발전과 더불어 인공지능이 급격히 발전하고 있음
- Ex) LLM, Stable-Diffusion
- Scaling Law
 - 모델의 사이즈와 데이터의 크기를 키울수록 모델의 성능이 증가함



LLM training datasets are growing

Datasets used to train key machine learning models have rapidly increased in size since 2017.



데이터 분석의 필요성

- 현상의 이해


- 데이터를 분석하여 현상 혹은 현재 상황을 이해할 수 있음
- Ex) 사람들의 검색 키워드를 분석해서 현재 어떤 트렌드가 뜨고 있는지 파악

- 인사이트 도출

- <https://youtu.be/2A8NeIGuWgl?si=asOrMDNzCQyQvKat&t=171>
- 데이터의 기본적인 통계를 넘어 잠재적 의미를 분석하여 의미를 찾고, 이를 통해 지식과 지혜를 발굴

- 의사결정 판단

- 데이터를 분석하고, 그 결과를 정책과 비즈니스의 중요한 결정을 내리는데 사용
- A/B Test



데이터 분석의 필요성

- 문제 해결

- 데이터 분석을 통해 특정한 문제를 풀기 위한 방법을 찾음
- Ex) 2차세계대전 전투기 생존 분석 (생존자 편향)
- 추천시스템을 통한 매출 증대

사용자 이벤트/상호작용
(예: 클릭 수, 가입 수, 대화)

상품 메타데이터
(예: 상품, 비디오,
상품 상세 내용)

사용자 메타데이터
(예: 나이, 위치)





그림 출처 - 한빛출판사




데이터 분석의 필요성

- 데이터의 가공
 - 데이터 중복 제거, 불필요/부적절 데이터 제거
 - 데이터의 편향 제거
- 인공지능 모델 학습
 - 모델의 학습 옵션 탐색
 - 모델의 성능을 분석하고 장단점을 찾아 이후 학습 프로세스에서 개선

Dataset	% of examples	Avg. # turns	Avg. # tokens	Avg. # tokens in context	Avg. # tokens in final response
General English	52.66%	6.3	974.0	656.7	317.1
Code	14.89%	2.7	753.3	378.8	374.5
Multilingual	3.01%	2.7	520.5	230.8	289.7
Exam-like	8.14%	2.3	297.8	124.4	173.4
Reasoning and tools	21.19%	3.1	661.6	359.8	301.9
Long context	0.11%	6.7	38,135.6	37,395.2	740.5
Total	100%	4.7	846.1	535.7	310.4

학습 데이터 분석 예, 그림 출처 – LLAMA 3 Papaer



모델 성능 분석 예, 그림 출처 – LLAMA 3 Papaer

데이터 분석 활용 예시



표 1-2. 데이터 분석 국외 활용 사례


분류	국외 기업	활용 내용
고객 관계 관리 / 경험의 변화	아비바생명	고객 맞춤형 보험 상품 제공
고객 관계 관리 / 경험의 변화	사우스웨스트항공	고객 맞춤형 광고
	타겟	고객 맞춤형 상품 프로모션
	넷플릭스	시청자들의 행동 관찰, 선호도 분석을 통한 맞춤형 콘텐츠 제작
	스타벅스	데이터 기반의 상권 분석, 소비자 정보 기반의 추천 서비스
내부 프로세스 / 효율성 개선	DHL	물류 효율화, 투자 의사결정에 참고
	자라(Zara)	효율적인 물류 배송망 운영
	구글	데이터 센터 성능 및 에너지 사용 최적화
	테슬라	데이터 분석을 통해 의사결정을 내리는 데이터 드리븐(Data Driven) 경영 방식 도입
신규 가치 제안 창출	아마존	고객 주문 전에 예측 배송
	GE	산업 인터넷으로 스마트 공장 구현
	후지쯔	농업용 빅데이터 분석 솔루션 제공

표 1-3. 데이터 분석 국내 활용 사례

분류	국내 기업	활용 내용
고객 관계 관리 / 경험의 변화	신한카드	고객 라이프 스타일 맞춤형 상품
	KB국민카드	소비자 정보 기반 카드 이용 및 편의성 서비스
	엔씨소프트	사기 탐지(Fraud Detection) 알고리즘을 통한 불법 행위 모니터링
	옥션, G마켓, 11번가	고객 구매력에 따른 개인화된 상품 추천과 광고 배달
내부 프로세스 / 효율성 개선	삼성SDS	제조업 생산성 향상 지원 솔루션
	이마트	데이터 분석을 통해 의사결정을 내리는 데이터 드리븐(Data Driven) 경영 방식으로 생산한 자체생산(PB) 상품
신규 가치 제안 창출	SK텔레콤	상권 분석 및 타겟 마케팅 지원 서비스

참고) 데이터 분석을 위한 전처리와 시각화 with 파이썬

데이터 분야 직군



다양한 데이터 관련 직군





그림 참고 - <https://www.codestates.com/blog/content/데이터-과학자-현실>

성장 중인 데이터 분야 직군



Software Developer

#3 in 100 Best Jobs

Software developers need to be innovative, creative and, of course, technical in order to succeed in this field. They might write new code or fix bugs in code to make it work better. [Read More »](#)

Projected Jobs
410,400

Median Salary
\$127,260

Education Needed
Bachelor's



Data Scientist

#8 in 100 Best Jobs

Data scientists use technology to glean insights from large amounts of data they collect. [Read More »](#)

Projected Jobs
59,400

Median Salary
\$103,500

Education Needed
Bachelor's



Statistician

#12 in 100 Best Jobs

Statistics is the science of using data to make decisions. This is relevant in almost all fields of work and there are many opportunities for employment. [Read More »](#)

Projected Jobs
10,500

Median Salary
\$98,920

Education Needed
Master's

그림 참고 - <https://money.usnews.com/careers/best-jobs/rankings/the-100-best-jobs>

[네이버웹툰] Data Scientist (추천시스템 ML모델링) (경력)

Share Save

Tech | AI/ML | 경력 | 정규 | 2024.08.13 ~ 2024.09.08



당근 팀과 함께 할
멋진 동료를 찾고 있어요!

전체 직군 (79) 전체 계열 (2) 전체 고용형태 Q data

Data Analyst - Enterprise-wide 당근 정규직

Data Analyst - 검색 New 당근 정규직

Data Analyst - 광고 서비스 당근 정규직

Data Analyst - 당근페이(Growth) 당근페이 정규직

Data Analyst - 로컬 비즈니스 당근 정규직

Data Analyst - 커뮤니티 New 당근 정규직

Manager, Data Analyst (Coupang Advertising)



서울

Data Analyst 집중 채용


비즈니스분석 · 제품분석 · SQL · 데이터시각화 · 집중채용

Product Data Analyst

Product Data Analyst | 경력 | 정규직

데이터 분석 관련 채용 중인 국내 회사들 (네이버 웹툰, 당근, 토스, 라이너 등)

데이터 분석가 / 데이터 사이언티스트가 되려면...



- 데이터 분석가 되려면 여러 분야의 지식 및 경험을 갖추어야 함.

Computer Science

- 파이썬 프로그래밍
- 데이터 시각화
- 자료구조
- 알고리즘
- 데이터베이스
- 운영체제
- 네트워크, 클라우드
- 인공지능 / 기계학습
- 오픈 소스 경험
- ...

Math

- 선형대수
- 확률/통계
- 미적분
- 최적화
- ...

Domain Data

- 분석하려는 데이터에 대한 이해, 지식
- 컴퓨터 과학 이외의 자연과학, 인문학이 필요할 수 있음
- ...

그 외

- 분석 능력, 창의력
- 영어 능력
- 커뮤니케이션 능력
- ...



Q&A