

정규식 기본문법

01 문자 다루기

02 반복 다루기

03 문자열 다루기



학습 목표

- ✓ 정규식의 개념과 용도를 이해한다.
- ✓ 정규식을 적절히 활용하는 방법을 습득한다.



학습 내용

1. 정규식으로 문자 다루는 법
2. 정규식으로 문자의 반복을 다루는 법
3. 정규식으로 문자열을 다루는 법



정규식 기본 문법

01 문자 다루기

02 반복 다루기

03 문자열 다루기

정규식이란?

정규식(Regular Expression, Regex)의 개념

- 텍스트 패턴을 정의하는 표현식으로, 특정 문자열을 검색, 검사, 치환하는 데 사용
- 다양한 프로그래밍 언어에서 지원하며, 입력 검증, 데이터 추출, 문자열 변환 등에 활용

주요 기능

- 특정 패턴의 문자열 찾기 (search, match)
- 문자열 변환 및 치환 (replace, sub)
- 데이터 필터링 (validate, sanitize)

기본 예시

정규식	설명	매칭 예시
\d+	숫자(0~9) 하나 이상	123 또는 4567
[a-zA-Z]+	영문자 하나 이상	hello 또는 SecureCoding
\w+@\w+\.\w+	이메일 패턴	user@example.com

(.*)

정규식이란?

사용자 입력 내용 검증

- 이메일 형식 확인 : `\w+@\w+\.\w+`
- 우편번호(숫자 5자리) 확인 : `\d{5}`

user@example.com (O)


user@@example (X)

12345 (O)

12a45 (X)

특정 패턴의 데이터 찾기

- 전화번호 찾기 : `/010-\d{4}-\d{4}/`
검색 결과: "내 번호는 010-1234-12345번이야"
- "Error"로 시작하는 로그 메시지 찾기 : `/^Error:.+ /`
검색 결과: "Error: 파일을 찾을 수 없습니다."



Parse: username@domain.TLD (top level domain)

출처: <https://kottke.org/21/07/a-history-of-regular-expressions-and-artificial-intelligence>

정규식 활용 사례

정규식은 어디에서 활용될까?

- 로그 분석: 서버 로그에서 특정 패턴을 포함한 로그 검색
- 데이터 변환 및 정제: 대량의 CSV, JSON 데이터를 필터링
- 보안 필터링: SQL Injection, XSS, Command Injection 탐지
- 웹 크롤링: HTML 소스에서 특정 데이터 추출

 정규식은 다양한 분야에서 활용되지만, 잘못 사용하면 성능 저하와 보안 문제가 발생할 수 있음

정규식 문자 다루기

문자 다루기

정규식	설명	매칭 예시
.	아무 문자나 하나	a, b, c
[abc]	a, b, c 중 하나	aaa, abc, cca, bbbbbbacacac
[a-z]	소문자 알파벳 (a~z)	hello, secure
[A-Z]	대문자 알파벳 (A~Z)	SECURE, TEST
[0-9]	숫자 (0~9)	123, 9876
[a-zA-Z0-9]	영문 대소문자 + 숫자	Hello123
[^a-z]	소문자가 아닌 문자	HELLO, 123, !@#

정규식 문자 다루기

기본 문자 클래스 (Character Class)

정규식	설명	매칭 예시	비고
\d	숫자 (0~9)	123, 4567	[0-9]와 동일
\D	숫자가 아닌 문자	abc, @!\$	[^0-9]와 동일
\w	영문자 + 숫자 + _	hello, user_123	[a-zA-Z0-9_]와 동일
\W	영문자/숫자가 아닌 기호	!@#, %^&*()	[^a-zA-Z0-9_]와 동일
\s	공백 문자 (띄어쓰기, 탭, 개행 등)	"Hello World"	[\t\n\r\f\v]와 동일
\S	공백이 아닌 문자	"Hello", "123!"	[^ \t\n\r\f\v]와 동일
\h	수평 공백 (스페이스, 탭)	Hello World	[\t]와 동일
\H	수평 공백이 아닌 문자	Hello123	[^ \t]와 동일
\v	수직 공백 (개행, 폼 피드 등)	\n, \r, \f	[\n\r\f]와 동일
\V	수직 공백이 아닌 문자	Hello123	[^ \n\r\f]와 동일
\b	단어 경계 (Word Boundary)	" hello " (○) "sayhello" (✗)	\bhello\b
\B	비단어 경계 (Not a Word Boundary)	"sayhello" (○) " hello " (✗)	\Bhello\B



정규식 기본 문법

01 문자 다루기

02 반복 다루기

03 문자열 다루기

반복 다루기

반복 메타문자

정규식	설명	매칭 예시	비고
a+	a가 1번 이상 반복	a, aa, aaa	최소 1개 이상
b*	b가 0번 이상 반복	`, b, bbb	b가 없어도 됨
c?	c가 0번 또는 1번 등장	`, c	c가 최대 1개
\d{3}	정확히 3개의 숫자	123, 987	{n} 사용
\d{2,4}	2~4개의 숫자	12, 4567	{n,m} 사용
\d{2,}	2개 이상 숫자	12, 45678	{n,} 사용
(hi)+	'hi'가 1회 이상 반복되는 패턴	hi, hihi, hihhihi	전체 패턴 ('hi')이 반복되어야 함
(ab){2,}	'ab'가 2회 이상 반복되는 패턴	abab, ababab, abababab	전체 그룹 ('ab')이 반복되어야 함

반복 다루기

실무 활용 예시

사용 목적	정규식	매칭 예시
숫자 6자리 (주민번호 앞자리 등)	<code>^\d{6}\$</code>	901231 (○), 90123 (✗)
영문자/숫자/밑줄로 구성된 5~12자리 ID	<code>^[A-Za-z0-9_]{5,12}\$</code>	user_01 (○), a!23 (✗)
전화번호 형식 검증	<code>^\d{2,3}-\d{3,4}-\d{4}\$</code>	010-1234-5678 (○), 02-4567 (✗)
이메일 주소 형식	<code>^[\\w\\.\\-]+@[\\w\\.\\-]+\\.\\w{2,3}\$</code>	user@example.com (○), user@com (✗)
URL 시작 형식 검사	<code>^https?://[\\w\\.\\-]+</code>	https://example.com (○), ftp://example.com (✗)



정규식 기본 문법

01 문자 다루기

02 반복 다루기

03 문자열 다루기

문자열 다루기

문자열의 시작과 끝

정규식	설명	매칭 예시
<code>^error</code>	"error"로 시작하는 문자열 찾기	"error: not found" (○), "no error" (✗)
<code>end\.\$</code>	마침표로 끝나는 "end." 찾기	"This is the end." (○), "the end!" (✗)

단어 경계

정규식	설명	매칭 예시
<code>\berror\b</code>	독립적인 단어 "error" 찾기	"error occurred" (○), "terror" (✗)
<code>\Bing</code>	"ing"가 단어 중간에 있는 경우 찾기	"running", "singing"

특정 문자열 포함 여부 검사

정규식	설명	매칭 예시
<code>apple</code>	"apple" 포함 여부 검사	"I like apple" (○), "I like oranges" (✗)
<code>foo bar</code>	"foo" 또는 "bar" 포함 여부 검사	"barbeque" (○), "ba rricade" (✗)
<code>.*test.*</code>	"test"가 포함된 문자열	"unit test passed" (○)
<code>^(?!admin).+</code>	"admin"으로 시작하지 않는 문자열	"user123" (○), "admin123" (✗)

문자열 다루기

자주 사용되는 정규식

사용 목적	정규식	매칭 예시
날짜 형식(YYYY-MM-DD)으로 찾기	<code>\b\d{4}-\d{2}-\d{2}\b</code>	"2024-05-08" (○), "24-5-8" (✗)
대소문자 구분 없이 "password" 찾기	<code>(?i)password</code>	"Password123" (○), "passWord" (○)
로그에서 http 또는 https로 시작하는 URL 찾기	<code>https?://[^\s]+</code>	"https://abc.com" (○), "abc.com" (✗)
영문자+숫자 8자 이상 검사	<code>^[A-Za-z0-9]{8,}\$</code>	"Secure12" (○), "pass!" (✗)
대문자+숫자 포함된 6자 이상 비밀번호 검사	<code>(?=.*[A-Z])(?=.*\d).\{6,}</code>	"Secur3" (○), "secure" (✗)

정규식 시각적 이해

정규식 디버깅 및 시각적 학습 도구

1. REGEXPER(regexper.com)


정규식을 이미지로 표시해 주는 사이트

2. RegExr(regexr.com)

정규식을 실시간으로 테스트하고 학습할 수 있는 사이트

3. regex101(regex101.com)

정규식 패턴을 해석하고, 다양한 정규식 엔진을 지원



정규식은 한눈에 이해하기 어렵기 때문에 시각적 도구를 활용하여 디버깅하면 더욱 효과적임



요약 정리

- 정규식은 텍스트 패턴을 정의하는 표현식으로, 특정 문자열을 검색, 검사, 치환, 필터링하는 데 사용
- 정규식을 활용하여 데이터 검증, 보안 필터링, 로그 분석 등을 효과적으로 수행할 수 있다.
- 정규식은 강력한 도구이지만, 올바르게 사용해야 효과적이다.



참고 문헌

- [KISA] 소프트웨어 개발 보안 가이드(2021.12.29)
- [KISA] 소프트웨어 보안약점 진단가이드(2021)
- 정규식 도식화 - <https://regexper.com/>
- 정규식 테스트 - <https://regexr.com/>
- 정규식 테스트 - <https://regex101.com/>
- 정규식 시각화 - <https://jex.im/regulex/>

The background is a vibrant blue gradient. It is decorated with various abstract elements: a large sphere with a gradient in the top left, a smaller sphere with diagonal stripes in the top right, and another sphere with horizontal stripes in the bottom left. Several network-like structures, consisting of small circles connected by thin lines, are scattered across the image. There are also solid-colored rectangles and trapezoids in different shades of blue. The central text is in a bold, white, sans-serif font.

감사합니다.



퀴즈

1. 정규식에서 ^ (Caret) 기호의 의미로 알맞은 것은?

- 1) 특정 단어를 강조하는 역할
- 2) 문자열의 시작을 의미
- 3) 숫자만 매칭하는 역할
- 4) 공백을 무시하는 역할

2. 다음 중 정규식 $a^?b$ 가 매칭할 수 있는 문자열은 무엇일까요? (2개)

- 1) b
- 2) ab
- 3) aabb
- 4) abc

3. 정규식을 사용할 때, 특정 문자가 한 번 이상 반복될 경우 사용할 수 있는 기호는 무엇일까요?

()



퀴즈 정답

1. 정규식에서 ^ (Caret) 기호의 의미로 알맞은 것은?

2) 문자열의 시작을 의미

^hello라는 정규식은 "hello"로 시작하는 문자열을 찾습니다.

2. 다음 중 정규식 $a?b$ 가 매칭할 수 있는 문자열은 무엇일까요? (2개)

1) b

2) ab

?는 앞의 문자가 0번 또는 1번 나올 수 있음을 의미합니다.

3. 정규식을 사용할 때, 특정 문자가 한 번 이상 반복될 경우 사용할 수 있는 기호는 무엇일까요?

(+)

+는 앞에 나온 문자가 한 번 이상 반복될 경우 매칭할 때 사용합니다.